

Regression Analysis

1. Introduction | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division
Korea Institute of Oriental Medicine

2026-09-01

Introduction

회귀분석이란

? 연구 질문

❓ 이 장의 질문: 회귀분석이란 무엇이며, 어떤 절차로 수행하는가?

❓ 연구 질문

- 구리 함량과 중성자 조사량이 이 정도일 때 압력용기의 천이온도는 평균적으로 얼마나 올라가는가
- 특정 에너지 대역에서 검출기의 계수 효율은 평균 얼마인가
- 1 Gy를 받은 집단에서 암 위험도는 평균적으로 얼마나 커지는가

세 질문의 공통 형태: 특정 조건이 주어졌을 때의 평균

- 측정 반복으로는 답이 나오지 않음. 조건이 같아도 결과는 매번 다름
- 회귀분석 = 흩어짐을 인정한 채 조건과 결과의 관계를 하나의 식으로 요약

회귀의 의미

◎ 용어의 기원

회귀(regression, 回歸)는 본래 이전 상태로 되돌아감을 뜻하며, 통계학에서는 평균(mean)으로의 회귀를 의미
회귀분석은 변수들 사이의 함수 관계를 자료로부터 탐색

Role	Symbol	분야별 다른 이름
반응변수 response variable	y	종속변수(dependent), 출력변수(output), target
설명변수 explanatory variable	x	독립변수(independent), 입력변수(input), 예측변수(predictor), covariate, regressor, factor, carrier


The two roles in a regression model, and the names used for them across fields

≡ 응용 분야

- 자연·공학 물리학, 화학, 공학, 기상학
- 생명·의학 의학, 생물학
- 사회·경제 경제학, 재무, 법학, 사회학, 심리학
- 교육·기타 교육학, 스포츠과학, 역사학

Galton과 회귀의 기원

≡ 중간부모의 키와 자녀의 키



Mid-parent height (explanatory variable) versus child height (response variable), $n = 898$ children of 197 families, in inches. The red line is $y = x$, the blue line is the least-squares fit.

📖 Sir Francis Galton (England, 1822-1911)

- 회귀(regression)라는 이름을 처음 붙인 사람
- 부모와 자식의 신체 특성이 어떻게 이어지는지를 자료로 따져 본 사람



⚠ 자료에 관한 주의

- 골턴이 직접 모은 **가족 기록**. 197개 가족의 자녀 898명
- 가로축은 **중간부모** = (아버지 + $1.08 \times$ 어머니) $\div 2$
- 빨간 선 $y = x$ 보다 파란 적합선이 **완만함**
- 이 기울기 차이가 회귀의 근거

Galton, F. (1886). Regression towards mediocrity in hereditary stature. *Journal of the Anthropological Institute of Great Britain and Ireland*, 15, 246-263. / Pearson, K. and Lee, A.

주변분포와 조건부분포

조건에 따른 분포 이동



❓ 질문 1. 아무 정보 없이 자식 한 명의 키를 예측한다면

전체 평균 69.2인치 = 조건을 걸지 않은 **주변분포(marginal distribution)**의 평균 $E(Y)$

- 기호 $E(\cdot)$ 는 기댓값(expectation), 곧 이론적인 평균

❓ 질문 2. 중간부모의 키가 72인치라는 조건이 있다면


조건을 만족하는 집단 안의 평균 = **조건부분포(conditional distribution)**의 평균 $E(Y | X = 72)$

- 해당 구간(72 ± 0.75 인치, 62명)의 표본평균: 70.8인치
- 회귀직선 $\hat{y} = 18.8 + 0.729x$ 가 $x = 72$ 일 때 71.3인치

질문 1 (marginal)에서 질문 2 (conditional)로의 전환이 회귀분석의 시작

국소평균과 회귀직선

조건 세분화



- 중간부모 키를 **1인치 구간**으로 나누어 조건이 여러 개로 확장
- 구간마다 구한 자녀 키의 평균은 **국소평균(local mean)**
- 관측이 10명 미만인 구간(회색 띠)은 평균의 흔들림이 커서 제외

국소평균들이 거의 하나의 직선 위에 놓임 → 최소제곱 회귀직선

회귀의 정의

◎ 정의


회귀(regression)란 설명변수 $X = x$ 가 주어졌을 때 반응변수 Y 의 조건부 기댓값이다.

$$E(Y | X = x)$$

- Y : 반응변수
- X : 설명변수
- x : 설명변수가 갖는 특정한 값 하나
- $E(Y | X = x)$: $X = x$ 일때 조건부 평균

ㄴ 그림 읽는 법

- 각 x 마다 Y 의 분포가 하나씩 존재
- 그 분포의 중심이 회귀직선 위에 위치
- 회귀직선은 그 중심들을 이은 선



Regression is the conditional mean of Y given $X = x$. At each x the conditional distribution of Y is centred on the regression line, with the residual standard deviation estimated from the data.

두 변수가 함께 종 모양의 좌우대칭 분포(이변량 정규분포)를 이루면, 이 조건부 기댓값은 정확히 직선

회귀모형과 선형회귀모형

◎ 회귀모형 (regression model)

$$X_1, X_2, \dots, X_p \longrightarrow Y, \quad Y = f(X_1, X_2, \dots, X_p) + \varepsilon$$

- Y : 반응변수
- $X_1, \dots, X_p$: p 개의 설명변수
- ε : 확률오차(random error)
- f : 설명변수 값이 주어졌을 때 Y 의 조건부 평균, 곧 $f(x) = E(Y \mid X = x)$

◎ 선형회귀모형 (linear regression model)

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

- $\beta_0, \beta_1, \dots, \beta_p$: 회귀모수(regression parameters), 회귀계수(coefficients)
- f 의 모양을 모르므로 **가장 단순한 형태인** 일차식으로 가정

❗ Remark

- 회귀모수 = 자료에서 추정해야 할 **미지의 상수(unknown constants)**
- 자료가 바뀌면 추정값은 바뀌나, 추정 대상인 모수 자체는 고정

Galton 자료: 모형 적합

田 결과

Term	Estimate	SE	<i>t</i> value	<i>p</i> -value
(Intercept) $\hat{\beta}_0$	18.8	2.84	6.61	< 0.001
x (mid-parent height) $\hat{\beta}_1$	0.729	0.0410	17.8	< 0.001

Least-squares fit of child's height on mid-parent height, $n = 898$, from Galton's family records.

Source	Df	Sum Sq	Mean Sq	<i>F</i> value	<i>p</i> -value
x	1	1575	1575	316	< 0.001
Residuals	896	4469	4.99	n.a.	n.a.

Analysis of variance for the fitted simple linear model. R-squared = 0.261, residual SD = 2.23 inches.


田 표의 용어

- 표준오차(SE): 같은 조사를 되풀이할 때 추정값이 얼마나 흔들리는지를 재는 값
- t 값: 추정값을 그 표준오차로 나눈 값. 절댓값이 클수록 추정값이 0에서 멀다
- p 값: 참값이 0이라고 할 때, 지금 자료에서 나온 것만큼 크거나 더 큰 값이 우연히 나올 확률

Preliminary Knowledge 참고

회귀분석의 8단계

≡ 전체 흐름



◎ 1단계, 연구 가설과 문제 설정이 가장 중요

1·2단계: 연구 질문과 변수 선택

? 예시: 기온과 판매량

✍ 1단계: 문제의 진술

- 답해야 할 질문을 한 문장으로 확정: **기온이 오르면 1인당 소비량의 평균이 올라가는가**
- 묻는 대상은 개별 소비량이 아니라 **평균**. 같은 기온의 기간이 여러 번 있어도 소비량은 매번 다름

≡ 2단계: 관련 변수의 선택

- 기온만으로 충분한가?
- 소비량에 영향을 줄 수 있는 다른 요인이 있을까?

요인	변수	유형	함께 재는 이유
날씨	<code>temp</code> 평균기온	양적	질문의 주인공
가격	<code>price</code> 아이스크림 가격	양적	비싸지면 덜 사 먹을 것
소득	<code>income</code> 가족 월수입	양적	여유가 있으면 더 사 먹을 것
시기	<code>year</code> 관측 연차	질적	해가 바뀌며 생긴 전반적 변화

Candidate drivers of ice cream consumption, and the reason each one was collected

3단계 자료 수집: 아이스크림 자료

田 30개 기간, 변수 6개

period	IC	price	income	temp	year	Variable	Symbol	설명 (단위)	Range	역할
1	0.386	0.270	78	41	0	period		기간 번호	1 – 30	식별자
2	0.374	0.282	79	56	0	IC	y_i	섭취량 (pint)	0.256 – 0.548	반응변수
3	0.393	0.277	81	63	0	price	x_{i1}	가격 (dollar)	0.260 – 0.292	설명변수
4	0.425	0.280	80	68	0	income	x_{i2}	월수입 (dollar)	76 – 96	설명변수
5	0.406	0.272	76	69	0	temp	x_{i3}	평균기온 (°F)	24 – 72	설명변수
6	0.344	0.262	78	65	0	year		연차 (0, 1, 2)	0 – 2	질적 설명변수

First six of the n = 30 four-week periods

Variables of the ice cream consumption data

- 행 = 관측(4주 단위의 한 기간),
- 열 = 변수. 관측 하나는 네 값의 묶음 $(y_i, x_{i1}, x_{i2}, x_{i3}), i = 1, \dots, 30$
- y 는 IC, x_1, x_2, x_3 은 각각 price, income, temp 를 가리킴

⚠ 주의 사항

- `year` 는 계절이 아니라 관측 연차(0, 1, 2). 30개 기간이 세 해에 걸쳐 수집되었음을 뜻함.
- 숫자처럼 보이지만 종류를 나누는 변수라 변수 처리 필요 → **Dummy Variable**

변수의 유형

◎ 양적 변수와 질적 변수

- 양적 변수(quantitative): 수치로 측정되는 변수
 - 일반 예: 가격, 소득, 기온, 조사량
 - 아이스크림 자료: `price`, `income`, `temp`
- 질적 변수(qualitative): 범주로 측정되는 변수
 - 일반 예: 제품 형태(용접재/판재/단조재), 성별(남/여)
 - 아이스크림 자료: `year`
 - 지시변수(indicator) 또는 가변수(dummy variable)로 바꾸어 모형에 넣음

회귀분석에서 반응변수는 양적, 설명변수는 양적 또는 질적 모두 가능.

i 참고: 변수 유형별 모형의 이름


Method	반응변수	설명변수
분산분석 (analysis of variance)	양적	질적
공분산분석 (analysis of covariance)	양적	양적, 질적 혼합
로지스틱회귀 (logistic regression)	질적 (보통 이항)	양적, 질적

Special names for regression models by the type of the response and the predictors.

4단계 모형 설정: 선의 후보

❓ 같은 산점도 위에 그을 수 있는 선은 무한함

- 직선 $E(IC \mid \text{temp}) = \beta_0 + \beta_1 \text{temp}$: 기온이 1도 오를 때마다 소비량의 평균이 늘 같은 폭으로 증가
- 곡선, 이차항 $\beta_0 + \beta_1 \text{temp} + \beta_2 \text{temp}^2$: 어느 기온부터 증가가 완만해지거나 꺾임
- 곡선, 로그 $\beta_0 + \beta_1 \log(\text{temp})$: 낮은 기온에서 민감하고 높은 기온에서 둔해짐



Three candidate shapes fitted to the same 30 observations: a straight line, a quadratic in temperature, and a log transform of temperature.

4단계 모형 설정: 모형의 분류

◎ 분류의 세 기준

4단계는 $E(Y \mid X = x)$ 를 어떤 형태의 식으로 적을지 정하는 일. 아이스크림 자료에서 고른 일차식은 여러 선택지 중 하나이며, 모형은 아래 세 기준으로 나뉨

무엇을 보는가	부르는 이름	판정하는 방법
모수가 들어간 방식	선형 / 비선형 linear / nonlinear	β_j 가 설명항에 곱해져 더해지면 선형, 아니면 비선형
설명항의 개수	단순 / 다중 simple / multiple	모형에 들어간 설명항이 하나면 단순, 둘 이상이면 다중
반응변수의 개수	일변량 / 다변량 univariate / multivariate	좌변의 Y 가 하나면 일변량, 둘 이상이면 다변량

Three criteria for classifying a regression model.

⚠ 주의 사항

- 선형인지는 그래프 모양이 아니라 β_j 가 들어간 방식으로 판정. 곡선을 그려도 선형모형일 수 있음
- $\log X$, X^2 처럼 변환한 항은 각각 별개의 설명항으로 간주
- 따라서 단순과 다중은 원변수의 개수가 아니라 모형에 들어간 항의 개수로 가름

모형의 분류: 연습

? 모형 6개 분류

1. $Y = \beta_0 + \beta_1 X_1 + \varepsilon$
2. $Y = \beta_0 + e^{\beta_1 X_1} + \varepsilon$
3. $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$
4. $Y_1 = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon_1$ 이고
 $Y_2 = \gamma_0 + \gamma_1 X_1 + \gamma_2 X_2 + \varepsilon_2$
5. $Y = \beta_0 + \beta_1 \log X_1 + \varepsilon$
6. $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$

판정 순서: 선형성 → 설명항의 개수 → 반응변수의 개수

모형의 분류: 정답과 해설

✔ 판정 결과

기준	해당 모형
선형 (linear)	1, 3, 4, 5, 6
비선형 (nonlinear)	2
단순 (simple)	1, 2, 5
다중 (multiple)	3, 4, 6
일변량 (univariate)	1, 2, 3, 5, 6
다변량 (multivariate)	4

Classification of the six example models.

💡 해설

- 2번은 β_1 이 지수 안에 들어가 있어 비선형
- 5번의 $\log X_1$, 6번의 X^2 는 변환된 항이지만 β_j 가 곱해져 더해지므로 선형
- 6번은 원변수가 X 하나여도 설명항이 X 와 X^2 로 두 개이므로 다중
- 모형이 선형이면 통상적인 회귀 소프트웨어를 그대로 사용. 1, 3, 4, 5, 6은 모두 같은 절차로 모수를 추정

5·6단계 적합 방법과 모형 적합

? 기준과 해법의 구분

◎ 5단계: 무엇을 가장 좋게 만들 것인가 (기준)

- **최소제곱법(least squares)**: 잔차의 **제곱합**을 최소로
 - 가장 보편적이며 이 강의에서 주로 다룰 내용
- **최대가능도법(maximum likelihood)**: 지금 자료가 관측될 **가능도**를 최대로 만드는 해
 - 오차가 정규분포를 따른다고 두면 **최소제곱과 같은 추정값**
- **최소절대편차(least absolute deviations)**: 잔차의 **절댓값 합**을 최소
 - 튀는 관측에 덜 흔들림

✍ 6단계: 그 기준의 최적점을 어떻게 찾을 것인가 (계산)



- **닫힌 해(closed solution)**: 정규방정식을 풀어 한 번에
 - $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$
- **경사하강법(gradient descent)**: 기울기를 따라 조금씩 내려가며 **반복**
 - 닫힌 해가 없거나 자료가 아주 클 때
- 두 방법은 **같은 최적점**을 향하는 서로 다른 경로
 - 오차제곱합은 아래로 볼록한 이차함수
 - $\mathbf{X}^\top \mathbf{X}$ 의 역행렬이 존재하면 최솟값은 하나뿐
 - 따라서 어느 길로 계산하든 **도달하는 해는 동일**

7단계 모형 검증과 비판

❓ 적합 이후의 점검

☞ 확인해야 할 사항

- 모형이 자료에 맞는가: 잔차에 굽은 자국이 남아 있지 않은가. 퍼짐이 한쪽에서만 커지지 않는가
- 한두 관측이 결과를 좌우하지 않는가: 멀리 떨어진 점, 그 점 하나를 빼면 기울기가 달라지는 점
- 모형에 사용한 변수 모두가 필요한가: 힘들게 모았더라도 설명에 보탬이 없다면 빼는 편이 나은가



Residual versus fitted value for the same 31 black cherry trees under two models: a straight line in girth (left) and a log-log model in girth and height (right).

8단계 선택된 모형의 사용

◎ 적합값과 예측값의 구분

6단계에서 얻은 계수를 $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ 라 하면, 8단계는 이 식에 설명변수 값을 넣어 답을 얻는 일

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip}, \quad i = 1, \dots, n$$

- $\hat{y}_i$: i 번째 관측의 적합값
- x_{ij} : i 번째 관측의 j 번째 설명변수 값

❓ 언제 적합값이고 언제 예측값인가

- 적합값(fitted value): 모형을 적합할 때 쓴 그 자료의 설명변수 값을 다시 넣어 얻은 값 $\hat{y}_i$
- 예측값(predicted value): 다른 표본, 다른 자료의 설명변수 값을 넣어 얻은 값 $\hat{Y}$
- 두 값의 계산식은 동일
- 넣은 설명변수 값이 자료 안의 관측이면 적합값, 자료 밖의 새 값이면 예측값
- 잔차 $e_i = y_i - \hat{y}_i$ 는 적합값에서만 정의됨

원자력 분야의 회귀분석 사례

☞ 세 사례의 공통 구조

Case	분야	반응변수 Y	어느 장에서 다루는가
조사취화 예측식 (ASTM E900)	재료	천이온도 변화량 TTS	Dummy Variable
감마선 효율 검교정	계측	검출 효율	Weighted Regression
원폭 생존자 선량-반응 (LSS)	역학	고형암 초과상대위험 ERR	Diagnosis & Variable Selection

Three regression problems from the nuclear field and the chapter that supplies the tool for each.

세 사례는 재료, 계측, 역학으로 분야가 다르지만 모두 설명변수가 주어졌을 때 반응변수의 조건부 기댓값 $E(Y \mid X = x)$ 를 추정하는 문제임

강의의 구성

≡ 장별 담당 단계

Step	단계	다루는 장
1~3	문제의 진술, 관련 변수의 선택, 자료 수집	Introduction
4	모형 설정	Preliminary Knowledge (행렬 표현), Simple Linear Regression, Multiple Linear Regression, Dummy Variable
5	적합 방법의 선택	Simple Linear Regression (최소제곱), Weighted Regression (가중최소제곱)
6	모형 적합	Simple Linear Regression, Multiple Linear Regression
7	모형 검증과 비판	Diagnosis & Variable Selection
8	선택된 모형의 사용	Simple Linear Regression (구간추정), Multiple Linear Regression (예측)

Mapping of the eight steps of regression analysis onto the chapters of this lecture.

참고문헌

회귀라는 이름의 출발점

- Galton, F. (1877). Typical laws of heredity. *Proceedings of the Royal Institution*, 8, 282-301. (완두콩 실험, 용어는 아직 *reversion*)
- Galton, F. (1885). Presidential address, Section H (Anthropology). British Association for the Advancement of Science. (*regression* 이 처음 등장, 중간부모 기울기 2/3)
- Galton, F. (1886). Regression towards mediocrity in hereditary stature. *Journal of the Anthropological Institute*, 15, 246-263. (성인 자녀 928명, 205가족)
- Pearson, K., & Lee, A. (1903). On the laws of inheritance in man. *Biometrika*, 2, 357-462.
- Gorroochurn, P. (2016). On Galton's change from "reversion" to "regression". *The American Statistician*, 70(2), 227-231. doi:10.1080/00031305.2015.1087876
- Stanton, J. M. (2001). Galton, Pearson, and the peas. *Journal of Statistics Education*, 9(3).

현장 사례의 출처

- ASTM E900-21e1. *Standard Guide for Predicting Radiation-Induced Transition Temperature Shift in Reactor Vessel Materials*. ASTM International.
- *Metals*, 12(3), 481 (2022). doi:10.3390/met12030481
- *Analytical Chemistry*, 91(7) (2019). doi:10.1021/acs.analchem.9b00119
- INMM Annual Meeting Proceedings. Weighted least squares fitting of gamma spectroscopy efficiency functions.
- Summary of radiation effects on incidence of solid cancers in the Life Span Study of atomic bomb survivors: 1958-2009. *Carcinogenesis* (2025).

교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.