

Regression Analysis

2. Preliminary Knowledge | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division
Korea Institute of Oriental Medicine

2026-09-01

Preliminary Knowledge

행렬 표기의 필요성

? 질문

- 회귀 = 조건부 기댓값 $E(Y \mid X = x)$
- 질문:** 조건부 기댓값을 계산하기 위해 필요한 수학적, 통계학적 도구는?

관측 하나마다 회귀식을 정의하려면 동일한 형태의 식이 n 개 필요

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 x_{11} + \cdots + \varepsilon_1 \\y_2 &= \beta_0 + \beta_1 x_{21} + \cdots + \varepsilon_2 \\&\vdots \\y_{30} &= \beta_0 + \beta_1 x_{30,1} + \cdots + \varepsilon_n\end{aligned}$$

- y_i : i 번째 관측의 반응변수
- x_{i1} : i 번째 관측의 첫 번째 설명변수 값
- $\beta_0, \beta_1, \dots$: 모든 관측에 공통인 회귀계수
- ε_i : i 번째 관측의 오차, n : 관측 수

≡ 특징

- 관측이 바뀌어도 식의 모양은 동일하고, 회귀계수 $\beta_0, \beta_1, \dots$ 는 모든 관측에 공통
- 같은 형태가 반복되므로 하나로 묶어 표기
- 행렬 표기는 이 n 개의 식을 한 줄로 축약

벡터와 행렬

◎ 정의

벡터: 숫자를 세로로 줄 세운 배열. 굵은 소문자 $\mathbf{y}$ 로 표기한다.

행렬: 숫자를 행과 열의 격자로 배열한 것. 굵은 대문자 $\mathbf{X}$ 로 표기한다.

차원: 크기는 항상 “행 $\times$ 열” 순서로 적는다.

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} (n \times 1), \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} (n \times (p+1))$$

💡 기호가 가리키는 것

- $\mathbf{y}$: 반응변수 $y_1, \dots, y_n$ 을 세로로 모은 벡터
- $\mathbf{X}$: 1열이 절편열(모두 1), 나머지 p 개 열이 설명변수 값인 설계행렬
- x_{ij} : i 번째 관측의 j 번째 설명변수 값
- n : 관측 수, p : 설명변수의 개수

✍ 표기 규약

- 원소 x_{ij} 의 아래첨자는 행 먼저, 열 나중
- 굵은 글씨는 벡터와 행렬, 아래첨자가 붙은 보통 글씨는 그 안의 개별 원소
- $\mathbf{X}$ 는 절편열을 포함한 $n \times (p+1)$ 설계행렬 전용 기호

행렬 연산

◎ 정의

덧셈·뺄셈: 크기가 같은 두 행렬끼리만 정의되며, 같은 자리의 성분끼리 더하거나 뺀다.

스칼라 곱 cA : 모든 성분에 같은 수 c 를 곱한다.

행렬 곱 AB : A 의 열 수와 B 의 행 수가 같을 때만 정의되며, (i, j) 성분은 A 의 i 행과 B 의 j 열을 짝지어 곱한 뒤 모두 더한 값이다.

$$\underbrace{\mathbf{A}}_{n \times k} \underbrace{\mathbf{B}}_{k \times m} = \underbrace{\mathbf{AB}}_{n \times m}, \quad (\mathbf{AB})_{ij} = \sum_{l=1}^k a_{il}b_{lj}$$

가운데의 k 가 서로 만나 사라지고 바깥의 n 과 m 만 남음

✔ 회귀식 세 줄을 한 번에 (3×2 곱하기 2×1)

$$\begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 6 \end{pmatrix} \begin{pmatrix} 3 \\ 5 \end{pmatrix} = \begin{pmatrix} 3 + 5 \cdot 2 \\ 3 + 5 \cdot 4 \\ 3 + 5 \cdot 6 \end{pmatrix} = \begin{pmatrix} 13 \\ 23 \\ 33 \end{pmatrix}$$

각 행이 $\beta_0 + \beta_1 x_i$ 한 줄

⚠ 순서를 바꾸면 값이 달라짐

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}$$

$$\mathbf{AB} = \begin{pmatrix} 3 & 2 \\ 1 & 1 \end{pmatrix} \neq \begin{pmatrix} 1 & 2 \\ 1 & 3 \end{pmatrix} = \mathbf{BA}$$

결합법칙 $(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC})$ 와 분배법칙 $\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}$ 는 성립하지만 교환법칙은 성립하지 않음

✂ 회귀에서의 쓰임: 관측 n 개의 회귀식 n 줄이 $\mathbf{X}\beta$ 한 덩어리로 묶임. $\mathbf{X}$ 가 $n \times (p + 1)$, β 가 $(p + 1) \times 1$ 이므로 결과는 언제나 $n \times 1$ 이 되어 $\mathbf{y}$ 와 크기가 맞음

특정 형태의 행렬: 대각 · 항등

◎ 정의

정방행렬(square matrix): 행 수와 열 수가 같은 행렬. 크기는 $n \times n$.

대각행렬(diagonal matrix) $\mathbf{D} = \text{diag}(d_1, \dots, d_n)$: 주대각선 밖의 성분이 모두 0인 정방행렬.

항등행렬(identity matrix) $\mathbf{I}_n$: 주대각선이 모두 1인 대각행렬. 곱셈에서 숫자 1의 역할을 하며 $\mathbf{A}\mathbf{I} = \mathbf{I}\mathbf{A} = \mathbf{A}$.

$$\mathbf{D} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 10 \end{pmatrix}, \quad \mathbf{I}_3 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

≡ 확인

✍ 곱셈이 행 단위로 끝남 (위 $\mathbf{D}$, $\mathbf{I}_3$ 로 확인)

- $\mathbf{D}\mathbf{A}$: $\mathbf{A}$ 의 1행 전체에 2, 2행에 5, 3행에 10을 곱한 것, 곧 관측별 가중
- $\mathbf{A}\mathbf{I}_3 = \mathbf{I}_3\mathbf{A} = \mathbf{A}$: 1을 곱한 것과 같아 아무것도 달라지지 않음
- 대각행렬끼리 곱해도 대각행렬: $\text{diag}(d_1, \dots, d_n) \text{diag}(e_1, \dots, e_n) = \text{diag}(d_1e_1, \dots, d_ne_n)$

✂ 회귀에서의 쓰임: 오차의 분산-공분산 구조를 $\text{Var}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}_n$ 한 줄로 적음(대각선은 모두 σ^2 , 나머지는 0 = 등분산 · 무상관). 가중회귀의 가중행렬 $\mathbf{W} = \text{diag}(w_1, \dots, w_n)$ 도 대각행렬이며 $\mathbf{W} = \mathbf{I}$ 이면 보통최소제곱과 같아짐

전치

◎ 정의

전치 $\mathbf{A}^\top$: 행과 열을 맞바꾼 행렬. $\mathbf{A}$ 의 (i, j) 원소가 $\mathbf{A}^\top$ 의 (j, i) 원소가 된다.

- $(\mathbf{A}^\top)^\top = \mathbf{A}$, $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$
- $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$: 곱의 전치는 순서가 뒤집힘
- $\mathbf{A}^\top = \mathbf{A}$ 인 정방행렬을 **대칭행렬**이라 함

≡ 확인

✍ 벡터의 전치: 세로가 가로로. 3×1 이 1×3 으로 (아이스크림 소비량 앞 세 값)

$$\mathbf{y} = \begin{pmatrix} 0.386 \\ 0.374 \\ 0.393 \end{pmatrix} \implies \mathbf{y}^\top = (0.386 \quad 0.374 \quad 0.393)$$

✍ 행렬의 전치: 대각선 축으로 뒤집기. 2×3 이 3×2 로, $\mathbf{M}$ 의 1행이 $\mathbf{M}^\top$ 의 1열

$$\mathbf{M} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \implies \mathbf{M}^\top = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}$$

✂ 회귀에서의 쓰임: $\mathbf{X}$ 가 30×4 이면 $\mathbf{X}^\top$ 은 4×30 , 둘을 곱한 $\mathbf{X}^\top \mathbf{X}$ 는 4×4 . 순서가 뒤집히는 성질을 쓰면 $(\mathbf{X}^\top \mathbf{X})^\top = \mathbf{X}^\top \mathbf{X}$, 곧 대칭행렬

행렬식: 정의

◎ 여인수 전개

행렬식(determinant) $\det(\mathbf{A})$: $n \times n$ 정방행렬 하나에 대응시키는 수 하나. 1×1 이면 $\det(a_{11}) = a_{11}$ 이고, $n \geq 2$ 이면 여인수 전개(cofactor expansion)로 한 단계씩 작은 행렬식으로 내려가며 정의된다.

$$\det(\mathbf{A}) = \sum_{j=1}^n (-1)^{1+j} a_{1j} \det(\mathbf{A}_{1j})$$

$\mathbf{A}_{1j}$ 는 $\mathbf{A}$ 에서 1행과 j 열을 지운 $(n-1) \times (n-1)$ 행렬이며, 부호는 $+, -, +, \dots$ 로 번갈아 붙음

✔ $n = 2$ 는 그 특수한 경우

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$$

1열을 지우면 d , 2열을 지우면 c 가 남고 부호가 $+, -$

✔ $n = 3$ 직접 계산

$$\mathbf{A} = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}$$

$$\det(\mathbf{A}) = 2 \begin{vmatrix} 3 & 1 \\ 1 & 2 \end{vmatrix} - 1 \begin{vmatrix} 1 & 1 \\ 0 & 2 \end{vmatrix} + 0 \begin{vmatrix} 1 & 3 \\ 0 & 1 \end{vmatrix} = 2 \cdot 5 - 1 \cdot 2 + 0 = 8$$

✂ 손으로 계산할 일은 없음: 항의 개수가 $n!$ 로 늘어나므로 실제 계산은 프로그램이 다른 방식으로 수행. 여기서는 정방행렬 하나가 수 하나로 요약된다는 것과 그 수가 무엇을 뜻하는지(다음 슬라이드)만 가져가면 충분

행렬식: 넓이와 부피

💡 핵심

$|\det(\mathbf{A})|$ 는 $\mathbf{A}$ 의 행들이 만드는 도형의 크기이다. 2×2 이면 두 행이 만드는 평행사변형의 넓이, 3×3 이면 세 행이 만드는 평행육면체의 부피, 일반적으로 $n \times n$ 이면 n 차원 부피에 해당한다. 행렬식이 0이라는 것은 그 크기가 0, 곧 도형이 한 차원 낮게 납작하게 눌렸다는 뜻이다.

✔ 2차원: 넓이

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \det(\mathbf{A}) = 2 \cdot 1 - 1 \cdot 1 = 1$$

두 행이 서로 다른 방향 $\rightarrow$ 넓이 1

$$\mathbf{S} = \begin{pmatrix} 2 & 1 \\ 4 & 2 \end{pmatrix}, \det(\mathbf{S}) = 2 \cdot 2 - 1 \cdot 4 = 0$$

2행이 1행의 2배 $\rightarrow$ 선으로 눌러 넓이 0

✔ 3차원: 부피

$$\mathbf{D} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 10 \end{pmatrix}, \det(\mathbf{D}) = 100$$

가로 2, 세로 5, 높이 10인 상자의 부피

$$\mathbf{T} = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{pmatrix}, \det(\mathbf{T}) = 0$$

3행 = 1행 + 2행 $\rightarrow$ 세 방향이 한 평면 위, 부피 0

왜 눌리는지는 다음 슬라이드의 **계수**, 눌리면 무엇이 문제인지는 그다음 **역행렬** 슬라이드에서 이어짐

❌ 회귀에서의 쓰임: 아이스크림 완전모형은 $\det(\mathbf{X}^\top \mathbf{X}) = 4.68 \times 10^5$. 화씨 기온을 섭씨로 바꾼 열을 하나 더 넣으면 1.5×10^{-6} 으로 떨어지고 계산이 멈춤

행렬의 계수

◎ 정의

계수(rank) $\text{rank}(\mathbf{A})$: 서로 독립인 열의 최대 개수. 행으로 세어도 같은 값이 나온다.

완전계수(full rank): $\text{rank}(\mathbf{A}) = \min(\text{행 수}, \text{열 수})$ 인 상태. 정방행렬이 완전계수인 것과 $\det(\mathbf{A}) \neq 0$ 은 동치이다.

- 서로 독립: 어떤 열도 나머지 열들의 조합으로 만들어지지 않음
- 만들어지는 열은 새 정보가 아님

田 앞 슬라이드의 두 행렬

- $\text{rank}(\mathbf{A}) = 2$ (2열 중 2) $\rightarrow$ 완전계수, $\det = 1$
- $\text{rank}(\mathbf{S}) = 1$ (2열 중 1) $\rightarrow$ 계수 부족, $\det = 0$
- $\mathbf{S}$ 의 2열 $(1, 2)^\top$ 은 1열 $(2, 4)^\top$ 의 절반. 열이 둘처럼 보이지만 정보는 하나

田 설계행렬에서

- $\mathbf{X}$ 는 30×4 , $\text{rank} = 4 \rightarrow$ 완전계수
- 섭씨 열을 더한 30×5 도 $\text{rank} = 4 \rightarrow$ 열은 5개인데 정보는 4개
- 그래서 $\det(\mathbf{X}^\top \mathbf{X})$ 가 0으로 떨어짐

✂ 회귀에서의 쓰임: $\text{rank}(\mathbf{X}^\top \mathbf{X}) = \text{rank}(\mathbf{X})$ 이므로 $\mathbf{X}$ 의 열이 완전계수 $p + 1$ 일 때에만 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 이 존재. 계수가 모자라면 $\hat{\beta}$ 가 하나로 정해지지 않음

역행렬

◎ 정의

역행렬 A^{-1} : 정방행렬 A 에 대해 $A^{-1}A = AA^{-1} = I$ 를 만족하는 행렬.

존재 조건: $\det(A) \neq 0$, 곧 A 가 완전계수일 때에만 존재한다.

- 행렬에 나눗셈이 없으므로 $A\mathbf{x} = \mathbf{b}$ 는 $\mathbf{x} = A^{-1}\mathbf{b}$ 로 풀

≡ 역행렬의 성질

- 유일성: 존재하면 단 하나뿐. $BA = I = AC$ 이면 $B = B(AC) = (BA)C = C$
- 두 번 되돌리면 제자리: $(A^{-1})^{-1} = A$
- 곱은 순서가 뒤집힘: $(AB)^{-1} = B^{-1}A^{-1}$. 실제로 $(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = I$
- 전치와 교환 가능: $(A^{\top})^{-1} = (A^{-1})^{\top}$
- 대칭행렬의 역행렬은 대칭: $A^{\top} = A$ 이면 $(A^{-1})^{\top} = (A^{\top})^{-1} = A^{-1}$
- 행렬식은 역수: $\det(A^{-1}) = 1/\det(A)$. $\det(A)$ 가 0에 가까울수록 역행렬의 원소가 커짐

✖ 회귀에서의 쓰임: $\hat{\beta}$ 계산에 필요한 역행렬은 $(\mathbf{X}^{\top}\mathbf{X})^{-1}$ 하나. 계수가 모자라면 아예 없고, 완전계수라도 그 경계에 가까우면 계수 추정값이 크게 흔들림

직교벡터와 직교행렬

◎ 정의

내적 $\mathbf{a}^\top \mathbf{b} = a_1 b_1 + \cdots + a_n b_n$: 두 벡터를 성분끼리 곱해 모두 더한 수 하나.

직교: $\mathbf{a}^\top \mathbf{b} = 0$ 이면 두 벡터는 서로 직각이다.

직교행렬 $\mathbf{Q}$: 열들이 서로 직교하고 길이가 모두 1인 정방행렬. $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$ 이므로 $\mathbf{Q}^{-1} = \mathbf{Q}^\top$.

✔ 직접 확인 $\mathbf{a} = (1, 2)^\top, \mathbf{b} = (-2, 1)^\top$

$$\mathbf{a}^\top \mathbf{b} = 1 \cdot (-2) + 2 \cdot 1 = 0$$

직각이면 피타고라스 정리가 성립

$$\|\mathbf{a} + \mathbf{b}\|^2 = \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 \implies 10 = 5 + 5$$

- $\|\mathbf{a}\| = \sqrt{\mathbf{a}^\top \mathbf{a}}$: 벡터의 길이
- $\mathbf{a}^\top \mathbf{b} = 0$ 은 두 벡터가 공유하는 성분이 하나도 없다는 뜻
- 직교행렬은 회전과 반사만 할 뿐 길이를 바꾸지 않음. 역행렬이 전치와 같아 계산이 매우 안정적

대각합

◎ 정의

대각합(trace) $\text{tr}(\mathbf{A}) = a_{11} + \cdots + a_{nn}$: 정방행렬의 주대각선 원소를 모두 더한 수 하나.

- $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$, $\text{tr}(c\mathbf{A}) = c \text{tr}(\mathbf{A})$
- $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$: $\mathbf{A}$ 가 $k \times n$, $\mathbf{B}$ 가 $n \times k$ 이면 두 곱의 크기가 서로 달라도 대각합은 같음

≡ 확인

✔ $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ 직접 확인 ($\mathbf{A}$ 는 1×3 , $\mathbf{B}$ 는 3×1)

$$\mathbf{AB} = (1 \ 2 \ 3) \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix} = 7, \quad \mathbf{BA} = \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix} (1 \ 2 \ 3) = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 0 & 0 \\ 2 & 4 & 6 \end{pmatrix}$$

$\text{tr}(\mathbf{AB}) = 7$, $\text{tr}(\mathbf{BA}) = 1 + 0 + 6 = 7$. 1×1 과 3×3 으로 크기가 다른데도 값이 같음

✂ 회귀에서의 쓰임: 자유도를 세는 도구. 다음 슬라이드에서 보듯 모형이 쓴 정보량 $p + 1$ 과 남은 자유도 $n - p - 1$ 이 모두 어떤 행렬의 대각합으로 나옴

고윳값과 고유벡터

◎ 정의

고윳값(eigenvalue) λ 와 고유벡터(eigenvector) $\mathbf{v} \neq \mathbf{0}$: $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ 를 만족하는 짝. 행렬을 곱해도 방향이 바뀌지 않고 길이만 λ 배 되는 특별한 방향이 고유벡터이고, 그 배율이 고윳값이다.

✔ 직접 확인 ($\mathbf{A}$ 는 대칭행렬)

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \quad \mathbf{A} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{A} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$\lambda_1 = 3$ 의 방향은 $(1, 1)$, $\lambda_2 = 1$ 의 방향은 $(1, -1)$. 방향만 중요하므로 길이를 1로 맞춰 $\mathbf{q}_1 = (1, 1)/\sqrt{2}$, $\mathbf{q}_2 = (1, -1)/\sqrt{2}$ 로 씀 (부호는 임의)

- $n \times n$ 행렬의 고윳값은 중복을 세어 n 개
- $\text{tr}(\mathbf{A}) = \sum_j \lambda_j$: 확인 $2 + 2 = 4 = 3 + 1$
- $\det(\mathbf{A}) = \prod_j \lambda_j$: 확인 $2 \cdot 2 - 1 \cdot 1 = 3 = 3 \times 1$

✂ 회귀에서의 쓰임: 앞 슬라이드의 대각합을 고윳값의 합으로 바꿔 읽을 수 있게 됨. 다음 두 슬라이드에서 자유도가 이 방식으로 세어짐

스펙트럴 분해

◎ 정의

스펙트럴 분해(spectral decomposition): 대칭행렬 $\mathbf{A}$ 는 직교행렬 $\mathbf{Q}$ 와 고윳값을 늘어놓은 대각행렬 $\mathbf{\Lambda}$ 로 항상 다음과 같이 쪼개진다.

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top = \sum_{j=1}^n \lambda_j \mathbf{q}_j \mathbf{q}_j^\top, \quad \mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$$

기호

- $\mathbf{q}_j$: $\mathbf{Q}$ 의 j 번째 열이자 λ_j 의 고유벡터
- 고유벡터끼리 서로 직교하며 길이가 1

✔ 앞 슬라이드의 $\mathbf{A}$ 로 확인

$$\mathbf{q}_1 \mathbf{q}_1^\top = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{q}_2 \mathbf{q}_2^\top = \frac{1}{2} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}, \quad 3 \mathbf{q}_1 \mathbf{q}_1^\top + 1 \mathbf{q}_2 \mathbf{q}_2^\top = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \mathbf{A}$$

- $\text{rank}(\mathbf{A}) = 0$ 이 아닌 고윳값의 개수. 대칭행렬에서는 계수를 고윳값만 세어 알 수 있음
- $\lambda_j = 0$ 인 조각은 합에서 사라지므로, 분해는 행렬을 방향별로 나눈 것과 같음

✂ 회귀에서의 쓰임: 다음 슬라이드의 멱등행렬, 그리고 적합값을 만드는 모자행렬이 모두 대칭이므로 이 분해가 그대로 적용됨

특정 형태의 행렬: 삼각행렬

◎ 정의

상삼각행렬(upper triangular matrix): 주대각선 아래 성분이 모두 0인 정방행렬.

하삼각행렬(lower triangular matrix): 주대각선 위 성분이 모두 0인 정방행렬.

상삼각이면서 동시에 하삼각인 행렬이 곧 대각행렬이다.

$$\mathbf{U} = \begin{pmatrix} 2 & 3 & 1 \\ 0 & 5 & 4 \\ 0 & 0 & 10 \end{pmatrix}, \quad \mathbf{L} = \mathbf{U}^{\top} = \begin{pmatrix} 2 & 0 & 0 \\ 3 & 5 & 0 \\ 1 & 4 & 10 \end{pmatrix}$$

≡ 확인

✍ 삼각행렬이 편리한 이유 (위 $\mathbf{U}$ 로 확인)

- $\det(\mathbf{U}) = \text{주대각 원소의 곱} = 2 \times 5 \times 10 = 100$, 고윳값도 주대각 원소 10, 5, 2 그대로
- 같은 종류의 삼각행렬끼리는 곱해도, 역행렬을 취해도 같은 종류의 삼각행렬
- $\mathbf{U}\mathbf{z} = \mathbf{c}$ 는 맨 아래 줄부터 차례로 대입해 풀 수 있음(후진대입). 역행렬을 따로 구하지 않아도 됨

✂ 회귀에서의 쓰임: 통계 프로그램은 $\hat{\beta} = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{y}$ 를 역행렬로 직접 계산하지 않음. 설계행렬을 $\mathbf{X} = \mathbf{QR}$ (열이 서로 직교인 $\mathbf{Q} \times$ 상삼각행렬 $\mathbf{R}$)로 분해한 뒤 $\mathbf{R}\hat{\beta} = \mathbf{Q}^{\top} \mathbf{y}$ 를 후진대입으로 푸는 방식이 수치적으로 더 안정적이기 때문

멱등행렬

◎ 정의

멱등행렬(idempotent matrix): $\mathbf{A}^2 = \mathbf{A}$ 를 만족하는 정방행렬. 한 번 적용한 결과에 같은 연산을 다시 적용해도 값이 변하지 않는다.

✔ 직접 확인

$$\mathbf{J} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \implies \mathbf{J}^2 = \frac{1}{4} \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} = \mathbf{J}$$

$\text{tr}(\mathbf{J}) = \frac{1}{2} + \frac{1}{2} = 1$. 앞 슬라이드의 $\mathbf{q}_1 \mathbf{q}_1^\top$ 과 같은 행렬이며, 고윳값은 1, 0

✔ 나머지 부분도 멱등

$$(\mathbf{I} - \mathbf{A})^2 = \mathbf{I} - 2\mathbf{A} + \mathbf{A}^2 = \mathbf{I} - \mathbf{A}$$

$\mathbf{A}^2$ 자리에 $\mathbf{A}$ 를 넣으면 $-2\mathbf{A} + \mathbf{A} = -\mathbf{A}$

- $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ 의 양변에 $\mathbf{A}$ 를 한 번 더 곱하면 $\mathbf{A}^2\mathbf{v} = \lambda^2\mathbf{v}$. $\mathbf{A}^2 = \mathbf{A}$ 이므로 $\lambda^2 = \lambda$, 곧 고윳값은 0 아니면 1
- 앞 슬라이드의 세 사실을 그대로 씀. 대각합 = 고윳값의 합, 계수 = 0이 아닌 고윳값의 개수. 여기서는 0이 아닌 고윳값이 모두 1이므로 $\text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A}) = \text{사영하고 남는 차원의 수}$

벡터와 행렬의 미분

◎ 정의

스칼라 값을 갖는 함수 $f(\mathbf{b})$ 를 벡터 $\mathbf{b} = (b_1, \dots, b_k)^\top$ 로 미분한다는 것은, 성분마다 편미분한 값을 같은 모양으로 쌓는다는 뜻이다.

$$\frac{\partial f}{\partial \mathbf{b}} = \left(\frac{\partial f}{\partial b_1}, \dots, \frac{\partial f}{\partial b_k} \right)^\top$$

≡ 필요한 공식은 두 개

$$\frac{\partial(\mathbf{a}^\top \mathbf{b})}{\partial \mathbf{b}} = \mathbf{a}, \quad \frac{\partial(\mathbf{b}^\top \mathbf{A} \mathbf{b})}{\partial \mathbf{b}} = 2\mathbf{A} \mathbf{b}$$

두 번째는 $\mathbf{A}$ 가 대칭일 때. 숫자의 미분 $\frac{d(ab)}{db} = a$,

$$\frac{d(ab^2)}{db} = 2ab \text{ 와 모양이 같음}$$

✍ 최소제곱에 적용

$$\begin{aligned} S(\boldsymbol{\beta}) &= (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \\ &= \mathbf{y}^\top \mathbf{y} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} + \boldsymbol{\beta}^\top (\mathbf{X}^\top \mathbf{X}) \boldsymbol{\beta} \\ \frac{\partial S}{\partial \boldsymbol{\beta}} &= -2\mathbf{X}^\top \mathbf{y} + 2(\mathbf{X}^\top \mathbf{X}) \boldsymbol{\beta} = \mathbf{0} \end{aligned}$$

첫 항은 $\boldsymbol{\beta}$ 가 없으므로 사라지고, 둘째 항에 첫 공식, 셋째 항에 둘째 공식을 적용($\mathbf{X}^\top \mathbf{X}$ 는 대칭). 정리하면
정규방정식

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$$

✂ 회귀에서의 쓰임: 최소제곱은 미분해서 0으로 놓는 계산 그 자체이며, 그 결과가 위의 정규방정식. 한 번 더 미분한 $\frac{\partial^2 S}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^\top} = 2\mathbf{X}^\top \mathbf{X}$ 가 완전계수일 때 양정치이므로 이 자리는 최댓값이 아니라 **최솟값**. 같은 도구가 4장의 최대가능도 추정에도 그대로 쓰임

최소제곱추정량 예고

💡 핵심

자료 $(\mathbf{y}, \mathbf{X})$ 가 주어졌을 때 회귀계수의 추정값은 전치와 역행렬만으로 한 줄에 표현된다.

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

기호

- $\hat{\beta}$: 자료로 추정한 회귀계수 벡터. 모자 기호는 추정값이라는 뜻
- $\mathbf{X}^\top$: $\mathbf{X}$ 의 전치, $(\mathbf{X}^\top \mathbf{X})^{-1}$: $\mathbf{X}^\top \mathbf{X}$ 의 역행렬
- $\mathbf{y}$: 반응변수 벡터

≡ 차원으로 따라가기 (아이스크림 완전모형, $n = 30$, 설명변수 $p = 3$)

$$\underbrace{\mathbf{X}^\top}_{4 \times 30} \underbrace{\mathbf{X}}_{30 \times 4} = \underbrace{\mathbf{X}^\top \mathbf{X}}_{4 \times 4} \implies \underbrace{(\mathbf{X}^\top \mathbf{X})^{-1}}_{4 \times 4} \underbrace{\mathbf{X}^\top}_{4 \times 30} \underbrace{\mathbf{y}}_{30 \times 1} = \underbrace{\hat{\beta}}_{4 \times 1}$$

관측이 30개든 3만 개든 역행렬을 취하는 대상은 언제나 $(p + 1) \times (p + 1)$ 행렬 하나

단순회귀, 다중회귀, 가변수회귀는 모두 이 한 줄의 특수한 경우. 유도는 앞 슬라이드의 미분 두 줄이며, 자세한 해석은 Multiple Linear Regression 장

정규분포

◎ 정의

확률변수 X 가 평균 μ , 표준편차 σ 인 정규분포를 따를 때 $X \sim N(\mu, \sigma^2)$ 로 적고, 그 밀도함수는 다음과 같다.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < \infty$$

- μ : 분포의 중심인 평균, σ : 흩어진 정도인 표준편차, σ^2 : 그 제곱인 분산
- 밀도함수 $f(x)$ 의 값 자체는 확률이 아님. 곡선 아래 넓이가 확률이고, 곡선 전체의 넓이는 1

💡 모양의 성질

- μ 를 중심으로 좌우대칭인 종 모양이고, 평균과 중앙값이 같음
- 모수 두 개(μ, σ)만 정하면 분포 전체가 결정됨. μ 는 위치, σ 는 폭을 조절
- $\mu = 0, \sigma = 1$ 인 경우를 표준정규분포라 하고 $N(0, 1)$ 로 적음

정규분포: 68-95-99.7 규칙

田 구간별 포함 확률

Interval	Probability
$\mu \pm 1\sigma$	0.683
$\mu \pm 2\sigma$	0.954
$\mu \pm 3\sigma$	0.997

Coverage probabilities of the normal distribution.

계산: $P(|Z| \leq 1) = 0.683$, $P(|Z| \leq 2) = 0.954$, $P(|Z| \leq 3) = 0.997$. 평균에서 표준편차 3배 넘게 떨어질 확률은 약 0.3%

💡 정규분포 가정의 근거

서로 독립인 작은 영향이 여러 개 더해지면 그 합 분포는 관여한 각 요인의 분포와 무관하게 정규분포에 가까워진다(중심극한정리).

측정오차 = 온도, 습도, 진동, 판독 습관 등 작은 요인 다수의 합. 따라서 종 모양 분포가 근거 있는 출발점

✂ 회귀에서의 쓰임: 오차 ε_i 가 평균 0, 분산 σ^2 인 정규분포를 따른다고 가정하고, 그 위에서 검정과 구간추정

표본과 표집분포

◎ 정의

모집단: 알고 싶은 대상 전체. 표본: 실제로 관측한 일부.

통계량: 표본에서 계산한 값(표본평균 $\bar{X}$ 등). 표본이 바뀌면 값도 바뀌므로 통계량 자체가 확률변수다.

표집분포: 같은 크기의 표본을 반복해서 뽑을 때 통계량이 갖는 분포.

$X_1, \dots, X_n$ 이 평균 μ , 분산 σ^2 인 모집단에서 뽑힌 표본일 때, 표본평균 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 의 표집분포는 다음을 만족

$$E(\bar{X}) = \mu, \quad \text{SD}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$


기호

- $E(\bar{X})$: 표본평균의 평균(반복해서 뽑았을 때의 중심)
- $\text{SD}(\bar{X})$: 표본평균의 표준편차 곧 **표준오차**(standard error, SE)

- 표준오차는 추정값의 흔들림 폭이고, n 이 커질수록 $\sqrt{n}$ 에 반비례해 줄어듦. n 이 4배면 표준오차는 절반
- 회귀에서의 쓰임: 계수 추정값 $\hat{\beta}_j$ 가 통계량이고, 결과표의 표준오차 열이 그 표집분포의 표준편차

카이제곱분포

◎ 정의



Chi-square densities for 3, 10, and 26 degrees of freedom

서로 독립인 표준정규 확률변수 $Z_1, \dots, Z_\nu$ 의 제곱을 모두 더하면

$$W = \sum_{i=1}^{\nu} Z_i^2$$

은 자유도 ν 의 카이제곱분포 $\chi^2(\nu)$ 를 따른다.

- 제곱의 합이므로 항상 0 이상
- 오른쪽 꼬리가 긴 비대칭 분포
- $E(W) = \nu, \text{Var}(W) = 2\nu$
- ν 가 커지면 점차 대칭에 가까워짐


❧ 회귀에서의 쓰임: 흩어진 정도를 재는 양의 분포. 잔차제곱합을 오차분산으로 나누면

$$\frac{\text{SSE}}{\sigma^2} \sim \chi^2(n - p - 1)$$

아이스크림 완전모형은 $\chi^2(26)$. 다음 두 분포가 모두 여기서 만들어짐

t분포

◎ 정의



Standard normal and t distributions with 3 and 10 degrees of freedom

σ 를 모른 채 표본표준편차 s 로 대신하면

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}}$$

는 자유도 $n - 1$ 의 t분포를 따른다.


- 정규분포보다 봉우리가 낮고 꼬리가 두꺼움
- σ 를 추정하는 불확실성이 더해졌기 때문
- 자유도가 커지면 정규분포에 가까워짐

- **자유도** = 분산을 추정하는 데 쓸 수 있는 독립인 정보의 개수
- 자유도가 클수록 s 가 σ 에 가까워지므로 t분포는 $N(0, 1)$ 에 수렴
- 양측 2.5% 임계값: 자유도 3에서 3.182, 자유도 10에서 2.228, 자유도 28에서 2.048, 정규분포는 1.960

❧ 회귀에서의 쓰임: 계수 검정에 자유도 $n - (p + 1)$ 의 t분포. 아이스크림 자료의 단순회귀는 $30 - 2 = 28$

F분포

◎ 정의



F densities; the shaded area is the upper 5 percent tail of F(3, 26)

서로 독립인 두 카이제곱 $W_1 \sim \chi^2(\nu_1)$, $W_2 \sim \chi^2(\nu_2)$ 를 각자의 자유도로 나눈 뒤 비를 취하면

$$F = \frac{W_1/\nu_1}{W_2/\nu_2}$$

은 자유도 (ν_1, ν_2) 의 F분포 를 따른다.

- 두 분산의 비이므로 항상 0 이상
- 분자 쪽이 클수록 F 가 커지므로 검정은 **오른 쪽 꼬리만 봄**
- $\nu_1 = 1$ 이면 $F(1, \nu_2) = \{t(\nu_2)\}^2$

❧ 회귀에서의 쓰임: 두 분산 추정값의 비. 모형이 설명한 몫과 남은 몫을 각자의 자유도로 나누어 견줄

$$F = \frac{\text{SSR}/p}{\text{SSE}/(n-p-1)} \sim F(p, n-p-1)$$

아이스크림 완전모형은 $F(3, 26)$ 이고, 유의수준 5%의 기각역은 $F > 2.98$

점추정: 추정량과 추정값

◎ 규칙과 숫자의 구분

- 모수 θ : 모집단이 가진, 알 수 없는 상수
- 추정량 $\hat{\theta}$: 표본의 함수로 정의된 규칙이며 그 자체가 **확률변수**
- 추정값: 특정 표본에 그 규칙을 적용해 실제로 나온 숫자.

Parameter θ	Estimator $\hat{\theta}$	Name
μ	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$	Sample mean
σ^2	$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	Sample variance
p	$\hat{p} = X/n$	Sample proportion

Common point estimators. The estimator is the rule; the number it produces from one particular sample is the estimate

표집오차(sampling error) = $\hat{\theta} - \theta$. 표본이 바뀌면 이 값도 바뀌므로, 오차 하나가 아니라 **오차의 분포**를 봐야 함


- 같은 추정량이라도 **표본이 다르면 추정값이 다름**. 따라서 추정량의 좋고 나쁨은 한 번의 값이 아니라 **표집분포**로 판단
- 회귀에서의 쓰임: $\hat{\beta}_0, \hat{\beta}_1$ 이 추정량이고, 자료 한 벌에서 계산된 0.207 과 0.00311 이 추정값

좋은 추정량: 편의와 변동성


🎯 과녁에 비유하면

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \underbrace{\left[E(\hat{\theta}) - \theta\right]^2}_{\text{편의}^2 \text{ (bias)}} + \underbrace{\text{Var}(\hat{\theta})}_{\text{변동성 (variance)}}$$


Variability vs Bias — Target Analogy




① Low Variability · Low Bias



② Low Variability · High Bias



③ High Variability · Low Bias



④ High Variability · High Bias

- **불편성**(unbiasedness) $E(\hat{\theta}) = \theta$: 반복하면 평균이 정확히 과녁 중심. 가로로 ① $\leftrightarrow$ ② 를 비교
- **변동성** $\text{Var}(\hat{\theta})$: 작을수록 탄착군이 조밀. 세로로 ① $\leftrightarrow$ ③ 을 비교
- $\sqrt{\text{Var}(\hat{\theta})}$ 가 **표준오차**
- 두 잣대 사이에는 **맞바꿈**이 있어 편의를 허용하면 변동성이 줄기도 함

Reused from the earlier UST lecture note, 07-sampling-distribution

회귀에서의 쓰임: 최소제곱 추정량 $\hat{\beta}_0, \hat{\beta}_1$ 이 ①에 해당한다는 주장이 3장의 **Gauss-Markov 정리**(불편이면서 그중 분산이 가장 작음)

신뢰구간

◎ 정의

95% 신뢰구간: 같은 절차로 표본 추출과 구간 계산을 반복했을 때, 만들어진 구간들 가운데 약 95%가 참값을 포함하도록 설계된 구간.

$$\hat{\theta} \pm t_{0.975, \nu} \times SE(\hat{\theta})$$

기호

- $\hat{\theta}$: 관심 모수의 추정값, $SE(\hat{\theta})$: 그 표준오차
- $t_{0.975, \nu}$: 자유도 ν 인 t분포의 상위 2.5% 지점. 자유도 28이면 2.048

가설검정의 논리

◎ 정의

귀무가설 H_0 : 반증되기 전까지 참이라고 두는 기본 가정. 보통 “효과가 없다”, “차이가 없다” 쪽에 놓는다.

대립가설 H_1 : 자료로 입증하고자 하는 주장. 보통 “효과가 있다” 쪽이다.

≡ 절차


1. H_0 와 H_1 을 자료를 보기 전에 확정
2. 자료에서 검정통계량을 계산(예: $T = (\bar{X} - \mu_0)/(s/\sqrt{n})$)
3. H_0 가 참일 때 그 통계량이 따르는 분포를 확인(예: 자유도 $n - 1$ 의 t분포)
4. 관측된 통계량이 그 분포에서 얼마나 드문 값인지를 측정

검정의 결론은 H_0 의 기각 또는 기각하지 못함 두 가지뿐. “ H_0 를 채택한다”는 표현은 쓰지 않음

✂ 회귀에서의 쓰임: 각 설명변수마다 $H_0 : \beta_j = 0$ (그 변수의 기여가 없음) 대 $H_1 : \beta_j \neq 0$ 의 검정

p-value: 정의

◎ 꼬리 넓이



p-value: 귀무가설이 참이라고 가정할 때, 실제로 관측된 것만큼 또는 그보다 더 극단적인 결과가 나올 확률.

$$p = P(|T| \geq 2.20 \mid H_0) = 0.0362$$

기호

- T : 자유도 28의 t분포를 따르는 검정통계량
- 계산은 $2 * \text{pt}(-2.20, 28) = 0.0362$

Two-sided p-value as the shaded tail area beyond $|t| = 2.20$, t distribution with 28 df

p가 작다 = 관측된 자료가 H_0 아래에서 보기 드문 결과. 이때 H_0 를 기각. 관례적 기준 $\alpha = 0.05$ 는 학문 공동체의 약속일 뿐 자연법칙이 아님

앞서 본 95% 신뢰구간이 0을 포함하지 않는 것과 양측 검정의 $p < 0.05$ 는 동일한 판정

✂ 회귀에서의 쓰임: 계수표의 p-value 열이 각 계수에 대한 이 확률

p-value: 해석의 함정

⚠ 네 가지 오독

1. **p는 귀무가설이 참일 확률이 아님:** H_0 가 참이라는 조건을 붙이고 계산한 자료 쪽의 확률
 - 조건과 결론을 맞바꾸어 읽으면 안 됨
2. **p가 크다고 효과 없음이 증명되지는 않음:** 표본이 작거나 측정오차가 크면 실재하는 효과도 드러나지 않음
 - 증거 없음 $\neq$ 없음의 증거
3. **통계적 유의성 $\neq$ 실질적 중요성:** n 이 매우 크면 실무적으로 무시할 만한 차이도 유의해짐
 - 효과의 크기를 함께 보고
4. **p = 0.049와 p = 0.051 사이에 질적 차이 없음:**
 - p 는 0에서 1까지 **연속으로** 변하는 값이고, 0.05는 관습적인 **기준**
 - 유의/비유의로 자르지 말고 p 값을 그대로 보고

따라서 p-value는 추정값의 크기, 표준오차, 신뢰구간과 **함께** 보고할 것

이 장의 정리

≡ Preliminary Knowledge

- 행렬 표기: n 개의 식을 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 한 줄로 압축. $\mathbf{X}$ 의 1열은 절편의 자리
- 새로 배운 연산: 전치 $\mathbf{X}^\top$, 행렬식 $\det$, 계수 rank , 역행렬 $\mathbf{A}^{-1}$, 내적, 대각합 tr , 벡터 미분
- $\det(\mathbf{X}^\top \mathbf{X}) \neq 0 \Leftrightarrow \mathbf{X}$ 가 완전계수 $\Leftrightarrow \hat{\boldsymbol{\beta}}$ 가 하나로 정해짐
- 벡터 미분 두 공식으로 $S(\boldsymbol{\beta})$ 를 미분하면 정규방정식 $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$
- 직교 $\mathbf{X}^\top \mathbf{e} = \mathbf{0}$ 은 제곱합 분해의 근거, 멱등행렬의 대각합은 자유도
- 최소제곱추정량 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$. 이후 모든 장이 이 한 줄의 특수한 경우
- 정규분포 $N(\mu, \sigma^2)$, 68-95-99.7 규칙. 회귀에서는 오차 ε_i 의 가정
- 표집분포와 표준오차 $\sigma/\sqrt{n}$. 회귀에서는 계수표의 표준오차 열
- 정규분포에서 만들어지는 세 분포: χ^2 (제곱합), t (평균의 검정), F (두 분산의 비)
- t 분포(자유도 $n - (p + 1)$)로 계수 검정, F 분포 $F(p, n - p - 1)$ 로 모형 전체 검정
- 신뢰구간과 p-value. 회귀에서는 구간추정과 계수 검정

참고문헌

이 장에서 인용한 문헌

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill. (행렬 표기)
- American Statistical Association (2016). Statement on statistical significance and p-values. *The American Statistician*, 70(2), 129-133.

교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.