

Regression Analysis

3. Simple Linear Regression | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division

Korea Institute of Oriental Medicine

2026-09-01

Simple Linear Regression

두 변수 간 관계 측정

? 관계의 측도

두 변수 사이의 관계는 **방향**과 **강도** 두 가지로 요약

- **방향**: x 가 커질 때 y 도 커지는가(양의 연관성), 반대로 작아지는가(음의 연관성)
- **강도**: 그 경향이 얼마나 또렷한가
- 재는 방법은 여러이나, 이 강의에서는 Pearson의 공분산과 상관계수를 씀

◎ 표기

관측 n 개가 짝을 이루어 $(x_1, y_1), \dots, (x_n, y_n)$ 로 나타남

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$


- y_i : i 번째 관측의 반응변수, x_i : 같은 관측의 설명변수
- n : 관측 수, $\bar{y}$, $\bar{x}$: 표본평균(값을 모두 더해 개수로 나눈 값)

숫자 요약보다 **산점도**(관측 하나를 가로축 x , 세로축 y 의 점 하나로 찍은 그림)를 먼저 볼 것


공분산의 착안: 편차의 곱

사분면의 쓸림

Positive association ($r = 0.77$)



Negative association ($r = -0.84$)



Quadrant	$y_i - \bar{y}$	$x_i - \bar{x}$	Product
1 (upper right)	+	+	+
2 (upper left)	+	-	-
3 (lower left)	-	-	+
4 (lower right)	-	+	-

Sign of the deviation product in each quadrant

부호의 논리

- 두 평균선이 평면을 넷으로 나눔
- 점 하나마다 두 편차를 곱하면 칸마다 부호가 정해짐
- 그림의 파란 +, 주황 - 가 이 표의 마지막 열
- 두 그림에서 부호 배치는 **동일**. 다른 것은 점이 몰린 칸뿐

공분산: 정의

◎ 관찰의 수식화

↗ 양의 연관성

- 1, 3사분면에 점이 많음
- 두 편차의 곱이 양수인 칸들
- 모두 더하면 양수

↘ 음의 연관성

- 2, 4사분면에 점이 많음
- 두 편차의 곱이 음수인 칸들
- 모두 더하면 음수

공분산(covariance)

$$\text{cov}(y, x) = \frac{1}{n - 1} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})$$

- $(y_i - \bar{y})$: y 가 평균에서 떨어진 거리, $(x_i - \bar{x})$: x 가 평균에서 떨어진 거리
- 두 편차의 곱을 모두 더해 $n - 1$ 로 나눔. 모집단 공분산과 구별하여 **표본공분산**이라 부름

공분산의 한계와 표준화

⚠ 주의: 단위 의존성

상수 a, b, c, d 에 대해 $\text{cov}(ay + b, cx + d) = ac \text{cov}(y, x)$ 가 성립한다.

- y 의 단위를 바꾸어 값에 a 를 곱하면 공분산도 a 배
- 키를 cm로 재느냐 inch로 재느냐에 따라 연관성의 크기가 달라진다면 곤란
- 공분산은 부호는 믿을 수 있으나 크기는 단위에 좌우되는 척도

✍ 해결: 표준화

$$z_i = \frac{y_i - \bar{y}}{s_y}, \quad s_y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

- s_y : 표본표준편차(자료가 평균에서 떨어진 정도를 대표하는 값, 원자료와 단위가 같음)
- z_i : 표준화된 값. 편차를 흠어짐의 크기로 나누면 단위가 사라지고 $\bar{z} = 0, s_z = 1$

상관계수: 정의와 성질

◎ 표준화한 공분산

$$r = \text{corr}(y, x) = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{y_i - \bar{y}}{s_y} \right) \left(\frac{x_i - \bar{x}}{s_x} \right) = \frac{\text{cov}(y, x)}{s_y s_x}$$


- s_y, s_x : 각각 y 와 x 의 표본표준편차
- 표준화한 두 변수의 공분산이 곧 상관계수
- 모집단 상관계수와 구별하여 **표본상관계수**라 부름

💡 성질

- 측정 단위를 바꾸어도 값이 변하지 않음: $\text{corr}(ay + b, cx + d) = \text{corr}(y, x)$ ($ac > 0$)
- $-1 \leq r \leq 1$
- 부호는 방향, 절댓값은 강도. 1 또는 -1 에 가까울수록 강한 **선형관계**
- $\text{corr}(y, x) = \text{corr}(x, y)$

상관계수: $r = 0$ 의 함정

⚠ $r = 0$ 과 독립의 구분




A perfect relation $y = 50 - x^2$ with correlation $r = 0$

$y = 50 - x^2$ 는 x 가 정해지면 y 가 완전히 결정되는 관계이나, 표본상관계수는 $r = 0$ 이다.

- 상관계수는 **선형** 연관성만 재는 척도
- $r = 0$ 은 “선형관계가 없다”는 뜻이지 “관계가 없다”는 뜻이 아님
- 따라서 숫자보다 산점도를 먼저 볼 것

상관계수: 산점도와 상관계수

산점도 형태에 따른 상관계수



예제 자료: 아이스크림 소비량

田 자료 구조와 공분산·상관계수

period	IC	price	income	temp	year
1	0.386	0.270	78	41	0
2	0.374	0.282	79	56	0
3	0.393	0.277	81	63	0
4	0.425	0.280	80	68	0
5	0.406	0.272	76	69	0

First five of $n = 30$ four-week periods; 6 variables in total

Variable	Meaning
period	Observation index (four-week period)
IC	Per-capita ice cream consumption (pints)
price	Price of ice cream
income	Income
temp	Mean temperature (°F)
year	Observation year code (0/1/2)

Variables of the ice cream data

한 행은 4주 기간 하나이며, 총 $n = 30$ 개 기간. 이 장에서 쓰는 변수는 $y_i = \text{IC}$, $x_i = \text{temp}$ 두 개

Statistic	temp (x)	IC (y)
Mean	49.1	0.359
Standard deviation	16.4	0.0658

Summary statistics of the two variables used in this chapter ($n = 30$)

$$\text{cov}(y, x) = 0.838, \quad r = \frac{\text{cov}(y, x)}{s_y s_x} = \frac{0.838}{0.0658 \times 16.4} = \frac{0.838}{1.08} = 0.776$$

- 부호가 양수이므로 온도가 높은 기간에 소비량도 큼
- $r = 0.776$ 은 1에 비교적 가까우므로 선형관계가 뚜렷함
- 공분산 0.838 자체의 크기는 단위에 좌우되므로 강도 판단에 쓰지 않음

단순선형회귀모형

◎ 정의

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n$$


- y_i : 반응변수, x_i : 설명변수, β_0 : 절편, β_1 : 기울기
- ε_i : 직선으로 설명되지 않는 오차(평균 0, 분산 σ^2)
- β_0, β_1 은 값을 모르지만 **고정된 상수**. y_i 가 흔들리는 원인은 오직 ε_i

💡 계수의 뜻

- β_1 (기울기): x 가 1단위 커질 때 y 가 **평균적으로** 변하는 양
- β_0 (절편): $x = 0$ 일 때 예측되는 y 의 평균
- 적합한 직선은 조건부 기댓값 $E(y | x) = \beta_0 + \beta_1 x$ 의 추정이므로, 개별 관측이 아닌 **평균**에 관한 진술
- $x = 0$ 이 자료 범위 밖이면 절편을 물리적으로 해석하지 않는 편이 안전함

후보 직선의 비교

? 무수히 많은 후보 직선



*Infinitely many lines pass through the same scatter.
Which one should be called the best?*

임의의 직선과 잔차


$$r_i = y_i - (a_0 + a_1 x_i)$$

- a_0, a_1 : 임의로 정한 직선의 절편과 기울기
- r_i : 그 직선에서 i 번째 점까지의 세로 간격

- 직선을 하나 정할 때마다 잔차가 n 개 생김. 좋은 직선은 이 n 개가 **전체적으로 작은** 직선
- 두 직선의 우열을 가리려면 잔차 n 개를 **하나의 수**로 요약해야 함. 이 요약값이 **기준** (criterion)
- 기준을 정해야 비로소 무수한 후보에 **순서**가 매겨지고 최적이라는 말이 정의됨

최소제곱 기준

그림으로 보기



Least squares minimizes the sum of squared vertical gaps

$$\text{잔차 } e_i = y_i - \hat{y}_i$$

기호

- $\hat{y}_i$: 직선이 예측한 값(적합값)
- e_i : 관측값과 적합값의 수직 간격

최소제곱 기준

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

이 제곱 합을 가장 작게 만드는 직선을 최적 직선으로 정의. 이를 **통상최소제곱법** (Ordinary Least Squares, OLS)이라 부름


제곱합을 기준으로 삼는 이유

네 직선, 세 기준

후보 직선	식	$\sum r_i$	$\sum r_i $	$\sum r_i^2$
A: 양 끝점을 이음	$-0.0321 + 0.679x$	-7.39	8.28	14.8
B: 평균점을 지나되 완만	$0.172 + 0.274x$	0.00	10.3	15.5
C: 절대편차합 최소	$-0.883 + 0.833x$	-2.48	6.25	10.8
OLS: 제곱합 최소	$-0.786 + 0.685x$	0.00	7.55	9.38

Four candidate lines scored by three criteria on the same 10 points. Bold marks the minimum of each criterion.

- $\sum r_i$ 는 순서를 매기지 못함. B와 OLS가 모두 0이며, 평균점 $(\bar{x}, \bar{y})$ 를 지나는 직선은 예외 없이 0이므로 무수히 많은 직선이 동점
- $\sum (y_i - a_0 - a_1 x_i) = n(\bar{y} - a_0 - a_1 \bar{x})$ 이므로, $a_0 = \bar{y} - a_1 \bar{x}$ 이면 기울기 a_1 이 무엇이든 합은 0
- 기준이 바뀌면 답도 바뀜. $\sum |r_i|$ 의 최소는 C, $\sum r_i^2$ 의 최소는 OLS로 서로 다른 직선



The sum of squared residuals as the candidate slope varies, with the intercept set to its best value at each slope.

💡 제곱합을 표준으로 삼는 근거

- 해가 달한 형태로 존재: $S(b)$ 가 b 의 이차함수이자 아래로 볼록이므로 미분해 0으로 놓으면 유일한 최소점을 얻음(다음 장)
- Gauss-Markov 정리: 오차의 평균이 0이고 등분산·무상관이면, y 의 선형결합으로 만든 불편추정량 가운데 분산이 가장 작음(BLUE)
- 정규오차에서 최대가능도와 일치: $\varepsilon_i \sim N(0, \sigma^2)$ 이면 가능도를 최대화하는 것이 곧 제곱합을 최소화하는 것(두 슬라이드 뒤에서 유도)
- 다만 $\sum |r_i|$ 기준은 이상점에 덜 민감하여 로버스트 회귀에서 쓰임. 제곱합이 유일한 정답은 아님

최소제곱법: 정규방정식

✍ 두 편미분을 0으로

목적함수를 $S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ 라 두면, 최소점에서 두 편미분이 모두 0

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

정리하면 미지수가 둘인 연립방정식, 곧 **정규방정식**

최소제곱법: 해의 유도

✍ 두 식, 두 미지수

- 1 첫 식에서 절편이 바로 나온다. 괄호를 풀어 항별로 더하면 $\sum y_i = n\beta_0 + \beta_1 \sum x_i$. 양변을 n 으로 나누면 평균끼리의 관계가 되고, 이것이 곧 절편의 식

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 \implies \bar{y} = \beta_0 + \beta_1 \bar{x} \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- 2 그 절편을 둘째 식에 대입한다. 둘째 식은 $\sum x_i y_i = \beta_0 \sum x_i + \beta_1 \sum x_i^2$. 여기에 $\beta_0 = \bar{y} - \beta_1 \bar{x}$ 와 $\sum x_i = n\bar{x}$ 를 넣고 β_1 이 든 항만 한쪽으로 모음

$$\sum x_i y_i - n\bar{x}\bar{y} = \beta_1 \left(\sum x_i^2 - n\bar{x}^2 \right)$$


- 3 양변이 편차의 제곱합이다. 괄호를 전개하면 $\sum x_i y_i - n\bar{x}\bar{y} = S_{xy}$, $\sum x_i^2 - n\bar{x}^2 = S_{xx}$ 이므로 양변을 S_{xx} 로 나누면 기울기가 나옴

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

기호: 앞으로 계속 쓸 세 제곱합은 모두 **평균에서의 편차**로 정의됨. $S_{xx} = \sum (x_i - \bar{x})^2$,
 $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$, $S_{yy} = \sum (y_i - \bar{y})^2$

최소제곱법: 해의 성질

≡ 평균점 통과



Least-squares fit of ice cream consumption on temperature, with the mean point marked



- 절편 식 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 를 옮기면 $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$, 곧 $x = \bar{x}$ 에서의 적합값이 정확히 $\bar{y}$. 확인 $0.207 + 0.00311 \times 49.1 = 0.359 = \bar{y}$
- 첫 번째 정규방정식으로부터 잔차의 합은 항상 0: $\sum_{i=1}^n e_i = 0$. 따라서 잔차의 평균도 0이며, 직선은 자료의 한가운데를 지나감

최대가능도법의 착안

◎ 정의

최대가능도법(maximum likelihood, 최대우도법): 지금 주어진 자료가 가장 나올 법하게 만드는 모수값을 고르는 방법. 가능도(likelihood)라는 함수를 정의하고, 그 함수가 최대가 되는 모수값을 찾음

확률을 말하려면 오차에 분포가 필요. $\varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$ 이면 $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$ (iid: 서로 독립이고 같은 분포)



The normal-error model (left) and the log-likelihood over candidate slopes (right)

왼쪽은 관측마다 종이가 하나씩 있고 중심만 직선을 따라 움직인다는 가정. 오른쪽 곡선의 꼭대기 $\hat{\beta}_1 = 0.00311$ 은 앞서 본 제곱합 곡선의 바닥과 같은 자리. 위아래로 뒤집은 모양

최대가능도 추정: 유도

✍ 가능도에서 정규방정식까지

- 1 밀도를 모두 곱한다. 관측이 서로 독립이므로 정규밀도 n 개의 곱이 **가능도**. 자료를 고정하고 모수를 변수로 본 함수이며, 지수를 모으면 앞 슬라이드의 제곱합 $S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ 이 저절로 등장

$$\begin{aligned} L(\beta_0, \beta_1, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{S(\beta_0, \beta_1)}{2\sigma^2}\right\} \end{aligned}$$

- 2 로그를 취한다. 로그는 증가함수이므로 최대점의 위치가 바뀌지 않음. β_0, β_1 이 들어 있는 항은 마지막 하나뿐

$$\ell(\beta_0, \beta_1, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} S(\beta_0, \beta_1)$$

- 3 계수 앞의 부호를 본다. 그 계수 $-\frac{1}{2\sigma^2}$ 는 항상 음수이므로, ℓ 을 β_0, β_1 로 미분해 0으로 놓으면 앞 슬라이드의 정규방정식이 그대로 나옴

$$\ell \text{ 을 최대화 } \iff S(\beta_0, \beta_1) \text{ 을 최소화}$$

최대가능도 추정: 결과

田 최소제곱과의 비교

$$\sigma^2 \text{ 에 대해서는 } \frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{S}{2(\sigma^2)^2} = 0 \text{ 이므로 } \hat{\sigma}_{ML}^2 = S(\hat{\beta}_0, \hat{\beta}_1)/n$$

Quantity	Least squares	Maximum likelihood
$\hat{\beta}_1$	0.003107	0.003107
$\hat{\beta}_0$	0.206862	0.206862
$\hat{\sigma}^2$	$S/(n-2) = 0.0500/28 = 0.001786$	$S/n = 0.0500/30 = 0.001667$

Simple regression of IC on temp, n = 30. The two criteria give the same line.

- 절편과 기울기는 동일
- $E(\hat{\sigma}_{ML}^2) = \frac{n-2}{n}\sigma^2$: **편향추정량**

- 정규가정이 있으면 최소제곱은 **가장 그럴듯한 직선**이기도 함. 앞서 제곱합을 택한 세 번째 근거가 여기서 증명됨
- 표준오차·검정·신뢰구간에는 자유도를 반영한 불편추정량 $S/(n-2)$ 를 씀. $\hat{\sigma}_{ML}^2$ 은 뒤의 AIC 계산에 쓰임
- 정규가정이 깨지면 두 기준은 **갈라짐**. 이때는 가정에 맞는 가능도를 세워 최대화(일반화선형모형)

공분산, 상관계수, 회귀계수의 관계

💡 핵심: 아래 세 표현은 모두 동일

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\text{cov}(y, x)}{\text{var}(x)} = r \frac{s_y}{s_x}$$

- $\text{var}(x) = s_x^2$: x 의 표본분산
- r : 표본상관계수

📝 유도

- $S_{xy} = (n - 1) \text{cov}(y, x)$, $S_{xx} = (n - 1) \text{var}(x)$ 이므로 $(n - 1)$ 이 약분

$$\frac{S_{xy}}{S_{xx}} = \frac{(n - 1) \text{cov}(y, x)}{(n - 1) \text{var}(x)} = \frac{\text{cov}(y, x)}{\text{var}(x)}$$

- $\text{cov}(y, x) = r s_y s_x$, $\text{var}(x) = s_x^2$ 이므로 s_x 가 한 번 더 약분


$$\frac{\text{cov}(y, x)}{\text{var}(x)} = \frac{r s_y s_x}{s_x^2} = r \frac{s_y}{s_x}$$

📖 해석

- 기울기 = 상관계수 $\times$ 흩어짐 비율 s_y/s_x
- 방향과 강도는 상관계수가, 단위와 눈금은 표준편차 비율이 결정
- 상관계수는 무단위, 기울기의 단위는 $(y \text{의 단위})/(x \text{의 단위})$

적합 결과: 아이스크림 자료

직선 하나, 계산 경로 넷



$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, \quad e_i = y_i - \hat{y}_i$$

$$\hat{y} = 0.207 + 0.00311 x$$

Term	Estimate	Interpretation
$\hat{\beta}_0$	0.207	Fitted IC at temp = 0
$\hat{\beta}_1$	0.00311	Mean change in IC per 1°F

Fitted simple linear regression (IC on temp, n = 30)

Ice cream consumption vs temperature with the fitted least-squares line

온도가 1°F 오를 때 소비량의 평균이 약 0.00311 증가. 자료에 temp = 0 인 관측이 없으므로 절편은 직선의 높이를 맞추는 값으로 읽음

Route	Expression	Input values	Slope
(1) Sums of squares	S_{xy}/S_{xx}	$(n - 1)$ cancels out	0.00311
(2) Covariance	$\text{cov}(y, x)/s_x^2$	$s_x^2 = 16.4^2 = 269$	0.00311
(3) Correlation	$r s_y/s_x$	$0.776 \times 0.0658/16.4$	0.00311
(4) Normal equations	$\hat{\beta}_1$ from $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$	n.a.	0.00311

Four routes to the same slope estimate (ice cream data, IC on temp, n = 30)

계산 경로가 서로 다른데도 네 값이 모두 일치함. 우연이 아니라 앞 장의 항등식이 성립한 결과

Gauss-Markov 정리

◎ 최소분산 선형 불편추정량

오차의 평균이 0이고, 분산이 모두 σ^2 로 같으며, 서로 무관하면, 최소제곱 추정량은 선형 불편추정량 가운데 분산이 가장 작다(BLUE, Best Linear Unbiased Estimator).

▲ 정리가 말하지 않는 것

- '선형'은 y 의 가중합으로 쓸 수 있다는 뜻. 비선형 추정량까지 포함해 최소라는 주장은 아님
- '불편' 조건을 풀면 분산이 더 작은 **편향**추정량이 있을 수 있음(능형회귀 등)
- **정규분포 가정은 필요 없음**. 정규성은 $t \cdot F$ 검정과 구간추정에서 비로소 필요
- 등분산이 깨지면 최소제곱은 여전히 불편이지만 최소분산은 아님 → 6장 가중회귀



Gauss-Markov 정리: 경쟁자로 확인

▮ 두 집단 평균으로 만든 추정량

x 의 중앙값에서 두 무리로 갈라 평균점끼리 이은 기울기 $\tilde{\beta}_1 = (\bar{y}_H - \bar{y}_L)/d$. 무게 $d = \bar{x}_H - \bar{x}_L = 29.53$ 이 x 만으로 정해지므로 **선형**, $\sum a_i = 0 \cdot \sum a_i x_i = 1$ 이므로 **불편**. 분산이 $\hat{\sigma}^2 \sum a_i^2$ 이고 $\hat{\sigma}^2$ 은 두 방법이 공유하므로 **가중치 제공합만** 견주면 됨 (이 분산 공식과 $\sum c_i^2 = 1/S_{xx}$ 는 다음 두 장에서 유도)

$$\text{두 집단 평균: } \sum a_i^2 = \frac{1/n_H + 1/n_L}{d^2} = 1.529 \times 10^{-4}$$

$$\text{최소제곱: } \sum c_i^2 = \frac{1}{S_{xx}} = 1.279 \times 10^{-4}$$



Least squares against a competing linear unbiased estimator (ice cream data, $n = 30$)

분산비 $1.529/1.279 = 1.196$, 표준오차로는 0.000478 대 0.000523. $\hat{\sigma}^2$ 이 약분되므로 이 비는 자료의 흩어짐과 무관하게 가중치만으로 결정됨

회귀계수의 불편성: 증명

✍ 기울기의 가중합 표현

- 1 $\hat{\beta}_1$ 을 y 의 가중합으로 고쳐 쓴다. S_{xy} 에서 $\bar{y}$ 가 붙은 항은 $\sum (x_i - \bar{x}) = 0$ 이라 사라짐. 남은 가중치 c_i 는 x 만으로 정해지는 상수

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum (x_i - \bar{x}) y_i}{S_{xx}} = \sum_{i=1}^n c_i y_i, \quad c_i = \frac{x_i - \bar{x}}{S_{xx}}$$

- 2 가중치의 두 성질을 확인한다. 이 두 줄이 증명의 전부이며, 둘째 등식은 $\sum (x_i - \bar{x}) x_i = \sum x_i^2 - n\bar{x}^2 = S_{xx}$ 에서 나옴

$$\sum c_i = \frac{\sum (x_i - \bar{x})}{S_{xx}} = 0, \quad \sum c_i x_i = \frac{\sum (x_i - \bar{x}) x_i}{S_{xx}} = \frac{S_{xx}}{S_{xx}} = 1$$

- 3 기댓값을 취한다. 모형이 $E(y_i) = \beta_0 + \beta_1 x_i$ 이므로 두 성질이 그대로 대입됨

$$E(\hat{\beta}_1) = \sum c_i E(y_i) = \beta_0 \underbrace{\sum c_i}_{=0} + \beta_1 \underbrace{\sum c_i x_i}_{=1} = \beta_1$$

- 4 절편은 따라 나온다. $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 이고 $E(\bar{y}) = \beta_0 + \beta_1 \bar{x}$ 이므로

$$E(\hat{\beta}_0) = E(\bar{y}) - \bar{x} E(\hat{\beta}_1) = (\beta_0 + \beta_1 \bar{x}) - \bar{x} \beta_1 = \beta_0$$

$$E(\hat{\beta}_0) = \beta_0, \quad E(\hat{\beta}_1) = \beta_1$$

회귀계수의 분산과 공분산

◎ 같은 가중치의 활용

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}, \quad \text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right), \quad \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\sigma^2 \bar{x}}{S_{xx}}$$

유도: 관측이 서로 무관하고 분산이 모두 σ^2 이므로 $\text{Var}(\sum c_i y_i) = \sigma^2 \sum c_i^2$ 이고,
 $\sum c_i^2 = \sum (x_i - \bar{x})^2 / S_{xx}^2 = 1/S_{xx}$. 절편은 $\text{Cov}(\bar{y}, \hat{\beta}_1) = \sigma^2 \sum c_i / n = 0$ 이라 두 항의 분산이 그대로 더해짐

여기서 $SSE = \sum_{i=1}^n e_i^2 = \sum (y_i - \hat{y}_i)^2$ 는 **잔차제곱합**이며, $\hat{\sigma}^2$ 이 σ^2 의 불편추정량이 되는 이유는 두 장 뒤에서 유도

Quantity	Formula	Ice cream (IC on temp)
$\hat{\sigma}^2$	$SSE/(n - 2)$	0.0017860
$\text{se}(\hat{\beta}_1)$	$\hat{\sigma}/\sqrt{S_{xx}}$	0.000478
$\text{se}(\hat{\beta}_0)$	$\hat{\sigma}\sqrt{1/n + \bar{x}^2/S_{xx}}$	0.0247
$\widehat{\text{Cov}}(\hat{\beta}_0, \hat{\beta}_1)$	$-\hat{\sigma}^2 \bar{x}/S_{xx}$	-1.121×10^{-5}

Estimated variability of the two coefficients (n = 30, x-bar = 49.1, Sxx = 7820.7)

- S_{xx} 가 클수록 기울기의 분산이 작아짐. **설명변수를 넓게 잡으라**는 설계 지침이 여기서 나옴
- 절편의 분산에 $\bar{x}^2$ 이 들어 있는 이유: 절편은 $x = 0$ 에서의 값인데 자료가 그 지점에서 멀수록 불확실. 이 자료의 온도 범위는 24~72 °F 로 0을 포함하지 않음
- 공분산이 **음수**: 직선이 평균점 $(\bar{x}, \bar{y})$ 를 반드시 지나므로, 기울기를 크게 잡으면 절편은 작게 잡힘

Gauss-Markov 정리: 증명

✍ 경쟁자의 손해 $\sum d_i^2$

- 1 경쟁자가 만족해야 할 조건을 적는다. 다른 선형추정량 $\tilde{\beta}_1 = \sum a_i y_i$ 가 불편이려면

$$E(\tilde{\beta}_1) = \beta_0 \sum a_i + \beta_1 \sum a_i x_i = \beta_1 \implies \sum a_i = 0, \quad \sum a_i x_i = 1$$

- 2 최소제곱과의 차이를 d_i 로 둔다. $a_i = c_i + d_i$ 로 쓰면 위 조건과 $\sum c_i = 0, \sum c_i x_i = 1$ 에서 d 쪽 두 성질이 나오고, 그것이 교차항을 없앴

$$\sum d_i = 0, \quad \sum d_i x_i = 0 \implies \sum c_i d_i = \frac{\sum d_i x_i - \bar{x} \sum d_i}{S_{xx}} = 0$$

- 3 가중치 제곱합을 전개한다. $a_i = c_i + d_i$ 를 제곱해 더하면 세 덩어리가 나오는데, 가운데가 방금 구한 교차항이라 통째로 사라짐

$$\sum a_i^2 = \sum (c_i + d_i)^2 = \sum c_i^2 + 2 \underbrace{\sum c_i d_i}_{=0} + \sum d_i^2 = \sum c_i^2 + \sum d_i^2$$

- 4 분산으로 옮긴다. $\sigma^2 \sum c_i^2$ 이 곧 최소제곱의 분산이고, 뒤에 더해지는 몫은 제곱합이므로 항상 0 이상

$$\text{Var}(\tilde{\beta}_1) = \sigma^2 \sum a_i^2 = \underbrace{\sigma^2 \sum c_i^2}_{= \text{Var}(\hat{\beta}_1)} + \sigma^2 \sum d_i^2$$

$$\text{Var}(\tilde{\beta}_1) \geq \text{Var}(\hat{\beta}_1), \quad \text{등호는 모든 } d_i = 0, \text{ 곧 } \tilde{\beta}_1 = \hat{\beta}_1 \text{ 일 때만}$$

오차분산의 추정: $E(\hat{\sigma}^2) = \sigma^2$

증명

- 1 잔차를 편차의 꼴로 바꾼다. $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 를 넣으면 $e_i = (y_i - \bar{y}) - \hat{\beta}_1(x_i - \bar{x})$, 제곱해 더한 뒤 $S_{xy} = \hat{\beta}_1 S_{xx}$ 를 쓰면

$$SSE = S_{yy} - 2\hat{\beta}_1 S_{xy} + \hat{\beta}_1^2 S_{xx} = S_{yy} - \hat{\beta}_1^2 S_{xx}$$

- 2 앞 항의 기댓값. 모형을 넣으면 $y_i - \bar{y} = \beta_1(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon})$ 이고, 교차항의 기댓값은 0

$$E(S_{yy}) = \beta_1^2 S_{xx} + \underbrace{E \sum (\varepsilon_i - \bar{\varepsilon})^2}_{= (n-1)\sigma^2} = \beta_1^2 S_{xx} + (n-1)\sigma^2$$

- 3 뒤 항의 기댓값. $E(Z^2) = \text{Var}(Z) + [E(Z)]^2$ 에 앞 두 장의 결과 $\text{Var}(\hat{\beta}_1) = \sigma^2 / S_{xx}$, $E(\hat{\beta}_1) = \beta_1$ 을 대입

$$E(\hat{\beta}_1^2 S_{xx}) = \left(\frac{\sigma^2}{S_{xx}} + \beta_1^2 \right) S_{xx} = \sigma^2 + \beta_1^2 S_{xx}$$

- 4 빼면 β_1 항이 상쇄된다. $\bar{y}$ 에서 자유도 하나, $\hat{\beta}_1$ 에서 하나가 더 빠져 $n - 2$

$$E(SSE) = [\beta_1^2 S_{xx} + (n-1)\sigma^2] - [\sigma^2 + \beta_1^2 S_{xx}] = (n-2)\sigma^2$$

$$\hat{\sigma}^2 = \frac{SSE}{n-2} \Rightarrow E(\hat{\sigma}^2) = \sigma^2, \quad \hat{\sigma}_{ML}^2 = \frac{SSE}{n} \Rightarrow E(\hat{\sigma}_{ML}^2) = \frac{n-2}{n}\sigma^2$$

기울기의 표준오차

◎ 정의

$$\hat{\sigma}^2 = \frac{SSE}{n - 2}, \quad \text{se}(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{S_{xx}}}$$

- $\hat{\sigma}^2$: 오차분산 σ^2 의 추정값, $\hat{\sigma}$: 잔차 표준오차
- $n - 2$: 자유도. 관측 n 개에서 추정한 계수 2개를 뺀 값
- $\text{se}(\hat{\beta}_1)$: **표준오차**. 자료가 바뀔 때 $\hat{\beta}_1$ 이 흔들리는 폭의 추정값

📌 아이스크림 자료 계산

$$\hat{\sigma}^2 = 0.00179, \hat{\sigma} = 0.0423, S_{xx} = (n - 1)s_x^2 = 7820.7$$

$$\text{se}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} = \sqrt{\frac{0.00179}{7820.7}} = 0.000478$$

S_{xx} 가 클수록, 곧 설명변수가 넓게 퍼져 있을수록 기울기를 정밀하게 추정함.

회귀계수의 검정

◎ 정의

$$H_0 : \beta_1 = 0 \text{ (} x \text{는 } y \text{를 설명하지 못함)} \quad \text{vs} \quad H_1 : \beta_1 \neq 0$$

$$H_0 : \beta_0 = 0 \text{ (직선이 원점을 지남)} \quad \text{vs} \quad H_1 : \beta_0 \neq 0$$

$$t = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)} \sim t_{n-2} \quad (H_0 \text{ 아래에서}), \quad j = 0, 1$$

- H_0 : 귀무가설(관측된 차이가 우연 때문이라고 보는 기본 가정)
- H_1 : 대립가설
- t : 추정된 계수를 그 표준오차로 나눈 값, 계수가 오차분산의 몇 배만큼 떨어져 있는지를 나타냄

회귀계수 검정: 결과와 p 값

田 아이스크림 자료

Term	Estimate	se	t	p -value
$\hat{\beta}_0$ (intercept)	0.20686	0.02470	8.37	4.1×10^{-9}
$\hat{\beta}_1$ (temp)	0.00311	0.000478	6.50	4.8×10^{-7}

Tests of H_0 : coefficient = 0 for the ice cream data (IC on temp, $n = 30$, $df = 28$)

각 t 는 추정값을 자기 표준오차로 나눈 값이고, 자유도 28의 t 분포에서 그 값의 양측 꼬리 면적이 p 값

💡 p 값 읽는 법: H_0 가 참이라는 가정 아래 지금 관측된 것만큼 또는 그보다 더 극단적인 결과가 나올 확률


- 4.8×10^{-7} 은 $1/(4.8 \times 10^{-7}) \approx 2.1 \times 10^6$, 곧 약 200만 번에 한 번꼴
- 따라서 H_0 를 기각하고 온도가 소비량을 설명한다고 판단함
- p 값은 가설이 참일 확률이 아님

결정계수 R^2 : 변동의 분해


◎ 총변동의 분해

$$SST = SSR + SSE, \quad R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

(a) One observation, split in two



(b) Adding the squares over all $n = 30$



$$R^2 = SSR / SST$$

$$= 0.076 / 0.126 = 0.602$$

the line explains 60.2% of the spread in y

- $SST = \sum (y_i - \bar{y})^2$ 총변동 · $SSR = \sum (\hat{y}_i - \bar{y})^2$ 회귀로 설명된 변동 · $SSE = \sum (y_i - \hat{y}_i)^2$ 남은 변동
- R^2 = 총변동 가운데 직선이 설명한 비율, $0 \leq R^2 \leq 1$. 1에 가까울수록 직선이 흩어짐을 많이 설명

결정계수와 상관계수

💡 $R^2 = r^2$

설명변수가 하나인 단순선형회귀에서 결정계수는 표본상관계수의 제곱과 같다.

$$R^2 = [\text{corr}(y, x)]^2 = [\text{corr}(y, \hat{y})]^2$$

Quantity	Value
$r = \text{corr}(y, x)$	0.776
r^2	0.602
R^2 of the fitted model	0.602

The coefficient of determination equals the squared correlation (IC on temp, n = 30)

⚠ 주의

- R^2 의 적정 수준에는 절대 기준이 없고 분야와 자료 유형에 따라 다름
- R^2 만으로 모형의 좋고 나쁨을 단정하지 않으며, 잔차 진단과 함께 판단
- $R^2 = r^2$ 라는 관계는 설명변수가 하나일 때의 성질이며, 다중회귀에서는 y 와 적합값 $\hat{y}$ 의 상관계수 제곱으로만 성립

회귀분산분석: 표의 구조

田 제공합과 자유도

앞의 $SST = SSR + SSE$ 를 자유도와 함께 표로 정리하면, 모형 전체를 한꺼번에 검정하는 통계량이 나온다.

Source	df	Sum of squares	Mean square	F
Regression	1	SSR	$MSR = SSR/1$	MSR/MSE
Residual	$n - 2$	SSE	$MSE = SSE/(n - 2)$	
Total	$n - 1$	SST		

Analysis of variance for simple linear regression

평균제곱(Mean square)은 제공합을 자유도로 나눈 값, 곧 **자유도 하나당 변동**. 크기가 다른 두 제공합을 견줄 수 있게 척도를 맞추는 작업이며, $MSE = \hat{\sigma}^2$ 은 앞에서 쓴 오차분산 추정값과 같은 것

- 가설은 $H_0 : \beta_1 = 0$ 대 $H_1 : \beta_1 \neq 0$ 로 t 검정과 같음. 단순회귀에서는 설명변수가 하나뿐이라 **모형 전체의 검정**과 **기울기 하나의 검정**이 같은 질문
- H_0 가 참이면 MSR 과 MSE 가 모두 σ^2 의 불편추정량이 되어 F 는 1 근처. 설명한 몫이 커질수록 F 가 커짐
- H_0 아래에서 $F \sim F(1, n - 2)$ 이며, 비이므로 **오른쪽 한쪽 꼬리만 봄**

회귀분산분석표: $F = t^2$ 확인

田 두 검정의 일치

Source	df	Sum Sq	Mean Sq	F	p -value
Regression	1	0.075514	0.075514	42.28	4.8×10^{-7}
Residual	28	0.050009	0.001786		
Total	29	0.125523			

Analysis of variance for the ice cream data (IC on temp, n = 30)

✔ 설명변수가 하나면 두 검정이 완전히 같다

$$F = t^2 : \quad 6.5023^2 = 42.280, \quad F(0.95; 1, 28) = 2.0484^2 = 4.196 = [t(0.975; 28)]^2$$

통계량도 임계값도 p 값(4.8×10^{-7}) 도 모두 일치. 설명변수가 둘 이상이면 이 관계는 깨지고, F 는 계수 전체를 한꺼번에 묻는 별도의 검정이 됨

- 세로로 더해짐: $0.075514 + 0.050009 = 0.125523$, $1 + 28 = 29$
- $MSE = 0.001786 = \hat{\sigma}^2$ 이고 $\sqrt{MSE} = 0.04226 = \hat{\sigma}$ 가 잔차 표준오차
- $R^2 = SSR/SST = 0.075514/0.125523 = 0.6016$ 도 이 표에서 바로 읽힘

회귀계수의 신뢰구간

◎ 정의

$$\hat{\beta}_j \pm t_{\alpha/2, n-2} \text{se}(\hat{\beta}_j), \quad j = 0, 1$$

- $t_{\alpha/2, n-2}$: 자유도 $n - 2$ 인 t 분포의 임계값
- 이 구간이 $100(1 - \alpha)\%$ 신뢰구간

✍ 아이스크림 자료의 95% 신뢰구간 ($\alpha = 0.05$, 자유도 28, $t_{0.025, 28} = 2.048$)

$$\hat{\beta}_1 : 0.00311 \pm 2.048 \times 0.000478 = 0.00311 \pm 0.00098 \Rightarrow (0.00213, 0.00409)$$

$$\hat{\beta}_0 : 0.20686 \pm 2.048 \times 0.02470 = 0.20686 \pm 0.05060 \Rightarrow (0.15627, 0.25746)$$

두 구간 모두 0을 포함하지 않으므로 앞의 검정 결과와 일치함.

확률은 계수가 아니라 구간을 만드는 절차에 붙음. 해석의 자세한 내용은 2장 신뢰구간 참조

구간추정: 평균반응과 새 관측

✂ 두 구간의 차이

신뢰구간 (평균반응)

새 조건 x_0 에서 조건부 기댓값 $E(y \mid x = x_0)$ 을 잡는 구간

$$\hat{y}_0 \pm t_{\alpha/2, n-2} \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

- $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$: 새 조건에서의 적합값
- $\hat{\sigma}$: 잔차 표준오차

예측구간 (새 관측 하나)

새로 관측될 값 y_0 자체를 잡는 구간

$$\hat{y}_0 \pm t_{\alpha/2, n-2} \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

근호 안에 1이 더해지는 이유는 개별 관측의 오차 ε_0 가 추가되기 때문. 따라서 **예측구간은 항상 신뢰구간보다 넓음**

두 구간의 수치 비교

田 아이스크림 자료, $x_0 = 65$

$$\hat{y}_0 = 0.207 + 0.00311 \times 65 = 0.409, \bar{x} = 49.1, S_{xx} = 7820.7, \hat{\sigma} = 0.0423, t_{0.025, 28} = 2.048$$

$$c = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} = \frac{1}{30} + \frac{15.9^2}{7820.7} = 0.0657$$

Interval	Half-width	Result
신뢰구간	$t \hat{\sigma} \sqrt{c} = 0.0222$	(0.387, 0.431)
예측구간	$t \hat{\sigma} \sqrt{1 + c} = 0.0893$	(0.319, 0.498)

Two intervals for the ice cream data at temp = 65 (n = 30)

예측구간의 폭이 신뢰구간의 약 4.0배. 근호 안의 1 이 0.0657 보다 압도적으로 크기 때문

두 구간 모두 $(x_0 - \bar{x})^2$ 항 때문에 x_0 가 $\bar{x}$ 에서 멀어질수록 넓어짐. 자료 범위 밖으로 외삽하면 구간이 급격히 넓어짐

추정에서 검정까지: 계산 경로

✍ 자료에서 t 통계량까지

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 7820.7, \quad S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 24.3$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{24.3}{7820.7} = 0.00311, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 0.207$$

$$\hat{\sigma}^2 = \frac{\text{SSE}}{n-2} = \frac{0.0500}{28} = 0.00179, \quad \hat{\sigma} = 0.0423$$

$$\text{SE}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} = \sqrt{\frac{0.00179}{7820.7}} = 0.000478, \quad t = \frac{\hat{\beta}_1}{\text{SE}(\hat{\beta}_1)} = 6.50$$

계산 경로: 결과표와 각 항의 뜻

田 프로그램 출력표

Term	Estimate	SE	t	p -value
(Intercept)	0.207	0.0247	8.37	4.1×10^{-9}
temp	0.00311	0.000478	6.50	4.8×10^{-7}

Fitted model IC on temp; residual standard error 0.0423 on 28 degrees of freedom, R-squared 0.602

💡 각 항의 뜻

- **Estimate:** 최소제곱 정규방정식의 해 $\hat{\beta}_j$
- **SE:** $\hat{\beta}_1$ 의 표집분포의 표준편차 $\hat{\sigma} / \sqrt{S_{xx}} \cdot S_{xx}$ 가 클수록 작아짐
- **t :** 추정값을 그 표준오차 단위로 잰 값. H_0 아래에서 자유도 $n - 2 = 28$ 의 t 분포를 따름
- **p -value:** $H_0 : \beta_1 = 0$ 에 대한 양측 검정의 유의확률
- **R^2 :** $0.602 = 0.776^2$, 곧 상관계수의 제곱. 단순회귀에서만 성립하는 항등식

이 장의 정리

≡ Simple Linear Regression

관계를 쟀다(공분산과 상관계수로 방향과 강도) → 직선을 긋는다(수직 간격의 제곱 합이 최소) → 계수를 읽는다(x 1단위당 y 의 평균 변화) → 불확실성을 확인한다(R^2 , t 검정, 구간).

Concept	Formula	Ice cream data
Covariance	$\frac{1}{n-1} \sum (y_i - \bar{y})(x_i - \bar{x})$	0.838
Correlation	$\text{cov}(y, x) / (s_y s_x)$	0.776
Slope	$r s_y / s_x = S_{xy} / S_{xx}$	0.00311
Coefficient of determination	$1 - SSE / SST = r^2$	0.602

Summary of the four quantities of simple linear regression

상관계수와 회귀 기울기는 같은 정보를 다른 눈금으로 표현한 값. 계수는 언제나 표준오차 또는 구간과 함께 보고할 것

오차에 정규분포를 가정하면 최소제곱 직선이 곧 **최대가능도 추정**. 회귀계수는 같고 오차분산만 $S/(n-2)$ 와 S/n 으로 갈림

🔗 다음 장: Multiple Linear Regression: 온도 하나로 설명한 60% 외에 남은 40%는 무엇이 설명하는가. 설명변수를 여럿으로 확장

참고문헌

☰ 교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.