

Regression Analysis

4. Multiple Linear Regression | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division
Korea Institute of Oriental Medicine

2026-09-01

Multiple Linear Regression

설명변수가 여럿일 때

? 질문

☞ 앞 장에서 여기까지: 온도 하나로 $R^2 = 0.602$. ❓ 이 장의 질문: 설명변수를 여럿으로 늘리면 계수를 어떻게 읽고, 얼마나 믿을 수 있는가

단순선형회귀의 적합 결과는 $R^2 = 0.602$ 였다. 소비량 변동의 약 40%는 온도 하나로 설명되지 않은 채 남아 있다.

Variable	Meaning	Role in this chapter
IC	Per-capita ice cream consumption (pints)	Response y_i
price	Price of ice cream	Predictor x_{i1}
income	Income	Predictor x_{i2}
temp	Mean temperature (°F)	Predictor x_{i3}
period	Index of the four-week period	Identifier
year	Observation year code (0/1/2)	Used in the Dummy Variable chapter

Ice cream data: $n = 30$ four-week periods, 6 variables

아이스크림 자료: 데이터 구조

田 앞 5행

period	IC	price	income	temp	year
1	0.386	0.270	78	41	0
2	0.374	0.282	79	56	0
3	0.393	0.277	81	63	0
4	0.425	0.280	80	68	0
5	0.406	0.272	76	69	0


First five rows of the ice cream data (n = 30)

≡ 표의 한 행이 모형의 한 식

- 한 행 = 4주짜리 관측 기간 하나 = 회귀식 한 줄. 그런 행이 모두 30개
- IC 열이 통째로 반응변수 벡터, price·income·temp 열이 설명변수 x_{i1}, x_{i2}, x_{i3}
- 이 표를 숫자 격자로 그대로 옮긴 것이 뒤에 나올 설계행렬

설명변수 간 관계 파악: 산점도 행렬

사전 자료 탐색



Scatterplot matrix of the ice cream data

읽는 순서

- 변수 4개의 모든 짝을 산점도로 그려 한 화면에 배치한 그림
- `temp`와 `IC`가 만나는 칸: 뚜렷한 우상향
- `price`, `income`과 `IC`가 만나는 칸: 방향이 흐릿함
- 설명변수끼리 만나는 칸도 함께 볼 것. 정보가 겹치는지 확인하기 위함

다중선형회귀모형: 정의

◎ 설명변수의 확장

관측 $i = 1, \dots, n$ 에 대하여

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i$$

기호

- y_i : i 번째 반응변수(소비량), x_{ij} : i 번째 관측의 j 번째 설명변수 값
- β_0 : 절편, $\beta_1, \dots, \beta_p$: 각 설명변수의 회귀계수
- ε_i : 평균 0, 분산 σ^2 인 오차
- n : 관측 수(30), p : 설명변수 개수(3)

✎ 조건부 기댓값으로 다시 쓰면

$$E(Y \mid x_1, \dots, x_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

회귀가 설명변수 조건 아래 반응변수의 평균이라는 정의는 그대로이고, 조건 자리에 놓이는 변수의 개수만 늘어남

다중선형회귀모형: 행렬 표현

✍ 관측 30개의 한 식 표현

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & x_{13} \\ 1 & x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} \end{pmatrix}$$

기호

- $\mathbf{y}$: 반응변수 n 개를 쌓은 벡터, $\boldsymbol{\varepsilon}$: 오차 벡터
- $\mathbf{X}$: 절편용 1의 열과 설명변수 열을 묶은 $n \times (p + 1)$ 설계행렬
- $\boldsymbol{\beta}$: 회귀계수 벡터($p + 1$ 개). 이 자료에서 $\mathbf{X}$ 는 30×4

✔ 행렬 곱과 개별 식의 동치

- 행렬 곱 규칙 = 행과 열을 짝지어 곱한 뒤 더하기
- $\mathbf{X}\boldsymbol{\beta}$ 의 i 번째 성분이 $\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}$
- 따라서 이 한 줄을 풀어 쓰면 관측별 식 30줄과 정확히 일치

아이스크림 자료: 설계행렬

✍ 표에서 행렬로

▣ Design matrix for the ice cream data, $n = 30, p = 3$

$$\underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_{30} \end{pmatrix}}_{\mathbf{y} \ (30 \times 1)} = \underbrace{\begin{pmatrix} 1 & x_{11} & x_{12} & x_{13} \\ 1 & x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{30,1} & x_{30,2} & x_{30,3} \end{pmatrix}}_{\mathbf{X} \ (30 \times 4)} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}}_{\boldsymbol{\beta} \ (4 \times 1)} + \underbrace{\begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_{30} \end{pmatrix}}_{\boldsymbol{\varepsilon} \ (30 \times 1)}$$

- $\mathbf{y}$: 30개 기간의 소비량 ic 를 모은 벡터
- $\mathbf{X}$ 의 2, 3, 4열: $price$ x_{i1} , $income$ x_{i2} , $temp$ x_{i3}
- 앞에서 본 표 첫 행의 실제 값: $y_1 = 0.386, x_{11} = 0.270, x_{12} = 78, x_{13} = 41$

최소제곱 해와 정규방정식

✍ 벡터 미분

- 1 목적함수를 전개한다. 잔차제곱합은 스칼라이므로 전치를 취해도 같은 값. 가운데 두 항이 서로 전치 관계라 하나로 묶임

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X}\beta$$

- 2 2장의 미분 공식 둘을 그대로 쓴다. $\frac{\partial(\beta^\top \mathbf{a})}{\partial \beta} = \mathbf{a}$ 와 $\frac{\partial(\beta^\top \mathbf{A}\beta)}{\partial \beta} = 2\mathbf{A}\beta$ ($\mathbf{A}$ 가 대칭일 때). 첫 항은 β 가 없으므로 사라짐

$$\frac{\partial S}{\partial \beta} = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\beta$$

- 3 0 으로 놓으면 정규방정식. $\mathbf{X}$ 가 full rank이면 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 가 존재하므로 양변 왼쪽에 곱해 해를 얻음

$$\mathbf{X}^\top \mathbf{X}\beta = \mathbf{X}^\top \mathbf{y}$$

$$\therefore \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

최소제곱 해가 존재할 조건

◎ $\mathbf{X}$ 의 full rank 조건

$\mathbf{X}$ 가 $n \times (p + 1)$ 이고 $\text{rank}(\mathbf{X}) = p + 1 (\leq n)$ 일 때, 그리고 그때만 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 가 존재하고 최소제곱 해가 유일하게 정해진다.

- 2장에서 본 사실 그대로. $\text{rank}(\mathbf{X}^\top \mathbf{X}) = \text{rank}(\mathbf{X})$ 이므로, $\mathbf{X}$ 가 full rank가 아니면 $\det(\mathbf{X}^\top \mathbf{X}) = 0$ 이고 역행렬이 없음
- 깨지는 경우 둘. 어떤 설명변수가 다른 설명변수들의 **정확한 선형결합**일 때(예: 섭씨와 화씨를 함께 투입), 그리고 $n < p + 1$ 로 관측이 계수보다 적을 때

田 아이스크림 완전모형: $n = 30, p = 3$ 이므로 $\mathbf{X}$ 는 30×4 . $\text{rank}(\mathbf{X}) = 4 = p + 1$ 로 full rank이며 해가 유일하게 정해짐

잔차제곱합은 두 가지로 같게 계산됨: $\mathbf{e}^\top \mathbf{e} = \mathbf{y}^\top \mathbf{y} - \hat{\boldsymbol{\beta}}^\top \mathbf{X}^\top \mathbf{y} = 0.035313$

모자행렬: 정의

◎ 적합값을 만드는 행렬

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top, \quad \hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{H}\mathbf{y}$$

기호

- $\mathbf{H}$: 설계행렬 $\mathbf{X}$ 만으로 결정되는 $n \times n$ 행렬, $\hat{\mathbf{y}}$: 적합값 벡터
- $\mathbf{y}$ 에 곱해 주면 $\mathbf{y}$ 가 모자를 쓴 $\hat{\mathbf{y}}$ 가 된다고 해서 **모자행렬(hat matrix)**

✍ 잔차도 같은 방식으로 얻는다


$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\mathbf{y}$$

$\mathbf{I}$: $n \times n$ 항등행렬, $\mathbf{e}$: 잔차 벡터($e_i = y_i - \hat{y}_i$). 적합값과 잔차가 모두 $\mathbf{y}$ 의 선형변환으로 표현됨

모자행렬: 직교사영

ㄴ 최소제곱의 기하학적 의미

Fitted Values Are an Orthogonal Projection of y



ㄴ 그림이 말하는 것

- $\hat{y} = Hy$ 는 y 를 X 의 열공간 (column space)에 수직으로 내린 사영
- 잔차 $e = (I - H)y$ 는 그 열공간에 직교: $X^T e = 0$
- 직교하므로 $\hat{y}$ 는 열공간 위의 점 가운데 y 에 가장 가까운 점

Fitted values as an orthogonal projection of y onto the column space of X

모자행렬: 성질과 확인

田 대칭, 멱등, 대각합

성질

Property	Expression	Ice cream full model
Size	$n \times n$	30×30
Symmetry	$\mathbf{H}^\top = \mathbf{H}$	성립
Idempotence	$\mathbf{H}\mathbf{H} = \mathbf{H}$	성립
Trace	$\text{tr}(\mathbf{H}) = p + 1$	4
Mean leverage	$(p + 1)/n$	0.133

Properties of the hat matrix verified on the full model ($n = 30, p = 3$)

멱등은 이미 사영한 것을 다시 사영해도 그대로라는 뜻. 대각합 $\text{tr}(\mathbf{H})$ 는 대각원소의 합이며 추정된 계수의 개수 $p + 1 = 4$ 와 일치

다음 장 예고

- 대각원소 h_{ii} = 레버리지(**leverage**), 곧 i 번째 관측이 자기 적합값을 끌어당기는 힘의 크기
- 이 자료의 평균 레버리지 $4/30 = 0.133$, 최댓값 0.278(관측 9)
- 레버리지가 큰 관측이 결과를 좌우하는지 판정하는 기준은 다음 장에서

모자행렬: 세 성질의 증명

✍ 대칭성에서 나오는 셋

$\mathbf{X}^\top \mathbf{X}$ 가 대칭이므로 그 역행렬도 대칭. 이 사실만으로 세 성질이 모두 나옴

$$\mathbf{H}^\top = \{\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top\}^\top = \mathbf{X} \{(\mathbf{X}^\top \mathbf{X})^{-1}\}^\top \mathbf{X}^\top = \mathbf{H}$$

$$\mathbf{H}\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \underbrace{\mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}}_{=\mathbf{I}} \mathbf{X}^\top = \mathbf{H}$$

$$\text{tr}(\mathbf{H}) = \text{tr} \{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}\} = \text{tr}(\mathbf{I}_{p+1}) = p + 1$$

셋째 줄에는 $\text{tr}(\mathbf{A}\mathbf{B}) = \text{tr}(\mathbf{B}\mathbf{A})$ 를 사용

우도함수를 이용한 추정: 유도

✍ 최소제곱과의 일치

- 1 결합가능도를 행렬로 적는다. 오차가 서로 독립인 정규분포를 따른다고 가정하면 밀도 n 개의 곱이 가능도. 지수에 모인 것이 앞 슬라이드의 $S(\beta)$

$$L(\beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{(\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)}{2\sigma^2}\right\}$$

- 2 로그를 취한다. 로그는 증가함수라 최대점의 위치가 바뀌지 않음. β 가 들어 있는 항은 마지막 하나뿐

$$\ell(\beta, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}S(\beta)$$

- 3 계수의 부호를 본다. 그 항의 계수 $-\frac{1}{2\sigma^2}$ 는 항상 음수이므로, ℓ 을 크게 만드는 일과 $S(\beta)$ 를 작게 만드는 일이 같은 문제가 됨

$$\therefore \hat{\beta}_{ML} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \hat{\beta}_{LS}$$

우도함수를 이용한 추정: σ^2 의 차이

⚠ 분산추정량만 다름

ℓ 을 σ^2 로 미분해 0으로 놓으면 최대가능도 분산추정량이 나옴. 최소제곱에서 쓰는 불편추정량과 분모가 다름

$$\hat{\sigma}_{ML}^2 = \frac{1}{n} \mathbf{y}^\top (\mathbf{I} - \mathbf{H}) \mathbf{y} = \frac{SSE}{n}, \quad \hat{\sigma}^2 = \frac{SSE}{n - p - 1}$$

Quantity	Formula	Ice cream full model
SSE	$\mathbf{y}^\top (\mathbf{I} - \mathbf{H}) \mathbf{y}$	0.035313
$\hat{\sigma}_{ML}^2$	SSE/n	0.0011771
$\hat{\sigma}^2$ (불편)	$SSE/(n - p - 1)$	0.0013582
Ratio	$(n - p - 1)/n = 26/30$	0.8667

Two variance estimators for the ice cream full model ($n = 30, p = 3$)

$E(\hat{\sigma}_{ML}^2) = \frac{n - p - 1}{n} \sigma^2$ 로 **과소추정**. 표준오차·검정·구간에는 항상 불편추정량 $\hat{\sigma}^2 = SSE/(n - p - 1)$ 을 씀

회귀계수의 해석: 정의

◎ 다른 변수 고정

β_j 는 다른 설명변수를 모두 고정한 채 x_j 만 한 단위 증가시켰을 때 반응변수 평균의 변화량이다.

$$\beta_j = E(Y \mid x_j + 1, \text{나머지 고정}) - E(Y \mid x_j, \text{나머지 고정})$$

⚠ 해석에 반드시 붙는 조건절

- “다른 변수를 고정했을 때”를 빼면 다중회귀 계수의 해석은 성립하지 않음
- 같은 설명변수라도 모형에 함께 들어간 변수가 달라지면 계수 추정값도 달라짐

회귀계수의 해석: full model 적합

田 가격·소득·온도

추정 경로

설계행렬 $\mathbf{X}$ 의 네 열은 절편, price, income, temp

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & x_{13} \\ 1 & x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{30,1} & x_{30,2} & x_{30,3} \end{pmatrix}_{30 \times 4}, \quad \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \begin{pmatrix} 0.193 \\ -1.03 \\ 0.00331 \\ 0.00346 \end{pmatrix}$$

단순회귀와 달라진 것은 열의 개수뿐. 공식 자체는 그대로

적합식

$$\hat{y}_i = 0.193 - 1.03 x_{i1} + 0.00331 x_{i2} + 0.00346 x_{i3}$$

기호

- $\hat{y}_i$: i 번째 기간 소비량의 적합값
- x_{i1} : 가격, x_{i2} : 소득, x_{i3} : 온도

계수표

Term	Estimate	p-value
(Intercept)	0.193	n.a.
price (x_{i1})	-1.03	0.226
income (x_{i2})	0.00331	0.0090
temp (x_{i3})	0.00346	3.0×10^{-8}

Full model fit (n = 30, $R^2 = 0.719$, adjusted $R^2 = 0.686$)

회귀계수의 해석: 계수와 p-value

💡 추정 결과의 서술

$\hat{\beta}_3 = 0.00346$ (temp): 가격과 소득을 고정한 채 온도만 1도(°F) 상승할 때의 평균 소비량 증가분

💡 p-value의 뜻

- “이 계수는 사실 0이다”라는 주장이 옳다고 가정했을 때, 지금 자료에서 얻은 것만큼 또는 그보다 더 극단적인 추정값이 나올 확률
- 값이 작을수록 그 주장을 우연으로 설명하기 어려움. 흔히 0.05를 기준으로 삼고, 그보다 작으면 **유의하다**고 말함
- 단순회귀의 기울기 0.00311이 여기서 0.00346으로 바뀐 이유: 다른 변수가 들어오며 온도의 몫을 다시 나누었기 때문

'보정'의 의미: 두 단계


💡 고정외의 계산적 정의

- 1 반응변수에서 다른 변수의 몫을 뺀다. y 를 가격과 소득에만 회귀시키고 남은 잔차 $e_{y \cdot (\text{price, income})}$, 곧 가격과 소득으로는 설명되지 않는 소비량 부분
- 2 관심 변수에서도 똑같이 뺀다. x_{temp} 를 가격과 소득에 회귀시키고 남은 잔차 $e_{\text{temp} \cdot (\text{price, income})}$, 곧 가격과 소득으로는 설명되지 않는 온도 부분
- 3 남은 것끼리 단순회귀한다. 두 잔차를 산점도에 찍고 직선을 그으면, 그 기울기가 다중회귀의 $\hat{\beta}_{\text{temp}}$ 와 정확히 일치

$$\hat{\beta}_j = \frac{\sum e_{y \cdot \text{others}} e_{x_j \cdot \text{others}}}{\sum e_{x_j \cdot \text{others}}^2}$$

'보정'의 의미: 직접 확인

보정 전후의 기울기



Temperature slope before and after adjusting for price and income, ice cream data ($n = 30$)

- 왼쪽 기울기 0.003107 = 온도만 넣은 **단순회귀**의 계수. 오른쪽 기울기 0.003462 = 가격·소득의 몫을 양쪽에서 걷어 낸 뒤의 기울기이며, 완전모형의 $\hat{\beta}_{\text{temp}}$ 와 일치(차이 8.7×10^{-19})
- 오른쪽 직선은 반드시 원점을 지남. 두 축이 모두 잔차라 평균이 0이기 때문

회귀계수의 해석: 유의하지 않은 계수

⚠ 증거 부족과 효과 없음

💡 p-value가 큰 계수를 읽는 법

- price: $\hat{\beta}_1 = -1.03, p = 0.226$
- 부호는 예상과 일치하나, 이 자료에서 효과를 뒷받침할 증거는 부족
- “증거 부족”은 “효과가 없다”는 증명이 아님
- 가격이 움직인 범위가 좁으면 효과가 있어도 잡아내기 어려움

가격을 식에서 뺄 것인지는 Diagnosis & Variable Selection 장의 변수선택에서 판단

모형의 설명력: 수정 R^2

▲ R^2 의 단조 증가

설명변수를 추가하면 R^2 는 결코 감소하지 않는다. 설명변수 개수가 다른 모형을 R^2 만으로 비교할 수 없는 이유다.

◎ 정의



$$\bar{R}^2 = 1 - \frac{SSE/(n - p - 1)}{SST/(n - 1)}$$

기호

- $SSE = \sum_{i=1}^n e_i^2$: 잔차제곱합($e_i = y_i - \hat{y}_i$), n : 관측 수, p : 설명변수 개수
- $SST = \sum_{i=1}^n (y_i - \bar{y})^2$: 총제곱합($\bar{y}$ 는 y 의 평균)
- p 가 커지면 나누는 수 $n - p - 1$ 이 작아져 벌점이 붙음. 쓸모없는 변수를 넣으면 $\bar{R}^2$ 는 오히려 내려감

R^2 , 수정 R^2 , SSE의 관계

≒ 세 값의 이동 방향



Schematic. Only the R-squared curve is stipulated; SSE and adjusted R-squared are derived from it by their definitions with $n = 20$

- SST 가 고정이므로 $R^2 = 1 - SSE/SST$ 는 SSE를 뒤집은 값일 뿐. 왼쪽이 내려가면 파란 선은 반드시 올라감. R^2 는 변수 추가에 반대할 수 없는 지표
- 수정 R^2 는 두 제곱합을 각자의 자유도로 나누므로, 새 변수가 자유도 하나 값을 못 벌면 **내려감**. 회색 구간이 그런 변수들이 들어간 자리이고, 꺾이는 지점이 적정 모형 크기

모형의 설명력: 세 모형 비교

田 벌점을 적용한 비교

Model	R^2	Adjusted R^2
IC ~ temp	0.602	0.587
IC ~ income + temp	0.702	0.680
IC ~ price + income + temp	0.719	0.686

R^2 and adjusted R^2 for three nested models (n = 30)

💡 읽기

- R^2 는 변수를 넣을수록 0.602, 0.702, 0.719로 계속 오름. 상승 자체는 당연
- 수정 R^2 는 0.587, 0.680, 0.686. 벌점을 적용해도 상승
- 모형끼리 비교할 때 보는 값은 수정 R^2 . 두 변수 모형과 세 변수 모형의 차이는 0.006으로 작음

제곱합의 분해

◎ 총변동의 분해

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{SSR}} + \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{\text{SSE}}$$

유도

$y_i - \bar{y}$ 를 적합값이 설명한 조각과 잔차로 쪼갠 뒤 제곱하면 교차항이 하나 생김

$$\sum (y_i - \bar{y})^2 = \sum \{(\hat{y}_i - \bar{y}) + e_i\}^2 = \text{SSR} + \text{SSE} + 2 \sum (\hat{y}_i - \bar{y}) e_i$$

앞 장의 성질 $\mathbf{X}^\top \mathbf{e} = \mathbf{0}$ 에서 $\sum e_i = 0$ 이고 $\hat{\mathbf{y}}^\top \mathbf{e} = \hat{\boldsymbol{\beta}}^\top \mathbf{X}^\top \mathbf{e} = 0$ 이므로

$$\sum (\hat{y}_i - \bar{y}) e_i = \underbrace{\sum \hat{y}_i e_i}_{=0} - \bar{y} \underbrace{\sum e_i}_{=0} = 0$$

교차항이 사라져 제곱합이 그대로 둘로 나뉨. 두 조각이 **직교**하기 때문이며, 직각삼각형에서 빗변의 제곱이 두 변의 제곱의 합이 되는 것과 같은 구조

자유도의 분해

▮ 자유도의 동반 분해


제공합만 나뉘는 것이 아니라 자유도도 정확히 나뉨: $p + (n - p - 1) = n - 1$

Sums of squares: a right triangle, drawn to scale


$$SST = SSR + SSE: 0.1255 = 0.0902 + 0.0353$$

side lengths (hyp, base, height): 0.3543, 0.3004, 0.1879

$$\cos^2\theta = SSR / SST = R^2 = 0.7187$$



Degrees of freedom split the same way



Sums of squares and degrees of freedom split the same way (ice cream model, $n = 30, p = 3$)

- 왼쪽 두 변이 직각인 것이 곧 $\sum(\hat{y}_i - \bar{y})e_i = 0$. 그래서 $SST = SSR + SSE$ 는 피타고라스 정리 그 자체이며, 세 변의 길이는 각 제공합의 제공근
- 빗변과 밑변이 이루는 각 θ 에 대해 $\cos^2\theta = SSR/SST = R^2 = 0.719$. 각이 작을수록 설명력이 큼
- 총 자유도가 n 이 아니라 $n - 1$ 인 이유: $\bar{y}$ 를 구하는 데 정보 하나를 이미 씀. 잔차 자유도 $n - p - 1$ 은 앞 장의 $\text{tr}(\mathbf{I} - \mathbf{H})$ 와 같은 값이고 $30 - 3 - 1 = 26$

모형 전체의 유의성: 검정의 목적

? 개별 계수에 앞선 검정

개별 계수를 하나씩 따지기 전에 먼저 물어야 할 것: 설명변수를 모두 합쳐도 반응변수를 설명하지 못하는 것은 아닌가?

◎ 가설

$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$ (절편을 제외한 모든 회귀계수가 0)

H_1 : 적어도 하나의 β_j 는 0이 아니다

기호

- H_0 : 귀무가설(기각 대상이 되는 기본 주장)
- H_1 : 대립가설

모형 전체의 유의성: F 통계량

✍ 설명한 몫과 남은 몫

$$F = \frac{SSR/p}{SSE/(n - p - 1)}$$

기호

- $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$: 회귀제곱합. 모형이 설명한 부분
- $SSE = \sum_{i=1}^n e_i^2$: 잔차제곱합. 설명하지 못한 부분
- 나누는 수 p 와 $n - p - 1$: **자유도**. 자료가 담은 정보 가운데 그 몫에 배정된 개수
- 관측 n 개에서 계수 $p + 1$ 개를 추정하는 데 쓰고 남은 것이 잔차의 자유도. 이 자료에서는 $30 - 3 - 1 = 26$

- H_0 가 참이면 분자와 분모가 모두 σ^2 의 불편추정량이 되어 F 는 1 근처. 설명한 부분이 커질수록 F 가 커져 H_0 를 기각
- H_0 아래에서 $F \sim F(p, n - p - 1)$. 아이스크림 완전모형은 $F(3, 26)$
- 점검 순서: 모형 전체(F-검정) 통과 $\rightarrow$ 개별 계수(t-검정)

✍ R^2 로 다시 쓰면: 분자와 분모를 SST 로 나누면 F 가 결정계수만의 함수가 됨

$$F = \frac{R^2/p}{(1 - R^2)/(n - p - 1)}$$

R^2 가 같아도 p 가 크면 F 는 작아짐. 설명력과 모형의 크기를 함께 보는 통계량

회귀분산분석표

田 아이스크림 완전모형

Source	Df	Sum Sq	Mean Sq	F	p -value
Regression	3	0.0902	0.0301	22.1	2.5×10^{-7}
Residual	26	0.0353	0.00136	n.a.	n.a.
Total	29	0.126	n.a.	n.a.	n.a.

Analysis of variance for the ice cream full model ($n = 30$, $p = 3$)

田 표 읽는 법

- **Mean Sq** = Sum Sq를 Df로 나눈 값, 곧 **자유도 하나당 변동**. 크기가 다른 두 제곱합을 비교할 수 있게 만드는 척도 조정
- $F = \text{MSR}/\text{MSE} = 0.0301/0.00136 = 22.1$. $F(3, 26)$ 의 5% 임계값 2.98을 크게 넘으므로 H_0 기각
- $\text{MSE} = 0.00136$ 이 오차분산 σ^2 의 추정값이고, 그 제곱근 $\hat{\sigma} = 0.0369$ 가 완전모형의 잔차 표준오차
- 세로 방향으로 제곱합과 자유도가 각각 더해짐: $0.0902 + 0.0353 = 0.126$, $3 + 26 = 29$

✔️ 단순회귀에서는 t검정과 같은 결론: 설명변수가 하나면 $F(1, n - 2) = \{t(n - 2)\}^2$ 이므로 두 검정이 완전히 일치. 온도만 넣은 단순회귀에서 $t = 6.50$, 그 제곱 $6.50^2 = 42.3$ 이 그대로 F 값

회귀계수 일부에 대한 검정

◎ 여러 변수의 동시 제거

완전모형(FM)에서 계수 k 개를 0으로 놓은 축소모형(RM)을 세우고, 두 모형의 잔차제곱합 차이를 완전모형의 오차분산으로 잰다.

$$F = \frac{\{SSE(RM) - SSE(FM)\}/k}{SSE(FM)/(n - p - 1)} \sim F(k, n - p - 1) \quad (H_0 \text{ 아래에서})$$

기호

- k : 0으로 놓은 계수의 개수
- $SSE(RM) \geq SSE(FM)$ 은 항상 성립하므로 분자는 음수가 될 수 없음
- 분자는 **뺀 변수들이 실제로 설명한 몫**을 뜻함

Quantity	Value
SSE (RM: temp only)	0.050009
SSE (FM: price + income + temp)	0.035313
차이 / $k = 2$	0.007348
$\hat{\sigma}^2 = SSE(FM)/26$	0.0013582
F	5.410
p -value	0.0109

Test of H_0 : price and income coefficients are both zero (ice cream data, $n = 30$)

회귀계수의 표집분포: 추정량은 확률변수

💡 참값과 오차의 몫

한 번의 자료에서 계산한 $\hat{\beta}$ 는 미지 계수 β 를 추정한 표본 결과이며, 자료가 바뀌면 값이 달라지는 확률변수이다. 자료를 다시 모아 같은 계산을 반복하면 추정값이 조금씩 달라지며, 그 값들이 이루는 분포가 표집분포 (sampling distribution)

- 1 정의에서 출발한다. 관측한 y 만으로 계산하는 식이며, 이 단계에는 미지의 참값이 아직 등장하지 않음

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top y$$

- 2 y 를 모형으로 바꿔 쓴다. 참 모형 $y = \mathbf{X}\beta + \varepsilon$ 를 대입. 관측값 안에 참값이 만든 부분과 오차가 함께 들어 있음을 드러내는 단계

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \varepsilon)$$

- 3 분배한 뒤 상쇄시킨다. 두 항으로 가르면 앞 항에서 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 와 $\mathbf{X}^\top \mathbf{X}$ 가 만나 항등행렬이 되므로 β 만 남음

$$\hat{\beta} = \underbrace{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}}_{= \mathbf{I}} \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon$$

$$\hat{\beta} = \underbrace{\beta}_{\text{고정된 참값}} + \underbrace{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon}_{\text{자료마다 달라지는 몫}}$$

회귀계수의 표집분포: 불편성

◎ 참값과의 일치

≡ 전제 조건

- $\mathbf{X}$ 를 고정된 것으로 두고 조건부로 생각
- $E(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \mathbf{0}$: 오차의 평균이 0
- $\text{Var}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{I}$: 오차의 분산이 모두 σ^2 로 같고 서로 무관

$E(\hat{\beta} \mid \mathbf{X}) = \beta$: 최소제곱 추정량의 기댓값은 참값과 일치한다(불편추정량).

Symbol	Nature	Meaning
β	Fixed unknown constant	모집단의 참 회귀계수
$\hat{\beta}$	Random variable	표본이 바뀌면 달라지는 추정량

Population coefficient versus its estimator

회귀계수의 분산: 분산-공분산 행렬

◎ 오차분산과 설계행렬

앞의 전제 조건 아래에서 최소제곱 추정량의 분산-공분산 행렬은 오차분산과 설계행렬만으로 결정된다.

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

기호

- σ^2 : 오차분산
- $(\mathbf{X}^\top \mathbf{X})^{-1}$: 설계정보 행렬의 역행렬
- 대각 원소가 각 계수의 분산 $\text{Var}(\hat{\beta}_j \mid \mathbf{X})$, 비대각 원소가 계수 사이의 공분산

회귀계수의 분산: 불확도의 결정 요인

💡 잡음의 크기와 설계의 정보량

오차의 크기

- 잡음이 클수록 σ^2 가 커지고 계수의 불확도가 증가
- 같은 설계에서 잡음이 두 배면 분산도 두 배

설계의 정보량

- 설명변수의 변동이 크고 서로 겹치지 않을수록 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 가 작아져 불확도가 감소
- 설명변수끼리 정보가 겹치면 역행렬이 커지고 표준오차도 커짐

실제 계산

- 오차분산은 알 수 없으므로 잔차로 추정: $\hat{\sigma}^2 = SSE/(n - p - 1)$
- j 번째 계수의 표준오차: $se(\hat{\beta}_j) = \sqrt{\widehat{\text{Var}}(\hat{\beta}_j)}$
- SSE 는 잔차제곱합, n 은 관측 수, p 는 설명변수 개수, $n - p - 1$ 은 잔차의 자유도

분산식의 유도: 세 단계

✍ 전달 → 선형변환 → 상쇄

- 1 추정량을 오차의 함수로 바꾼다. $\hat{\beta}$ 의 정의에 모형 $\mathbf{y} = \mathbf{X}\beta + \epsilon$ 를 대입하면 앞의 두 항이 상쇄되어 β 만 남음. 흔들리는 부분은 오차가 통로 $\mathbf{A}$ 를 지나온 것뿐

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \epsilon) = \beta + \underbrace{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{\mathbf{A}} \epsilon$$

$E(\epsilon) = \mathbf{0}$ 이므로 이 한 줄이 불편성 $E(\hat{\beta}) = \beta$ 도 함께 증명

- 2 선형변환의 분산 성질을 쓴다. 상수행렬 $\mathbf{A}$ 와 확률벡터 $\mathbf{z}$ 에 대해 $\text{Var}(\mathbf{A}\mathbf{z}) = \mathbf{A} \text{Var}(\mathbf{z}) \mathbf{A}^\top$. $\mathbf{X}$ 를 고정으로 보므로 $\mathbf{A}$ 가 상수행렬이 됨

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = \text{Var}(\mathbf{A}\epsilon) = \mathbf{A} \text{Var}(\epsilon) \mathbf{A}^\top$$

- 3 대입하면 저절로 상쇄된다. $\text{Var}(\epsilon) = \sigma^2 \mathbf{I}$ 를 넣고, $(\mathbf{X}^\top \mathbf{X})^{-1}$ 가 대칭이라 $\mathbf{A}^\top = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}$ 임을 쓰면 가운데에 $\mathbf{X}^\top \mathbf{X}$ 가 생겨 역행렬 하나와 사라짐

$$\mathbf{A}(\sigma^2 \mathbf{I}) \mathbf{A}^\top = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \underbrace{\mathbf{X}^\top \mathbf{X}}_{\text{상쇄}} (\mathbf{X}^\top \mathbf{X})^{-1}$$

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

분산식의 유도: 결과 읽기

💡 단계별로 쓰인 가정

Step	사용한 가정	깨지면 생기는 일
1. 오차의 함수로	모형이 옳음 ($E(\boldsymbol{\epsilon}) = \mathbf{0}$)	추정량이 편향 됨. 분산 이전의 문제
2. 선형변환	$\mathbf{X}$ 는 고정 (확률변수 아님)	조건부가 아닌 분산은 더 복잡해짐
3. $\text{Var}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}$	등분산(대각원소가 모두 같음) + 독립(대각 밖이 0)	계수 추정값은 그대로여도 표준오차가 틀림

Where each assumption enters the variance derivation

- 결과가 $\sigma^2 \times (\mathbf{X}^\top \mathbf{X})^{-1}$ 로 **깔끔히 분리**됨. 앞은 측정의 잡음, 뒤는 설계가 담은 정보. 실험을 설계할 때 손댈 수 있는 쪽은 뒤쪽
- j 번째 계수의 표준오차 $\text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{c_{jj}}$, 계수 사이 공분산은 비대각원소 $\sigma^2 c_{jk}$. 결과표의 표준오차와 신뢰구간이 모두 이 한 식에서 나옴

Gauss-Markov 정리: 가정

≡ 정리가 성립할 조건

≡ 정리가 성립하기 위한 조건

- 선형모형: $y = \mathbf{X}\beta + \varepsilon$
- 오차 평균 0: $E(\varepsilon \mid \mathbf{X}) = \mathbf{0}$
- 등분산: 모든 i 에 대해 $\text{Var}(\varepsilon_i \mid \mathbf{X}) = \sigma^2$
- 무상관: $i \neq j$ 에 대해 $\text{Cov}(\varepsilon_i, \varepsilon_j \mid \mathbf{X}) = 0$
- full rank: $\mathbf{X}$ 의 열들이 선형독립, 즉 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 가 존재

등분산과 무상관을 함께 쓰면 $\text{Var}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}$. 정규성은 이 목록에 없음

Gauss-Markov 정리: BLUE

◎ 최소분산 선형 불편추정량

Theorem (Gauss-Markov)

앞의 가정이 성립하면, 최소제곱 추정량 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 는 $\mathbf{y}$ 의 선형함수이면서 불편인 모든 추정량 가운데 분산이 가장 작다.

💡 BLUE 네 글자의 뜻

- **B**est: 같은 부류의 추정량 중 분산이 가장 작음
- **L**inear: 관측값 $\mathbf{y}$ 의 선형함수
- **U**nbiased: $E(\hat{\beta}) = \beta$
- **E**stimator: 추정량

Gauss-Markov 정리: 결론별 필요 가정

⚠ 정규성의 역할

Conclusion	Required assumptions
$\hat{\beta}$ is BLUE	평균 0, 등분산, 무상관, full rank
Exact t , F tests and interval estimation	위 조건에 오차의 정규성 을 추가

Assumptions required for each inferential conclusion (Kutner et al., 2005; Faraway, 2015)

- 정규분포는 평균을 중심으로 좌우대칭인 종 모양 분포. 오차가 이 분포를 따른다는 가정이 정규성
- 정규성은 BLUE 자체에 필수가 아니며, 정확한 t , F 검정과 구간 추론에 추가로 쓰임
- 등분산이 깨지면 최소제곱은 더 이상 BLUE가 아님: Weighted Regression 장으로 이어지는 지점

표준오차에서 신뢰구간으로

◎ 자유도 $n - p - 1$ 의 t 분포

정규오차 가정 아래에서 표준화된 계수 추정량은 자유도 $n - p - 1$ 인 t 분포를 따른다.

$$\frac{\hat{\beta}_j - \beta_j}{\text{se}(\hat{\beta}_j)} \sim t_{n-p-1} \quad \Longrightarrow \quad \hat{\beta}_j \pm t_{\alpha/2, n-p-1} \text{se}(\hat{\beta}_j)$$

- t 분포는 정규분포처럼 좌우대칭인 종 모양이나 꼬리가 더 두꺼움. 자유도가 커질수록 정규분포에 근접
- $\text{se}(\hat{\beta}_j)$: 표준오차, $t_{\alpha/2, n-p-1}$: 자유도 $n - p - 1$ 인 t 분포의 임계값
- 오른쪽 식이 $100(1 - \alpha)\%$ 신뢰구간

회귀계수에 대한 검정과 신뢰구간

◎ $(\mathbf{X}^\top \mathbf{X})^{-1}$ 의 대각원소

$$\text{se}(\hat{\beta}_j) = \hat{\sigma} \sqrt{c_{jj}}, \quad t = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)} \sim t_{n-p-1}, \quad \hat{\beta}_j \pm t_{\alpha/2, n-p-1} \hat{\sigma} \sqrt{c_{jj}}$$

기호

- c_{jj} : $(\mathbf{X}^\top \mathbf{X})^{-1}$ 의 j 번째 대각원소
- $\hat{\sigma}^2 = SSE/(n - p - 1) = 0.0013582, t_{0.025, 26} = 2.0555$

Term	$\hat{\beta}_j$	c_{jj}	se	t	p -value	95% CI
(Intercept)	0.19270	53.3248	0.26912	0.72	0.480	(-0.360, 0.746)
price	-1.02906	507.6785	0.83037	-1.24	0.226	(-2.736, 0.678)
income	0.00331	0.001011	0.00117	2.83	0.0089	(0.00090, 0.00572)
temp	0.00346	0.000146	0.00045	7.77	< 0.001	(0.00255, 0.00438)

Coefficient tests and 95% confidence intervals for the ice cream full model ($n = 30, p = 3$)

신뢰구간 해석의 주의

⚠ 확률이 붙는 대상

💡 95% 신뢰구간을 읽는 법

- 옳은 해석: 같은 절차를 반복해 만든 구간의 약 95%가 진짜 β_j 를 포함하도록 설계됨
- 틀린 해석: “이번에 계산한 구간 안에 β_j 가 있을 확률이 95%
- 확률은 계수가 아니라 구간을 만드는 절차에 붙음

✂ 실무 적용

보고 항목: 추정값, 표준오차, 95% 신뢰구간, 분석에 쓴 가정과 표본 범위. 구간은 $\hat{\beta}_j \pm t_{\alpha/2, n-p-1} \text{SE}(\hat{\beta}_j)$ 로 계산

반응평균의 신뢰구간과 예측구간: 정의

◎ 평균과 개별 관측

새 설명변수 조합 $\mathbf{x}_0 = (1, x_{01}, \dots, x_{0p})^\top$ 에서 적합값은 $\hat{y}_0 = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}}$ 로 같으나, 목표가 조건부 평균인지 새 관측 하나인지에 따라 구간의 폭이 달라진다.

$$\text{신뢰구간 : } \hat{y}_0 \pm t_{\alpha/2, n-p-1} \hat{\sigma} \sqrt{\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}$$

$$\text{예측구간 : } \hat{y}_0 \pm t_{\alpha/2, n-p-1} \hat{\sigma} \sqrt{1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}$$

- 근호 안의 1 이 두 구간을 가르는 전부. 새 관측에는 개별 오차 ε_0 이 추가로 실리기 때문. 따라서 **예측구간이 항상 더 넓은**
- $\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$ 는 $\mathbf{x}_0$ 가 자료의 중심에서 멀수록 커짐. 자료 범위 밖으로 외삽하면 두 구간 모두 급격히 넓어짐

반응평균의 신뢰구간과 예측구간: 수치

田 아이스크림 자료, 새 조건

$\mathbf{x}_0 = (1, 0.280, 85, 65)^\top$ 에서

$$\hat{y}_0 = 0.19270 - 1.02906 \times 0.280 + 0.00331 \times 85 + 0.00346 \times 65 = 0.41107$$

$$\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0 = 0.089095, \quad \hat{\sigma} = 0.036853, \quad t_{0.025, 26} = 2.0555$$

Interval	Half-width	Result	Width
신뢰구간 (평균반응)	$t\hat{\sigma}\sqrt{0.089095} = 0.02261$	(0.38846, 0.43368)	0.0452
예측구간 (새 관측)	$t\hat{\sigma}\sqrt{1.089095} = 0.07906$	(0.33201, 0.49013)	0.1581

Two intervals at price = 0.280, income = 85, temp = 65 (ice cream full model, n = 30)

예측구간의 폭이 신뢰구간의 **3.50배**. 근호 안의 1 이 0.0891 을 압도하기 때문이며, 검교정에서 **다음 측정값 하나를 보증**해야 한다면 반드시 예측구간을 씀

이 장의 정리

≡ 정리

- 원인이 여럿이면 조건도 여럿으로: $E(Y \mid x_1, \dots, x_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$
- 최소제곱 해는 변수 개수와 무관하게 정규방정식 $\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$ 에서 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 하나로 정리됨
- 모자행렬 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 는 $\mathbf{y}$ 를 설계행렬의 열공간에 수직으로 내리는 사영
- 계수는 “다른 변수를 고정했을 때”라는 조건절과 함께 읽을 것
- 계수의 흔들림은 $\text{Var}(\hat{\boldsymbol{\beta}} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 이 결정. 등분산이 깨지지 않는 한 최소제곱은 BLUE

🌀 다음 장: Diagnosis & Variable Selection: 이렇게 세운 모델을 그대로 믿어도 되는가. 잔차로 가정을 점검하고 변수를 고른다

참고문헌

이 장에서 인용한 문헌

- Hoaglin, D. C., & Welsch, R. E. (1978). The hat matrix in regression and ANOVA. *The American Statistician*, 32(1), 17-22.
- Kutner, M. H., et al. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill. (계수 해석, 추론에 필요한 가정)
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press. (결론별 필요 가정)

교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.