

Regression Analysis

5. Diagnosis & Variable Selection | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division
Korea Institute of Oriental Medicine


2026-09-01

Diagnosis & Variable Selection

요약통계량이 같은 네 자료

그림으로 보기

앞 장에서 여기까지: full model 적합과 계수 해석까지 마침. 이 장의 질문: 이 모형을 믿어도 되는가, 변수를 다 남겨야 하는가



Anscombe's quartet: four data sets with the same fitted line

서로 다른 네 자료에 최소제곱 직선을 적합하면 네 경우 모두 같은 직선이 나온다.

$$\hat{y}_i = 3.00 + 0.500 x_i$$

기호

- $\hat{y}_i$: i 번째 관측의 적합값, x_i : 설명변수 값
- 3.00: 절편 추정값 $\hat{\beta}_0$, 0.500: 기울기 추정값 $\hat{\beta}_1$

- 요약 숫자만으로는 네 자료를 구분할 수 없음
- 그림에서는 네 자료의 구조가 서로 전혀 다름 (Anscombe, 1973)
- 회귀분석은 계수 계산과 그림 확인을 함께 수행함

회귀모형의 네 가지 가정

◎ 정의

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

기호

- y_i : 반응변수, x_{ij} : i 번째 관측의 j 번째 설명변수
- $\beta_0, \dots, \beta_p$: 회귀계수, ε_i : 오차, σ^2 : 오차의 분산
- $N(0, \sigma^2)$: 0을 중심으로 좌우대칭인 종 모양 분포
- iid : 오차들이 서로 영향을 주지 않으며(독립) 모두 같은 분포를 따름

≡ 네 가지 가정

- 선형성: x 와 y 의 관계가 직선으로 표현됨
- 독립성: 오차 ε_i 끼리 서로 독립
- 정규성: 오차가 정규분포 $N(0, \sigma^2)$ 을 따름
- 등분산성: 오차의 분산이 어디서나 같은 σ^2

📌 Remark

네 가정 중 하나라도 크게 위반되면 회귀계수의 표준오차(추정값이 자료가 바뀔 때마다 얼마나 흔들리는지를 나타내는 값), 유의성 검정, 신뢰구간이 모두 함께 흔들림 (Kutner et al., 2005)

잔차: 모형이 설명하지 못한 나머지

◎ 정의

$$e_i = y_i - \hat{y}_i, \quad \mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H}) \mathbf{y}$$

- e_i : 잔차, y_i : 관측값, $\hat{y}_i$: 적합값, $\mathbf{I}$: 단위행렬
- $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$: 앞 장의 모자행렬. 적합값이 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 이므로, 잔차는 $\mathbf{y}$ 에서 $\mathbf{H}$ 가 설명한 부분을 뺀 나머지

잔차의 역할

- 오차 ε_i 는 관측할 수 없으나 잔차 e_i 는 자료에서 직접 계산됨
- 가정이 모두 성립하면 잔차는 0 주위에 **패턴 없이** 흩어짐
- 요약 숫자가 양호해도 잔차 그림에서 모형의 문제가 드러나기도 함

잔차의 대수적 성질

- $\mathbf{M} = \mathbf{I} - \mathbf{H}$ 도 대칭이고 멱등. $\mathbf{M}$: 잔차를 만들어 내는 행렬

$$\mathbf{X}^\top \mathbf{e} = \mathbf{X}^\top (\mathbf{I} - \mathbf{H}) \mathbf{y} = (\mathbf{X}^\top - \mathbf{X}^\top) \mathbf{y} = \mathbf{0} \implies \sum_{i=1}^n e_i = 0$$


$$E(\mathbf{e}) = \mathbf{0}, \quad \text{Var}(\mathbf{e}) = \sigma^2 (\mathbf{I} - \mathbf{H}) \implies \text{Var}(e_i) = \sigma^2 (1 - h_{ii})$$

$$\text{tr}(\mathbf{I} - \mathbf{H}) = n - (p + 1) = 30 - 4 = 26 = \text{잔차의 자유도}$$

$\text{Var}(e_i)$ 가 관측마다 다르므로, 잔차를 그대로 비교하지 않고 크기를 맞춘 **표준화잔차** $r_i = e_i / (\hat{\sigma} \sqrt{1 - h_{ii}})$ 를 사용

진단 그림 4종 읽는 법

ㄴ 그림으로 보기



💡 읽는 법

- **좌상 Residuals vs Fitted:** 곡선 패턴이 보이면 선형성 위반 신호
- **우상 Normal Q-Q:** 잔차를 크기순으로 늘어놓고 정규분포에서 기대되는 값과 짝지은 그림. 점들이 대각선에서 크게 벗어나면 정규성 의심
- **좌하 Scale-Location:** 오른쪽으로 갈수록 깔때기처럼 퍼지면 등분산성 위반
- **우하 Residuals vs Leverage:** 오른쪽 구석의 외딴 점은 영향점 후보

Residual diagnostics for the full model $IC \sim price + income + temp$

레버리지 h_{ii}

◎ 정의

레버리지 h_{ii} 는 모자행렬 $\mathbf{H}$ 의 i 번째 대각원소이며, i 번째 관측이 설명변수 공간에서 얼마나 바깥에 놓여 있는지를 나타낸다.

$$\sum_{i=1}^n h_{ii} = \text{tr}(\mathbf{H}) = p + 1, \quad \bar{h} = \frac{p + 1}{n}$$

기호

- $\text{tr}(\mathbf{H})$: 대각원소의 합, n : 관측 수, p : 설명변수 개수
- $p + 1$: 절편을 포함한 회귀계수의 개수
- 레버리지의 평균이 $(p + 1)/n$ 으로 고정되므로, 이 값의 2배를 넘는 관측을 주목 대상으로 삼는 관례 (Kutner et al., 2005)

田 결과: full model

Quantity	Value
$\text{tr}(\mathbf{H}) = p + 1$	4
Average leverage $(p + 1)/n$	0.133
Rule of thumb $2(p + 1)/n$	0.267
Largest h_{ii} (observation 9)	0.278

Leverage summary for the full model, n = 30

스튜던트화 잔차

◎ 정의

잔차의 분산이 관측마다 다르므로 그대로 비교할 수 없다. 각자의 표준편차로 나눈 값이 스튜던트화 잔차다.

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii}), \quad r_i = \frac{e_i}{\hat{\sigma}\sqrt{1 - h_{ii}}}$$

기호

- e_i : i 번째 잔차, h_{ii} : 레버리지, $\hat{\sigma}$: 잔차 표준오차
- r_i : 스튜던트화 잔차. $E(r_i) = 0$ 이지만 $\text{Var}(r_i)$ 가 정확히 1은 아님
- 같은 값을 **표준화 잔차**라 부르는 문헌도 많음. 이름이 둘인 것이지 다른 값이 아님

💡 읽는 법

- $-2 \leq r_i \leq 2$ 안에 들고, 무늬가 없고, 퍼짐이 고르면 오차 가정을 만족한다고 봄
- 레버리지가 큰 관측일수록 $1 - h_{ii}$ 가 작아, 같은 e_i 라도 r_i 가 커짐. 시소 끝에 앉은 점의 이탈을 놓치지 않으려는 보정
- 정확히 정규분포를 따르지는 않으나 실무에서는 정규분포로 보고 판단

외적 스튜던트화 잔차

⚠ $\hat{\sigma}$ 부풀림 문제

i 번째 관측을 빼고 추정한 오차분산 $\hat{\sigma}_{(i)}^2$ 로 나눈 값을 외적 스튜던트화 잔차(스튜던트화 제외 잔차)라 한다.

$$t_i = \frac{e_i}{\hat{\sigma}_{(i)} \sqrt{1 - h_{ii}}}$$

기호

- $\hat{\sigma}_{(i)}^2$: i 번째 관측을 제외한 $n - 1$ 개로 추정한 오차분산. 자유도는 $n - p - 2$
- t_i : 외적 스튜던트화 잔차. 앞 슬라이드의 r_i 와 분모만 다름

💡 왜 굳이 빼고 재는가

- $\hat{\sigma}$ 는 모든 관측으로 계산되므로 이상점 자신이 $\hat{\sigma}$ 를 부풀림
- 부풀어난 분모로 나누면 자기 잔차가 작아 보임. 이상점이 스스로를 감추는 셈
- 자기를 빼고 만든 자로 재면 이 자기지시가 사라짐. 그래서 이상점 검정은 r_i 가 아니라 t_i 로 함

이상치, 레버리지, 영향점: 정의

◎ 세 용어의 구별

이상치(outlier): y 방향으로 동떨어진 점, 즉 잔차 e_i 가 큰 관측

레버리지(leverage): x 방향으로 얼마나 끝자리에 있는지를 나타내는 값 h_{ii}


영향점(influential point): 그 한 점을 제외하면 회귀직선이 크게 움직이는 점

💡 핵심

- y 방향의 이탈(큰 잔차)과 x 방향의 이탈(큰 레버리지)이 **결합될 때** 회귀직선이 실제로 움직임
- 잔차만 크거나 레버리지만 큰 점은 직선을 크게 흔들지 못하는 경우가 있음
- 따라서 두 값은 따로 보지 않고 함께 평가함

이상치, 레버리지, 영향점: 그림 비교

≒ 점 하나를 더한 세 경우



The same 20 points refitted three times, each with one extra point added (red). Dashed line: fit without it. Solid line: fit with it.

추가한 점	x 방향 이탈 (레버리지)	y 방향 이탈 (잔차)	직선이 움직이는가
(a) 이상치	작음	큼	거의 그대로
(b) 레버리지가 큰 점	큼	작음	거의 그대로
(c) 영향점	큼	큼	크게 꺾임

What moves the fitted line: not either deviation alone, but the two together

- (b)와 (c)의 붉은 점은 x 방향으로 **같은 자리**. 차이를 만든 것은 직선에서 벗어난 정도
- 잔차와 레버리지 중 하나만 커서는 직선이 흔들리지 않음. **둘이 겹칠 때만 영향점**

이상치, 레버리지, 영향점: Cook 거리

✍ 잔차와 레버리지의 결합

◎ 정의와 기호

$$D_i = \frac{r_i^2}{p+1} \cdot \frac{h_{ii}}{1-h_{ii}}$$

기호

- r_i : i 번째 표준화잔차. 잔차 e_i 를 그 표준오차로 나누어 서로 견줄 수 있게 만든 값
- h_{ii} : 레버리지, $p+1$: 절편을 포함한 회귀계수의 개수
- 두 요소가 곱해지므로 잔차와 레버리지가 함께 클 때 D_i 가 특히 커짐 (Cook, 1977)

田 결과: full model

Diagnostic statistic	Largest value	Observation
Standardized residual (absolute)	2.46	30
Leverage h_{ii}	0.278	9
Cook's distance D_i	0.475	30

Largest diagnostic values in the full model, $n = 30$

Cook 거리 최댓값 0.475는 흔히 쓰는 기준값 1보다 작음: 한 관측이 결과를 좌우한다고 볼 근거는 없음

영향점 측도: DFFITS

◎ 정의

i 번째 관측을 빼면 그 관측의 적합값이 얼마나 움직이는가를 표준화한 값

$$\text{DFFITS}_i = \frac{\hat{y}_i - \hat{y}_{(i)}}{\hat{\sigma}_{(i)} \sqrt{h_{ii}}} = t_i \sqrt{\frac{h_{ii}}{1 - h_{ii}}}$$

기호

- $\hat{y}_{(i)}$: i 번째를 빼고 적합한 모형이 주는 i 번째 적합값
- t_i : 외적 스튜던트화 잔차, h_{ii} : 레버리지

💡 Cook 거리와의 관계

- 두 측도 모두 잔차 $\times$ 레버리지 구조. 앞에서 본 두 요소가 함께 커야 값이 커진다는 성질이 같음
- 보는 대상이 다름: Cook 거리는 적합값 n 개 전체가 움직인 양, DFFITS는 그 관측 하나의 적합값이 움직인 양
- 판정 기준: $|\text{DFFITS}_i| > 2\sqrt{(p+1)/n}$
- h_{ii} 가 1에 가까우면 $\sqrt{h_{ii}/(1 - h_{ii})}$ 가 발산. 레버리지가 극단이면 작은 잔차로도 값이 커짐

이상점 검정

✍ 제외 후 예측

- 1 그 관측을 빼고 적합한다. i 번째를 제외한 $n - 1$ 개로 $\hat{\beta}_{(i)}$ 와 $\hat{\sigma}_{(i)}^2$ 을 구함. 자유도는 $n - p - 2$
- 2 뺀 관측을 예측한다. $\hat{y}_{(i)} = \mathbf{x}_i^\top \hat{\beta}_{(i)}$. 적합에 쓰이지 않았으므로 y_i 와 서로 독립이며, 이 독립성이 다음 단계의 t 분포를 성립시킴
- 3 예측오차를 표준화한다. y_i 가 이상점이 아니라면 $E(y_i - \hat{y}_{(i)}) = 0$ 이므로

$$t_i = \frac{y_i - \hat{y}_{(i)}}{\hat{\sigma}_{(i)} \sqrt{1 + \mathbf{x}_i^\top (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{x}_i}} = \frac{e_i}{\hat{\sigma}_{(i)} \sqrt{1 - h_{ii}}} \sim t(n - p - 2)$$

$|t_i| \geq t_{\alpha/2, n-p-2}$ 이면 이상점으로 판정. 단, n 개를 모두 검정하므로 유의수준을 α/n 으로 낮추는 **Bonferroni 보정**을 함께 씀

이상점: 유의점과 대처

⚠ 함정과 절차

⚠ 검정을 그대로 믿으면 안 되는 네 경우

- **이상점끼리 서로를 가림:** 두 개 이상이 이웃해 있으면 서로의 효과를 상쇄해 어느 쪽도 잡히지 않을 수 있음
- **모형이 바뀌면 이상점도 바뀜:** 어떤 모형에서의 이상점이 변수변환 뒤에는 이상점이 아닐 수 있음. **모형을 바꿀 때마다 이상점을 다시 조사**
- **정규분포가 아닐 때:** 오차 분포의 꼬리가 두꺼우면 큰 잔차가 나오는 것이 자연스러움. 이상점이 아니라 분포 특성일 수 있음
- **이상점이 무리를 이룰 때:** 큰 자료에서 한두 개는 문제가 되지 않지만, 그룹을 형성하면 모형 설정 자체를 의심해야 함

✂ 이 순서로 확인

1. **데이터 입력 오류를 검사한다.** 단위, 소수점, 자릿수 밀림처럼 기록 단계의 잘못인지 원자료와 대조
2. **그 관측이 나온 상황을 알아본다.** 그날의 장비 상태, 시료, 작업 조건처럼 표에 적히지 않은 사정을 확인
3. **제거하고 분석하되 반드시 밝힌다.** 어떤 관측을 왜 뺐는지를 결과에 함께 적음. **새 모형을 적합할 때는 뺐던 관측을 되돌려 넣고 다시 판단**
4. **실제로 가능한 값이면 제거하지 않는다.** 이상점을 포함한 채 건딜 수 있는 모형, 예를 들어 로버스트 회귀를 찾음

⚠ **주의:** 원인을 모르는 채 관측을 삭제하는 일은 금지. 결론이 한 점에 좌우되면 포함한 분석과 제외한 분석을 둘 다 보고

다중공선성과 VIF: 정의

◎ 설명변수 간 정보 중복

설명변수끼리 정보가 겹치는 현상을 다중공선성이라 하며, 이때 회귀계수 추정값 $\hat{\beta}_j$ 가 불안정해진다.

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

기호

- R_j^2 : j 번째 설명변수를 나머지 설명변수들로 회귀했을 때의 결정계수, 곧 그 변수의 변동 중 나머지 변수들이 설명한 비율
- 겹침이 없으면 $R_j^2 = 0$ 이라 $\text{VIF}_j = 1$
- 겹침이 심해 R_j^2 가 1에 가까워질수록 값이 급격히 증가

판정 기준

- 관례적으로 VIF_j 가 10, 문헌에 따라 5를 넘으면 심각한 다중공선성을 의심 (Kutner et al., 2005)

다중공선성과 VIF: 아이스크림 자료

full model의 VIF

VIF 표

Variable	VIF
price	1.03
income	1.14
temp	1.14

VIF for the full model IC ~ price + income + temp

세 변수 모두 1에 가까움: 이 자료에서는 다중공선성 문제 없음

계산 절차

설명변수 하나를 나머지 설명변수로 회귀했을 때의 결정계수 R_j^2 로 계산

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

Regression	R_j^2	$\text{VIF}_j = 1/(1 - R_j^2)$
price on income, temp	0.0331	$1/0.967 = 1.03$
income on price, temp	0.126	$1/0.874 = 1.14$
temp on price, income	0.125	$1/0.875 = 1.14$

Derivation of the VIF values for the full model (n = 30)

$R_j^2 = 0$ 이면 $\text{VIF}_j = 1$ 로 최솟값. $R_j^2 \rightarrow 1$ 이면 분모가 0에 가까워져 $\text{VIF}_j \rightarrow \infty$

진단 후 처방

✂ 실무 적용

Diagnostic signal	Suspected violation	Remedy
잔차 그림의 곡선 패턴	선형성	변수 변환(log, 제곱근) 또는 곡선 항 추가
잔차 퍼짐의 깔때기 모양	등분산성	가중회귀로 보정: Weighted Regression 장에서 다룸
Q-Q 그림에서 대각선 이탈	정규성	반응변수 변환 검토
유난히 큰 Cook 거리	특정 관측의 과도한 영향	원자료 확인 후 민감도 분석


Diagnostic signals and corresponding remedies

🔗 관련 슬라이드

- 이상 관측의 처리 절차는 앞의 **이상점: 유의점과 대처** 슬라이드에 정리
- 표의 **Remedy** 옆에 있는 변수 변환은 이어지는 네 슬라이드에서 하나씩 펼침
- 가중회귀는 Weighted Regression 장이 통째로 담당

잔차그림과 가정 위반

≒ 여섯 가지 유형



Six residual shapes and what each one accuses the model of. Panels (a) to (d) plot residuals against the fitted value; (e) and (f) are lag plots, each residual against the one before it.

- 세로축은 **스튜던트화 잔차**. (a)~(d)의 가로축은 적합값 $\hat{y}_i$ 이고, 가정이 성립하면 (a)처럼 0을 중심으로 무늬 없이 흩어져야 함
- (e)~(f)는 **시차산점도**. 점 하나가 이웃한 잔차 한 쌍 (e_{t-1}, e_t) 이고, 구름이 기운 방향이 **잔차 간 상관의 부호**. 기울기는 1차 자기상관계수 r_1 (가중회귀 장의 Durbin-Watson 통계량이 요약하는 값). 자료가 모인 **순서**가 있어야 그릴 수 있음
- 자기상관은 잔차 대 적합값 그림에서 **볼 수 없음**. 최소제곱에서 $\mathbf{e}^\top \hat{\mathbf{y}} = \mathbf{y}^\top (\mathbf{I} - \mathbf{H})\mathbf{H}\mathbf{y} = 0$ 이므로 $\text{cor}(e, \hat{y}) = 0$ 이 자료와 무관하게 항상 성립
- 설명변수마다 같은 그림을 따로 그려 보면 **어느 변수가 원인인지** 좁힐 수 있음

보정 1: Box-Cox 변환

◎ 거듭제곱의 선택

Box-Cox 변환: 반응변수를 아래 형태로 바꾸어, 변환 뒤의 오차가 정규분포에 가까워지도록 하는 λ 를 찾는다.

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln y, & \lambda = 0 \end{cases}$$

기호

- λ : 찾아야 할 하나의 상수. $\lambda = 1$ 이면 변환하지 않은 것과 같고, $\lambda = 0.5$ 는 제곱근, $\lambda = 0$ 은 로그
- $y > 0$ 이어야 함. 0이나 음수가 있으면 상수를 더한 뒤 적용


✍ λ 를 정하는 법

- 각 λ 마다 변환 후 모형의 **로그가능도** $L(\lambda)$ 를 계산해 가장 큰 값을 주는 $\hat{\lambda}$ 를 택함
- 95% 신뢰구간은 $\{\lambda : L(\lambda) > L(\hat{\lambda}) - \frac{1}{2}\chi_{0.95,1}^2\}$. 구간 안에 1 이 들어 있으면 **변환할 근거가 없음**
- $H_0 : \lambda = \lambda_0$ 검정은 $2\{L(\hat{\lambda}) - L(\lambda_0)\} \sim \chi^2(1)$

⚠ **주의:** 반응변수를 변환하면 계수의 뜻이 원래 단위에서 벗어나 **해석이 어려워짐**. 구간 안에 0.5, 0, 1 같은 값이 있으면 $\hat{\lambda}$ 대신 그 값을 쓰는 편이 설명하기 쉬움

보정 1: Box-Cox 적용 예

↳ Galapagos 자료: 종 수 모형



(a) Residuals against fitted values on the raw response. (b) Profile log-likelihood over lambda with its 95% interval. (c) Residuals after the square-root transform.

Check	$y = \text{Species}$	$y = \sqrt{\text{Species}}$
R^2	0.766	0.783
잔차 정규성 p (Shapiro-Wilk)	0.018	0.287
등분산 p (Breusch-Pagan)	0.081	0.246
잔차 표준편차의 비 (적합값 상위 절반 / 하위 절반)	2.32	1.08

Galapagos species data ($n = 30$). $\hat{\lambda} = 0.315$, 95% CI $[0.120, 0.505]$: 1 is outside, 0.5 is inside at the boundary.

보정 2: 분산안정화 변환

✍ 분산과 평균의 관계

✍ 유도

$\mu = E(y)$ 이고 분산이 평균의 함수 $\text{Var}(y) = g(\mu)$ 라 하자. 함수 h 를 씌운 뒤의 분산을 델타법으로 근사하면

$$\text{Var}\{h(y)\} \approx \{h'(\mu)\}^2 g(\mu)$$

이 값이 μ 와 무관해지려면 $h'(\mu) \propto 1/\sqrt{g(\mu)}$, 곧 $h(\mu) = \int \frac{d\mu}{\sqrt{g(\mu)}}$

$\text{Var}(y)$	변환 $h(y)$	적용 상황
$\propto \mu$	$\sqrt{y}$	분산이 기댓값에 비례. 계수 자료
$\propto \mu, y$ 에 0 존재	$\sqrt{y} + \sqrt{y+1}$	값이 0이거나 0에 가까운 경우
$\propto \mu^2$	$\ln y$	가장 많이 쓰임. y 의 범위가 큰 경우
$\propto \mu^2, y$ 에 0 존재	$\ln(y+1)$	0이 존재하는 경우
$\propto \mu^3$	$y^{-1/2}$	작은 값을 많이 갖는 경우
$\propto \mu(1-\mu)$	$\arcsin \sqrt{y}$	y 가 비율인 경우

Variance-stabilizing transformations, each obtained from the integral above

가중회귀(Weighted Regression 장)와 이 표는 **같은 문제에 대한 두 처방**. 분산 구조를 알면 가중치로, 모르면 변환으로 대응

보정 3: 선형화 변환

✎ 곡선을 직선으로

원래 형태	변환	선형모형
$y = \beta_0 x^{\beta_1} \varepsilon$	양변에 ln	$\ln y = \ln \beta_0 + \beta_1 \ln x + \ln \varepsilon$
$y = \beta_0 e^{\beta_1 x} \varepsilon$	양변에 ln	$\ln y = \ln \beta_0 + \beta_1 x + \ln \varepsilon$
$y = \beta_0 + \beta_1 \ln x + \varepsilon$	x 만 ln	$y = \beta_0 + \beta_1 x^* + \varepsilon, x^* = \ln x$
$y = \frac{1}{\beta_0 + \beta_1 x + \varepsilon}$	양변의 역수	$y^* = \beta_0 + \beta_1 x + \varepsilon, y^* = 1/y$

Linearizing transformations. Multiple regression extends each row by adding the remaining terms.

⚠ 주의

- 위 첫 두 줄은 오차가 곱셈형($y = f(x) \cdot \varepsilon$)일 때만 로그 후 덧셈형이 됨. 덧셈형 오차 $y = f(x) + \varepsilon$ 에 로그를 씌우면 오차 구조가 바뀜
- 설명변수만 변환하면 계수 해석이 그대로 남지만, **반응변수를 변환하면 원래 단위의 뜻이 사라짐**
- 변환 뒤에는 잔차그림과 이상점 조사를 **처음부터 다시** 수행

변수선택의 필요성

◎ 정의

과적합(overfitting): 자료에 들어 있는 우연한 변동인 잡음까지 모형이 반영하여, 지금 가진 자료에는 잘 맞지만 새로운 자료의 예측에는 실패하는 현상.

⚠ 주의: R^2 비교의 한계

설명변수를 추가하면 결정계수 R^2 , 곧 반응변수의 변동 중 모형이 설명한 비율은 **절대 감소하지 않음**. R^2 만 보면 변수를 모두 포함한 모형이 언제나 우수해 보이며, 이것이 설명변수를 모두 포함하려는 잘못된 판단의 원인 (Kutner et al., 2005)

≡ 정리

- 필요한 것은 모수 개수만큼 벌점을 부과하는 모형 선택 기준
- 대표적인 기준: 수정 R^2 , AIC

모형 선택 기준: AIC의 정의

◎ 적합도와 벌점

AIC (Akaike Information Criterion): 모형의 적합도 항과 모수 개수에 매기는 벌점 항을 더한 모형 선택 기준. 같은 자료로 적합한 모형들 사이에서 값이 작을수록 선호된다 (Akaike, 1974).

$$AIC = -2 \log \hat{L} + 2k$$

기호

- $\hat{L}$: 적합한 모형이 지금의 자료를 얼마나 그럴듯하게 만들어 내는지를 나타내는 값(최대가능도). 잘 맞을수록 증가
- $\log$: 자연로그
- k : 추정하는 모수의 개수. 회귀계수 $p + 1$ 개에 오차분산 σ^2 하나를 더한 $p + 2$

AIC의 두 항 읽기

💡 두 항의 상충

- 앞항 $-2 \log \hat{L}$: **적합도** 부분으로, 자료에 잘 맞을수록 작아짐
- 뒷항 $2k$: **벌점** 부분으로, 추정하는 모수가 하나 늘 때마다 2가 더해짐
- 변수를 추가하면 앞항은 줄고 뒷항은 늘어남: 두 항의 합이 작은 모형이 균형이 좋은 모형

⚠ 주의

AIC의 절대값 자체에는 의미가 없음. 같은 자료로 적합한 모형들 사이의 **상대적 크기**만 의미를 가지므로 값이 음수여도 무방. 수정 R^2 도 변수 개수를 반영해 R^2 를 깎는다는 점에서 같은 취지의 지표

아이스크림 자료: 후보 모형 비교

田 결과

결과

Model	Predictors	R^2	Adjusted R^2	AIC
M_1 (full)	price, income, temp	0.719	0.686	-107.21
M_2	income, temp	0.702	0.680	-107.48
M_3	temp	0.602	0.587	-100.77

Candidate models for the ice cream data, $n = 30$

AIC 계산

오차가 정규분포를 따르면 최대가능도가 잔차제곱합만의 함수가 되어 다음과 같이 정리됨

$$AIC = -2 \ln \hat{L} + 2k = n \ln \left(\frac{SSE}{n} \right) + 2k + n\{1 + \ln 2\pi\}$$

기호

- k : 추정한 모수의 개수(회귀계수 $p + 1$ 개와 σ^2 하나를 합해 $k = p + 2$)
- $n\{1 + \ln 2\pi\} = 85.136$: 모형에 무관한 상수

$$AIC(M_1) = 30 \ln \frac{0.0353}{30} + 2 \times 5 + 85.136 = -202.35 + 10 + 85.136 = -107.21$$

$$AIC(M_2) = 30 \ln \frac{0.0374}{30} + 2 \times 4 + 85.136 = -200.62 + 8 + 85.136 = -107.48$$

판단: R^2 는 full 모형이 가장 크지만 AIC 최솟값은 $IC \sim \text{income} + \text{temp}$. full 모형의 price 계수는 p-value가 0.226으로, 효과가 없다고 가정했을 때 이 정도 결과가 우연히 나올 확률이 작지 않음. 두 근거를 함께 보아 price 를 제외

후진제거법: 탐색 경로

田 한 번에 하나씩 제거

완전모형에서 출발하여 변수를 하나씩 제거해 보고, AIC가 가장 작아지는 방향으로 한 걸음씩 이동

탐색 경로

Candidate	AIC*	Decision
출발점: price, income, temp	-194.34	starting point
price 제거	-194.62	smaller: price 제외
income 제거	-188.31	larger: income 유지
temp 제거	-160.31	larger: temp 유지

Backward elimination path by AIC on the ice cream data

두 AIC 눈금의 관계

탐색에는 상수를 뺀 간이 정의를 쓰기도 함

$$AIC^* = n \ln\left(\frac{SSE}{n}\right) + 2(p + 1), \quad AIC - AIC^* = 2 + n\{1 + \ln 2\pi\} = 87.136$$

절댓값은 다르지만 상수를 더한 것뿐이므로 **모형 간 차이는 동일**

$$-194.62 - (-194.34) = -0.28, \quad -107.48 - (-107.21) = -0.27$$

두 값의 차이는 표에 적은 반올림 자릿수 때문. AIC는 절댓값이 아니라 모형 사이의 차이로만 읽음

✔ **결과:** price 제외, income 과 temp 는 유지. 앞 슬라이드의 수동 비교와 같은 결론

선택 후 재진단

ㄴ 그림으로 확인

선택된 축소 모형식

$$\hat{y}_i = -0.113 + 0.00353 x_{i2} + 0.00354 x_{i3}$$

기호

- x_{i2} : 소득, x_{i3} : 온도
- $R^2 = 0.702$, 수정 $R^2 = 0.680$

자동 선택의 한계

⚠ 주의

- 자동 탐색은 후보를 제안할 뿐이며 최종 결정은 연구자의 몫
- **도메인 지식이 우선**: 이론상 반드시 필요한 변수는 정보기준 값만으로 제외하지 않음
- 같은 자료를 여러 번 들여다보며 모델을 고른 뒤 계산한 p-value와 신뢰구간은 **그대로 신뢰하기 어려움**. 선택 과정 자체가 결과에 유리한 쪽으로 작용하기 때문
- 선택된 모형의 성능을 정직하게 평가하려면 **선택에 쓰지 않은 자료**가 필요함

실무 적용: 방사선 선량-반응 모형 선택

☢ 원폭 생존자 수명연구(LSS)

- 포아송 회귀로 1 Gy당 **초과상대위험**(excess relative risk, ERR)을 추정. 방사선방호 선량한도의 근거 자료
- 고형암 발생 1958~2009년 자료: 대상 105,444명, 고형암 22,538건, 3.1백만 인년

집단	가장 잘 맞는 모형	1 Gy 에서의 ERR	95% 신뢰구간
여성	선형	0.64 /Gy	0.52 ~ 0.77
남성	선형-이차	0.20	0.12 ~ 0.28

Dose-response model selected for each sex in the Life Span Study

- 같은 자료, 같은 반응변수인데 집단을 나누면 세워야 할 모형이 달라짐
- 어느 모형을 고를 것인가가 이 장의 주제. 적합도만으로 정할 수 없고 진단과 정보기준을 함께 봄
- 선량한도라는 규제 값이 이 선택에 걸려 있음. 모형 선택이 행정 결정으로 이어지는 사례

이 장의 정리

≡ Diagnosis & Variable Selection

진단은 모형이 자료와 맞는지 확인하는 절차이고, 변수선택은 설명력과 단순함의 균형점을 찾는 절차이며, 두 절차는 번갈아 반복된다.

✂ 이 장의 도구

- 가정 네 가지: 선형성, 독립성, 정규성, 등분산성
- 진단: 잔차 e_i , 진단 그림 4종, 레버리지 h_{ii} , Cook 거리 D_i , VIF
- 선택: $AIC = -2 \log \hat{L} + 2k$, 수정 R^2 , 후진제거법
- 아이스크림 자료의 결론: $IC \sim \text{income} + \text{temp}$

🔗 다음 장: Weighted Regression: 진단에서 잔차가 깔때기 모양으로 퍼졌을 때, 곧 등분산이 깨졌을 때의 처방

참고문헌

이 장에서 인용한 문헌

- Anscombe, F. J. (1973). Graphs in statistical analysis. *The American Statistician*, 27(1), 17-21.
- Cook, R. D. (1977). Detection of influential observation in linear regression. *Technometrics*, 19(1), 15-18.
- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716-723.
- Kutner, M. H., et al. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill. (진단 기준값, 과적합)
- Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society B*, 26(2), 211-252.
- 충남대학교 강의노트 제5장. 회귀진단 및 보정. (이 장의 구성, 이상점 검정과 유의점, 보정 방법의 분류, 예제 5.2 Galapagos 자료)
- Johnson, M. P., & Raven, P. H. (1973). Species number and endemism: the Galapagos Archipelago revisited. *Science*, 179(4076), 893-895. (Galapagos 자료의 원 출처)

교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.