

Regression Analysis

6. Weighted Regression | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division

Korea Institute of Oriental Medicine

2026-09-01

Weighted Regression

이 장의 출발점

? 질문

🔗 앞 장에서 여기까지: 진단에서 잔차가 깔때기 모양으로 퍼지면 등분산 위반. ❓ 이 장의 질문: 그때 어떤 방법을 사용하는가

모든 관측값을 동일한 신뢰도로 취급해야 하는가?

💡 핵심

- 계측기마다 교정 성적서에 적힌 **측정 불확도**가 다름
- 관측값이 서로 다른 횟수의 반복 측정을 평균한 값일 수 있음
- 관측별 신뢰도를 모형에 반영하는 장치가 필요함: 가중치 w_i
- 추정 대상인 조건부 기댓값 $E(y \mid x)$ 자체는 바뀌지 않음. 관측마다 주는 가중치만 달라짐

기호

- w_i : i 번째 관측에 부여하는 가중치
- 그 관측이 추정에 미치는 영향의 크기를 조절

등분산과 이분산: 정의

◎ 아래첨자 i 의 유무

등분산(homoscedasticity): 모든 $i = 1, \dots, n$ 에 대해 $\text{Var}(\varepsilon_i) = \sigma^2$.
오차의 분산이 공통

이분산(heteroscedasticity): $\text{Var}(\varepsilon_i) = \sigma_i^2$. 오차의 분산이 관측마다 다
름


기호

- ε_i : i 번째 관측의 오차. 참 직선에서 그 관측이 위아래로 벗어난 양
- Var : 분산. 값들이 평균에서 흩어진 정도를 재는 수치
- σ^2 : 모든 관측에 공통인 오차 분산
- σ_i^2 : 관측마다 달라지는 오차 분산
- n : 관측 수

두 식의 차이는 아래첨자 i 하나뿐이지만, 뒤에서 볼 결과의 차이는 작지 않음

등분산과 이분산: 깔때기 신호

잔차 그림으로 확인



이분산의 전형적 신호

- 산점도: x 가 커질수록 점들이 직선 주위로 넓게 퍼짐
- 잔차 그림: 왼쪽은 좁고 오른쪽은 넓은 깔때기 모양
- 등분산이면 잔차가 위아래로 고른 띠를 이룸

Simulated data with error spread growing in x (funnel-shaped residuals)

등분산은 자료가 저절로 만족해 주는 성질이 아니라 분석자가 걸어 둔 가정이므로, Diagnosis 장의 잔차 그림으로 확인해야 함

등분산 위반: Gauss-Markov 복습

💡 OLS가 최선이었던 근거

Gauss-Markov 정리: 다음 두 조건이 성립하면 통상최소제곱 추정량 $\hat{\beta}_{OLS}$ 는 BLUE이다.

$$E(\varepsilon \mid \mathbf{X}) = \mathbf{0}, \quad \text{Var}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}$$

기호

- ε : 오차를 세로로 쌓은 $n \times 1$ 벡터
- $\mathbf{X}$: 절편열을 포함한 $n \times (p + 1)$ 설계행렬
- $\mathbf{I}$: $n \times n$ 항등행렬
- 둘째 조건 = **등분산**(모든 오차의 분산이 σ^2 로 같음) + **무상관**(서로 다른 관측의 오차가 함께 움직이지 않음)

© BLUE(Best Linear Unbiased Estimator): y 의 선형결합으로 만든 불편 추정량 가운데 분산이 가장 작은 것. 불편은 같은 실험을 무수히 반복했을 때 추정값의 평균이 참값과 일치한다는 뜻

등분산 위반: 무너지는 결론

⚠ 불편이나 최소분산 아님

이분산에서는 $\text{Var}(\varepsilon) = \sigma^2 \mathbf{I}$ 가 성립하지 않으므로 Gauss-Markov 정리의 전제가 무너진다. $\hat{\beta}_{OLS}$ 는 여전히 불편추정량이지만 더 이상 최소분산이 아니다.

- 편향은 생기지 않음: $E(\hat{\beta}_1) = \beta_1$ 이 그대로 성립함
- 최소분산이 아님: 분산이 더 작은 선형 불편 추정량이 존재함
- 표준오차가 왜곡됨: 등분산을 전제로 유도한 공식이기 때문
- 따라서 t -검정, p -값, 신뢰구간이 모두 틀어짐 (Kutner et al., 2005)

기호

- $\hat{\beta}_1$: 기울기의 추정량, β_1 : 그 참값
- **표준오차**: 추정값이 표본마다 얼마나 흔들리는지를 재는 수치
- p -값: “기울기가 0이다”라는 가정이 옳다고 볼 때 지금 자료만큼 극단적인 결과가 나올 확률

가중최소제곱(WLS): 목적함수

◎ 정의

가중최소제곱(weighted least squares)은 다음 가중 잔차제곱합을 최소화하는 값을 추정량으로 택한다.

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n w_i (y_i - \beta_0 - \beta_1 x_i)^2$$

기호

- y_i : 반응변수, x_i : 설명변수
- β_0, β_1 : 절편과 기울기
- w_i : i 번째 관측의 가중치, n : 관측 수

💡 핵심

- 이론적 최적 가중치는 오차 분산의 역수: $w_i = 1/\sigma_i^2$
- 분산이 작은(정밀한) 관측일수록 큰 w_i 를 받음
- 모든 $w_i = 1$ 이면 통상최소제곱과 같음: **OLS는 WLS의 특수한 경우**
- 가중치는 비율만 의미를 가짐. 전체에 같은 상수를 곱해도 추정값은 불변

가중최소제곱(WLS): 행렬 해

◎ OLS 공식에 $\mathbf{W}$ 삽입

$$\hat{\beta}_W = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$$

기호

- $\mathbf{y}$: 반응변수를 세로로 쌓은 $n \times 1$ 벡터
- $\mathbf{X}$: 절편열을 포함한 $n \times (p + 1)$ 설계행렬
- $\mathbf{W} = \text{diag}(w_1, \dots, w_n)$: 가중치를 대각선에 놓고 나머지 자리를 0으로 채운 대각행렬
- $\hat{\beta}_W$: 가중최소제곱 추정량

OLS 공식 $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 와 비교하면 $\mathbf{X}$ 와 $\mathbf{y}$ 사이에 $\mathbf{W}$ 가 끼어든 형태. $\mathbf{W} = \mathbf{I}$ 이면 OLS로 되돌아감

가중최소제곱(WLS): 해의 유도

✍ 절차는 OLS와 동일

가중 잔차제곱합을 행렬로 쓰면

$$S_W(\beta) = \sum_{i=1}^n w_i (y_i - \mathbf{x}_i^\top \beta)^2 = (\mathbf{y} - \mathbf{X}\beta)^\top \mathbf{W}(\mathbf{y} - \mathbf{X}\beta)$$

β 로 미분해 $\mathbf{0}$ 으로 놓으면 정규방정식을 얻음

$$\frac{\partial S_W}{\partial \beta} = -2 \mathbf{X}^\top \mathbf{W}(\mathbf{y} - \mathbf{X}\beta) = \mathbf{0} \implies \mathbf{X}^\top \mathbf{W} \mathbf{X} \hat{\beta}_W = \mathbf{X}^\top \mathbf{W} \mathbf{y}$$

$\mathbf{X}^\top \mathbf{W} \mathbf{X}$ 가 가역이면 앞 슬라이드의 해

기호

- $\mathbf{x}_i^\top$: 설계행렬 $\mathbf{X}$ 의 i 번째 행
- $S_W(\beta)$: 가중 잔차제곱합

가중치를 정하는 규칙

田 실무 규칙

Situation	Weight w_i
측정 분산 σ_i^2 를 아는 경우(교정 성적서, 반복 측정)	$w_i = 1/\sigma_i^2$
y_i 가 n_i 개 측정값의 평균인 경우	$w_i = n_i$
퍼짐이 x_i 에 비례해 커지는 경우	$w_i \propto 1/x_i$

Practical rules for choosing weights (Kutner et al., 2005)

기호

- σ_i^2 : i 번째 관측의 오차 분산
- n_i : y_i 를 만들 때 평균한 측정 횟수
- $\propto$: “비례한다”는 기호

💡 핵심

세 규칙은 모두 하나의 원리에서 나온다: 가중치는 분산의 역수. n_i 개 측정값을 평균하면 그 평균의 분산이 σ^2/n_i 이므로, 역수를 취하면 $w_i \propto n_i$ 가 된다.

가중치의 실무 적용: 감마선 검교정

✂ 분산을 이미 아는 경우

Introduction 장에서 소개한 사례가 앞 표의 첫째 줄에 해당함

- 검출기의 검출 효율 곡선을 적합하는 검교정 문제
- 각 측정점의 분산이 **계수 통계(counting statistics)**로 이미 알려져 있음
- 따라서 가중치를 추정하지 않고 곧바로 계산함: $w_i = 1/\sigma_i^2$
- 오차 분산을 알고 오차가 서로 무상관이면, 역분산 가중이 선형 불편 추정량 가운데 최소분산을 줌

기호

- σ_i : i 번째 측정점 계수율의 표준편차
- 계수 통계에서 곧바로 계산되는 값

예제 자료(물리 측정): 자료 구조

田 w 는 분산에 비례


x	y	w
0.345	367	17
0.287	311	9
0.251	295	9

First 3 rows of the physics data. $n = 10$ observations, 3 variables (CNU lecture note, Example 8.1)

- 양자충돌 실험 자료, $n = 10$
- x 는 설명변수, y 는 반응변수인 측정값
- w 는 각 y 의 **측정 분산에 비례**하는 값. 분산 자체가 아니라 분산에 비례하는 값
- 따라서 가중치는 그 역수인 $1/w$ 가 됨. w 가 클수록 신뢰도가 낮은 점

예제 자료(물리 측정): OLS와 WLS 비교

두 직선의 차이



💡 읽는 법

- 점의 크기가 가중치 $1/w$ 에 비례함
- 큰 점일수록 정밀하게 측정된 점
- 실선은 모든 점을 동일하게 취급한 OLS
- 점선은 가중치를 반영한 WLS
- 두 직선이 갈라지는 이유는 WLS가 큰 점 쪽으로 더 기울기 때문

OLS vs WLS fits on the physics data; point size is proportional to weight

예제 자료(물리 측정): 추정 결과

田 계수와 표준오차의 변화

추정 경로

자료에 기록된 w_i 는 각 y_i 의 측정분산. 가중치는 그 역수이므로

$$\mathbf{W} = \text{diag}\left(\frac{1}{w_1}, \dots, \frac{1}{w_{10}}\right), \quad \hat{\beta}_{\text{WLS}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$$

$$\text{Var}(\hat{\beta}_{\text{WLS}}) = \sigma^2 (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1}$$

$\mathbf{W} = \mathbf{I}$ 로 두면 두 식이 그대로 OLS의 $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 와 $\sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 이 됨. OLS는 모든 관측에 동일한 가중치를 부여한 WLS

추정 결과

Estimate	OLS	WLS
$\hat{\beta}_0$ (intercept)	136.6 (SE 11.9)	144.8 (SE 10.3)
$\hat{\beta}_1$ (slope)	602.4 (SE 55.6)	549.5 (SE 53.6)

OLS vs WLS estimates on the physics data (n = 10). WLS $R^2 = 0.929$

결과 읽기

- 기울기 추정: 602.4에서 549.5로 이동함
- 표준오차: 절편은 11.9에서 10.3으로, 기울기는 55.6에서 53.6으로 감소함
- WLS 적합의 결정계수는 $R^2 = 0.929$
- 표준오차의 감소 폭보다, 분산 구조를 반영한 표준오차를 쓰게 되었다는 점이 중요함

감쇠 곡선: 문제 설정

◎ 가중치를 아는 문제

✍ 유도

감쇠는 Beer-Lambert 형태로, 로그를 취하면 선형이 되고 기울기의 음수가 감쇠계수 μ

$$N(x) = N_0 e^{-\mu x} \implies \ln N(x) = \ln N_0 - \mu x$$

계수는 Poisson을 따르므로 $\text{Var}(N) = N$. 여기에 델타법을 적용하면



$$\text{Var}(\ln N) \approx \left(\frac{d \ln N}{dN} \right)^2 \text{Var}(N) = \frac{1}{N^2} \cdot N = \frac{1}{N}$$

- 델타법: 함수 $g(N)$ 의 분산을 $\{g'(N)\}^2 \text{Var}(N)$ 로 근사하는 방법

- 흡수체가 두꺼워져 계수가 줄수록 $\ln N$ 의 분산이 커짐. 로그 변환이 이분산을 만들어 냄
- 그 크기가 이론으로 이미 알려져 있으므로 가중치는 곧바로 $w_i = 1 / \text{Var}(\ln N_i) = N_i$
- 앞의 규칙 표 첫째 줄(분산을 아는 경우)에 그대로 해당

감쇠 곡선: 분산의 증가

≒ 모의실험 $\mu = 1.25 \text{ cm}^{-1}$, $N_0 = 20000$




(a) log counts with plus or minus 3 SD bars. (b) $\text{Var}(\log N)$ against absorber thickness.

Thickness (cm)	0.0	1.2	2.4	3.6	4.0
Counts N	19920	4449	1046	216	139
$\text{Var}(\ln N) = 1/N$	0.000050	0.000225	0.000956	0.004630	0.007194

One simulated attenuation experiment; the error variance grows 143-fold across the range

감쇠 곡선: OLS와 WLS 비교

≈ 2000회 반복에서의 $\hat{\mu}$ 분포



(a) One experiment: the two fits nearly coincide. (b) Sampling distribution of the estimated attenuation coefficient over 2000 repeats.

Method	Bias	SD	RMSE
로그 계수에 OLS	+0.0005	0.0124	0.0124
로그 계수에 WLS ($w_i = N_i$)	-0.0002	0.0060	0.0060

Recovery of the true attenuation coefficient over 2000 simulated experiments

둘 다 편향은 없으나 WLS의 분산이 4.3배 작음. 같은 측정으로 μ 를 두 배 이상 정밀하게 얻는다는 뜻

감쇠 곡선: WLS의 한계

⚠ 최대가능도로의 전환

가중치로 쓰는 N_i 가 관측값 자체이므로, 계수가 적으면 가중치와 자료가 음의 상관을 갖게 되어 편향이 생김

가장 얇은 신호의 기대계수	OLS 편향	WLS 편향	Poisson GLM 편향
135	+0.0005	-0.0002	+0.0001
13.5	+0.0090	-0.0026	-0.0000
1.3	+0.0034	-0.0286	-0.0083

Bias in the estimated attenuation coefficient as the weakest signal gets smaller (2000 repeats each)

✂ 실무 지침

- 계수가 수십 이상: 로그 변환 후 $w_i = N_i$ 로 WLS
- 계수가 한 자리로 떨어짐: 로그를 취하지 말고 **Poisson 최대가능도**(로그연결 GLM)로 직접 적합
- 계수가 0인 점: 로그가 정의되지 않으므로 WLS 자체가 불가능. GLM은 그대로 처리 가능

일반화최소제곱(GLS): 정의

◎ 오차 간 상관의 포함

오차의 공분산행렬이 $\text{Var}(\epsilon) = \Sigma$ 인 선형모형 $y = X\beta + \epsilon$ 에서, 일반화최소제곱 추정량은 다음과 같다.

$$\hat{\beta}_{GLS} = (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} y$$

기호

- Σ : 오차 벡터 ϵ 의 공분산행렬. 대칭이고 양정치
- 대각 원소: 각 오차의 분산
- 비대각 원소: 두 오차가 함께 움직이는 정도인 공분산
- 나머지 기호는 앞 슬라이드와 동일

WLS 공식에서 W 자리에 Σ^{-1} 이 들어간 형태

일반화최소제곱(GLS): 유도

✍ 변환을 통해 OLS로 환원

$\Sigma^{-1} = \mathbf{P}^\top \mathbf{P}$ 를 만족하는 대칭행렬 $\mathbf{P}$ 를 잡아 모형의 양변에 곱하면

$$\mathbf{P}\mathbf{y} = \mathbf{P}\mathbf{X}\boldsymbol{\beta} + \mathbf{P}\boldsymbol{\varepsilon}, \quad \text{Var}(\mathbf{P}\boldsymbol{\varepsilon}) = \mathbf{P}\boldsymbol{\Sigma}\mathbf{P}^\top = \mathbf{I}$$

변환된 자료는 등분산과 무상관을 모두 만족. 여기에 **통상최소제곱**을 그대로 적용하면 앞 슬라이드의 GLS 해

기호

- $\mathbf{P}$: Σ^{-1} 을 분해해 얻는 변환행렬
- $\mathbf{I}$: 항등행렬

일반화최소제곱(GLS): WLS와의 관계

💡 핵심

- WLS는 Σ 가 대각행렬인 특수한 경우. 오차 사이의 상관을 나타내는 비대각 원소가 모두 0
- $\Sigma = \sigma^2 \mathbf{I}$ 이면 GLS와 WLS와 OLS가 모두 일치함
- Σ 를 알 때 GLS가 BLUE라는 결과가 Gauss-Markov 정리의 일반화임(Aitken 정리)

田 자기상관 구조의 예


시간 순서로 이웃한 오차가 서로 닮아 있는 성질을 **자기상관**이라 함. 한 칸 멀어질 때마다 상관이 ρ 배로 줄어드는 구조가 가장 단순한 예

$$\Sigma = \sigma^2 \begin{pmatrix} 1 & \rho & \rho^2 & \cdots & \rho^{n-1} \\ \rho & 1 & \rho & \cdots & \rho^{n-2} \\ \rho^2 & \rho & 1 & \cdots & \rho^{n-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho^{n-1} & \rho^{n-2} & \rho^{n-3} & \cdots & 1 \end{pmatrix}, \quad |\rho| < 1$$

$\rho = 0$ 이면 비대각 원소가 모두 사라져 $\Sigma = \sigma^2 \mathbf{I}$, 곧 OLS로 되돌아감

GLS 예제: Lake Huron 수위

≈ 98년 연간 기록의 추세



(a) Annual lake level 1875-1972 with the OLS and GLS trends and their 95% confidence bands. (b) Residual ACF against the fitted AR(1) curve.

Quantity	Value	뜻
Durbin-Watson d	0.4395 ($p = 1.0 \times 10^{-22}$)	2에서 아래로 크게 벗어남
Residual ACF, lags 1-3	0.762, 0.464, 0.261	이웃 해의 잔차가 강하게 닮아 있음
Runs of one sign	19	98개 잔차에서 부호가 18번만 바뀜

Autocorrelation in the OLS residuals of the Lake Huron trend model ($n = 98$ annual measurements)

- $d = \sum_{t=2}^n (e_t - e_{t-1})^2 / \sum_{t=1}^n e_t^2$: **Durbin-Watson 통계량**
- 이웃한 잔차가 무관하면 2 부근, 같은 방향으로 움직이면 2보다 작아짐
- 퍼짐은 고르므로 등분산은 유지되고, $\text{Var}(\epsilon) = \sigma^2 \mathbf{I}$ 의 **무상관** 쪽만 깨져 있음

GLS 예제: 풀이 절차

✍ 세 단계

- 1 구조를 고른다. 앞 슬라이드의 AR(1)을 그대로 씀. 관측이 98개면 공분산행렬의 칸이 9604개이므로, 모양을 정해 추정할 값을 ρ 하나로 줄임

$$\Sigma = \sigma^2 \mathbf{V}, \quad V_{ij} = \rho^{|i-j|}$$

- 2 ρ 를 추정한다. 서로 다른 세 방법이 거의 같은 값을 줌: Cochrane-Orcutt 반복 0.768, 최대가능도 0.783, 제한최대가능도 0.825. 추정 방법이 결과를 좌우하지 않는다는 확인이며, 이후 계산은 $\hat{\rho} = 0.825$ 를 사용

- 3 공식에 넣는다. $\hat{\beta}_{GLS} = (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{y}$ 로 계산. $\rho = 0$ 을 검정하는 가능도비는 $\chi_1^2 = 89.6, p < 0.0001$ 로 자기상관 항을 넣을 근거가 뚜렷함

Σ 를 몰라 자료에서 추정해 쓰므로 실행가능 GLS(feasible GLS). Aitken 정리의 BLUE 보장은 근사적으로만 성립

GLS 예제: OLS와 GLS 비교

田 기울기는 그대로, 표준오차는 3배

Estimate	OLS	GLS (AR(1), $\hat{\rho} = 0.825$)
$\hat{\beta}_0$ (intercept)	625.555 (SE 7.764)	616.489 (SE 24.363)
$\hat{\beta}_1$ (slope, feet/year)	-0.02420 (SE 0.00404)	-0.01943 (SE 0.01266)
t for the slope	-6.00	-1.53
p for the slope	3.5×10^{-8}	0.128
95% CI for the slope	$[-0.0322, -0.0162]$	$[-0.0446, +0.0057]$

OLS vs feasible GLS on the Lake Huron trend model (n = 98, df = 96)

💡 읽는 법

- 기울기 추정값은 -0.0242 에서 -0.0194 로 조금 움직였을 뿐. **바뀐 것은 정밀도의 평가**
- 표준오차가 **3.14배**로 커지고 신뢰구간도 같은 배율로 넓어져 0을 포함하게 됨
- 결론이 뒤집힘: OLS는 하강 추세가 $p = 3.5 \times 10^{-8}$ 로 확실하다고 하지만, GLS는 $p = 0.128$ 로 **유의하지 않**다고 함
- 원인은 정보량의 과대계산. 이웃 해의 값이 서로 닮아 있으면 실제 독립 정보는 98년치보다 적는데, OLS 공식은 98개를 전부 독립으로 셈

⚠ **주의:** AR(1)은 근사. 그림 (b)에서 붉은 곡선이 lag 2 이상에서 실제 ACF보다 위에 있고, 변환 뒤에도 lag-1 상관이 0.19 남음. 이 자료에는 AR(2) 계열이 더 맞는다고 알려져 있으나, **결론의 방향은 바뀌지 않음**

이 장의 정리

≡ 정리

- 이분산이면 OLS는 편향은 없지만 **최소분산이 아니고, 표준오차가 틀어짐**
- 처방은 WLS: $\min \sum w_i (y_i - \beta_0 - \beta_1 x_i)^2$, 해는 $(\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$
- 이론적 최적 가중치는 분산의 역수 $w_i = 1/\sigma_i^2$ 이며, 가중치에는 근거가 있어야 함
- 오차 사이의 상관까지 있으면 GLS로 확장함: $\mathbf{W}$ 자리에 Σ^{-1}

✂ 실무 적용

측정 불확도가 기록되어 있다면 그 분산의 역수를 가중치 $w_i = 1/\sigma_i^2$ 로 삼는다.

기호는 이 장에서 정의한 것과 같음(w_i 가중치, σ_i^2 관측별 오차 분산, $\mathbf{W}$ 가중치 대각행렬, Σ 오차 공분산행렬)

🔗 다음 장: Dummy Variable: 아이스크림 자료의 관측 연차처럼 숫자로 계산하면 안 되는 정보를 모형에 넣는 방법

참고문헌

이 장에서 인용한 문헌

- Kutner, M. H., et al. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill. (이분산의 결과, 가중치 선택 규칙, 자기상관과 Cochrane-Orcutt 절차)
- *Analytical Chemistry*, 91(7) (2019). doi:10.1021/acs.analchem.9b00119
- INMM Annual Meeting Proceedings. Weighted least squares fitting of gamma spectroscopy efficiency functions.
- Brockwell, P. J., & Davis, R. A. (1991). *Time Series: Theory and Methods*, 2nd ed. Springer, p. 555. (GLS 예제의 Lake Huron 자료. R의 `datasets::LakeHuron` 이 출처로 드는 문헌)

교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.