

Regression Analysis

7. Dummy Variable | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division
Korea Institute of Oriental Medicine

2026-09-01

Dummy Variable

질적 설명변수의 처리

💡 복습: 변수의 유형

🔗 앞 장에서 여기까지: 관측별 신뢰도를 가중치로 반영. ❓ 이 장의 질문: 숫자가 아닌 범주 정보를 설계행렬에 어떻게 넣는가

📊 Types of variables

- 양적 변수(quantitative): 온도, 가격, 소득처럼 수치로 측정되어 크기와 간격이 정의되는 변수
- 질적 변수(qualitative): 관측 연차, 계측기 제조사, 운전/정지 상태, 제품 형태처럼 범주로만 구분되는 변수
- 회귀분석에서 반응변수는 양적 변수, 설명변수는 양적과 질적 모두 가능

? 질문

질적 변수의 범주에는 덧셈과 곱셈이 정의되지 않는다. 이 정보를 어떻게 $y = \mathbf{X}\beta + \varepsilon$ 의 설계행렬 $\mathbf{X}$ 의 열로 만들 것인가?

기호

- $\mathbf{X}$: 절편열을 포함한 $n \times (p + 1)$ 설계행렬
- n : 관측 수, p : 설명변수의 개수
- $\mathbf{X}$ 의 원소는 모두 숫자여야 하므로 범주 이름을 그대로 넣을 수 없음

가변수의 정의

◎ 정의

가변수(dummy variable, indicator variable): 질적 설명변수의 특정 범주에 대해

$$d_i = \begin{cases} 1, & i\text{번째 관측이 그 범주에 속할 때} \\ 0, & \text{그 외} \end{cases}$$

로 정의되는 0/1 지시변수.

기호

- d_i : i 번째 관측이 그 범주에 속하는지를 나타내는 값($i = 1, \dots, n$)
- 값이 0 또는 1인 숫자이므로 설계행렬 $\mathbf{X}$ 의 한 열이 될 수 있음

💡 핵심

- 범주 자체를 수치화하는 것이 아니라, 범주에 속하는지 여부를 0과 1로 기록
- 가변수가 들어간 모형도 여전히 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 형태의 선형모형. 추정과 검정 절차는 앞 장과 동일

예제 자료: 관측 연차

田 자료 구조

period	IC	price	income	temp	year
1	0.386	0.270	78	41	0
2	0.374	0.282	79	56	0
3	0.393	0.277	81	63	0
4	0.425	0.280	80	68	0
5	0.406	0.272	76	69	0

First 5 rows of the ice cream data. $n = 30$ four-week periods, 6 variables.

💡 핵심

- `year`는 0/1/2 값을 가지는 **관측 연차**, 곧 몇 년째 기록인지를 나타내는 질적 변수. 계절 구분이 아님
- 앞 장까지는 `price`, `income`, `temp`만 사용하고 `year`는 보류
- `year`의 범주 수는 $k = 3$

가변수 코딩: $k - 1$ 개 규칙

▣ 코딩 규칙

year (observation year)	d_{i1}	d_{i2}
0 (baseline)	0	0
1	1	0
2	0	1

Dummy coding for the observation year. $k = 3$ categories require only $k - 1 = 2$ indicator columns.

기호

- d_{i1} : 관측 연차가 $\text{year} = 1$ 이면 1, 아니면 0인 가변수
- d_{i2} : 관측 연차가 $\text{year} = 2$ 이면 1, 아니면 0인 가변수

💡 핵심

- 범주가 k 개면 가변수는 $k - 1$ 개. year 는 $k = 3$ 이므로 가변수 2개로 충분
- 모든 가변수가 0인 상태가 **기준 범주**(baseline, 여기서는 $\text{year} = 0$)이며, 그 수준은 절편 β_0 가 담당

가변수 코딩: dummy trap

⚠ k 개 모두 넣은 경우

✍ 유도

범주 수만큼 가변수를 만들어 $\text{year} = 0$ 을 나타내는 d_{i0} 까지 설계행렬에 넣으면, 모든 관측에서

$$d_{i0} + d_{i1} + d_{i2} = 1, \quad i = 1, \dots, n$$

가 항상 성립

- d_{i0} : $\text{year} = 0$ 이면 1, 아니면 0인(실제로는 만들지 않는) 세 번째 가변수
- 우변의 1은 절편에 대응하는 열, 곧 모든 원소가 1인 $\mathbf{X}$ 의 첫 열과 동일
- 한 열이 다른 열들의 합으로 그대로 재현되므로 **완전 공선성**(설명변수 열 사이에 정확한 선형 관계가 성립하는 상태)이 발생
- 이때 $\mathbf{X}^\top \mathbf{X}$ 의 역행렬이 존재하지 않아 최소제곱해가 유일하게 결정되지 않으며, 이를 dummy trap이라 부름

✂ 해결: 기준범주의 흡수

d_{i0} 을 만들지 않고 빼면 열 사이의 선형관계가 사라져 $\mathbf{X}^\top \mathbf{X}$ 의 역행렬이 존재

$$\mathbf{X} = \left[\underbrace{\mathbf{1}}_{\text{절편}} \quad \underbrace{\mathbf{x}}_{\text{temp}} \quad \underbrace{\mathbf{d}_1 \quad \mathbf{d}_2}_{k-1=2 \text{ 개}} \right]_{30 \times 4}, \quad \text{rank}(\mathbf{X}) = 4$$

빠진 범주 $\text{year} = 0$ 은 사라진 것이 아니라 절편 β_0 이 대신 나타냄. 그래서 이 범주를 **기준범주(baseline)**라 부름


평행선 모형: 정의

◎ 기울기는 공통, 절편만 이동

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 d_{i1} + \beta_3 d_{i2} + \varepsilon_i$$

기호

- y_i : i 번째 기간의 아이스크림 소비량(IC), x_i : 온도(temp)
- d_{i1}, d_{i2} : 관측 연차가 각각 year = 1, year = 2일 때 1이 되는 가변수
- β_0 : 기준 연차(year = 0)의 절편, β_1 : 세 연차가 공유하는 온도의 기울기
- β_2, β_3 : 기준 연차 대비 절편의 차이, ε_i : 평균 0, 분산 σ^2 인 오차



One common slope, three year-specific intercepts (parallel-lines model)

평행선 모형: 연차별 반응함수

◎ 조건부 기댓값 표현

회귀를 조건부 기댓값 $E(Y \mid X = x)$ 로 정의하였으므로, 가변수를 포함한 모형도 연차별 조건부 기댓값으로 읽는다.

$$E(y_i \mid x_i, \text{year} = 0) = \beta_0 + \beta_1 x_i$$

$$E(y_i \mid x_i, \text{year} = 1) = (\beta_0 + \beta_2) + \beta_1 x_i$$

$$E(y_i \mid x_i, \text{year} = 2) = (\beta_0 + \beta_3) + \beta_1 x_i$$

💡 핵심

- 연차별 절편: year = 0은 β_0 , year = 1은 $\beta_0 + \beta_2$, year = 2는 $\beta_0 + \beta_3$
- 기울기 β_1 은 세 연차가 공통이므로, 가변수는 직선을 **위아래로 평행이동**만 시킴
- β_2 = 온도를 같은 값으로 고정했을 때 year = 1과 year = 0의 평균 소비량 차이

평행선 모형: 적합 결과

◎ 추정한 모형

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 d_{i1} + \beta_3 d_{i2} + \varepsilon_i, \quad i = 1, \dots, 30$$

기호

- x_i : temp
- d_{i1} : year = 1이면 1 아니면 0, d_{i2} : year = 2이면 1 아니면 0
- 추정할 계수는 네 개

▣ 결과

Term	Estimate	p-value
$\hat{\beta}_0$ (intercept, year = 0)	0.169	n.a.
$\hat{\beta}_1$ (temp)	0.00339	1.0e-09
$\hat{\beta}_2$ (d_1 : year = 1)	0.0165	0.232
$\hat{\beta}_3$ (d_2 : year = 2)	0.0743	8.2e-05

Coefficients of the parallel-lines model. R-squared = 0.790, adjusted R-squared = 0.765, n = 30.

p-value = 해당 계수가 실제로는 0이라고 가정했을 때 지금 얻은 것만큼 큰 계수가 우연히 나올 확률. 작을수록 계수가 0이 아니라는 근거가 강함

평행선 모형: 결과 해석

💡 연차 효과의 잔존

- 온도의 기울기 0.00339는 세 연차 공통. $p = 1.0 \times 10^{-9}$ 로 매우 유의
- 같은 온도에서 3년차(year = 2)의 평균 소비량은 1년차(year = 0)보다 **0.0743 높음** ($p = 8.2 \times 10^{-5}$)
- 2년차(year = 1)의 차이 0.0165는 $p = 0.232$. 1년차와 다르다고 보기 어려움
- 연차별 절편: year = 0은 $\hat{\beta}_0 = 0.169$, year = 1은 $\hat{\beta}_0 + \hat{\beta}_2 = 0.185$, year = 2는 $\hat{\beta}_0 + \hat{\beta}_3 = 0.243$
- 온도만 사용한 단순회귀의 $R^2 = 0.602$ 에서 가변수 추가 후 $R^2 = 0.790$ 으로 상승 (adj. $R^2 = 0.765$)

상호작용 모형: 도입

⚠ 주의: 평행선 모형의 숨은 가정

평행선 모형은 관측 연차가 절편만 바꾼다고 가정한다. 온도에 대한 민감도, 즉 기울기는 세 연차가 동일하다고 강제한다.

◎ 상호작용 모형

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 d_{i1} + \beta_3 d_{i2} + \beta_4 x_i d_{i1} + \beta_5 x_i d_{i2} + \varepsilon_i$$

기호

- $x_i d_{i1}, x_i d_{i2}$: 온도와 연차 가변수를 곱한 상호작용 항
- β_4, β_5 : year = 1, year = 2에서 기울기가 기준 연차보다 달라지는 양
- 나머지 기호는 앞 슬라이드와 동일

상호작용 모형: 연차별 직선

가변수에 0과 1을 대입

가변수에 0과 1을 대입하면 연차별 회귀직선이 분리됨

$$\text{year} = 0 : y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$\text{year} = 1 : y_i = (\beta_0 + \beta_2) + (\beta_1 + \beta_4)x_i + \varepsilon_i$$

$$\text{year} = 2 : y_i = (\beta_0 + \beta_3) + (\beta_1 + \beta_5)x_i + \varepsilon_i$$

year = 1의 기울기는 $\beta_1 + \beta_4$. 절편뿐 아니라 기울기까지 연차별로 달라지므로 세 직선은 더 이상 평행하지 않음

◎ 상호작용항을 포함한 모형식

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 d_{i1} + \beta_3 d_{i2} + \beta_4 (x_i d_{i1}) + \beta_5 (x_i d_{i2}) + \varepsilon_i$$

기호

- $x_i d_{i1}, x_i d_{i2}$: 설명변수와 가변수를 곱해 만든 **상호작용항**
- 추정할 계수가 평행선 모형의 4개에서 6개로 늘어남

상호작용 모형: 적합 결과

田 계수 6개와 연차별 직선

Term	Estimate	SE	p-value
$\hat{\beta}_0$ (intercept, year = 0)	0.19259	0.03635	2.0e-05
$\hat{\beta}_1$ (temp)	0.002932	0.000665	1.9e-04
$\hat{\beta}_2$ (d_1 : year = 1)	0.00401	0.04556	0.931
$\hat{\beta}_3$ (d_2 : year = 2)	0.00573	0.05057	0.911
$\hat{\beta}_4$ (xd_1)	0.000219	0.000854	0.800
$\hat{\beta}_5$ (xd_2)	0.001444	0.000989	0.157


Coefficients of the interaction model. R-squared = 0.809, adjusted R-squared = 0.770, residual SE = 0.0316, n = 30, df = 24.

Year	Intercept	Slope	계산
0	0.19259	0.002932	$\hat{\beta}_0, \hat{\beta}_1$
1	0.19659	0.003151	$\hat{\beta}_0 + \hat{\beta}_2, \hat{\beta}_1 + \hat{\beta}_4$
2	0.19832	0.004376	$\hat{\beta}_0 + \hat{\beta}_3, \hat{\beta}_1 + \hat{\beta}_5$

The three year-specific lines recovered from the six coefficients. Fitting each year separately reproduces them to 1.9e-16.

상호작용 모형: 모형 선택

기울기 차이의 유의성



(a) The interaction model: three lines free to differ in slope. (b) The parallel-lines fit (dashed) drawn over the interaction fit (solid).

Criterion	평행선 모형	상호작용 모형	판정
계수 개수	4	6	
R^2	0.7896	0.8093	항을 넣으면 항상 오름
수정 R^2	0.7653	0.7696	거의 그대로
AIC	-115.91	-114.87	평행선 모형이 낫다
Partial $F(2, 24)$		1.243 ($p = 0.307$)	기울기 차이는 유의하지 않다

Parallel-lines model vs interaction model on the ice cream data.

실무 적용: 원자로압력용기 조사취화 예측식

✂ ASTM E900-15

▣ Variables in the ASTM E900-15 embrittlement trend curve

- 반응변수: 중성자 조사에 따른 샤르피 41 J 천이온도 변화량(transition temperature shift, TTS)
- 양적 설명변수: 구리, 니켈, 인, 망간 함량, 중성자 조사량(fluence)과 조사율(flux), 조사 온도
- 질적 설명변수: 제품 형태(용접재, 판재, 단조재)를 지시변수로 투입

- 자료: 상용 원전 감시시험 1878건(13개국 감시시험 프로그램)
- 방법: 최대가능도로 26개 모수를 적합. 적합도 RMSE 13.3 °C, 결정계수 $R^2 = 0.875$
- 이 장의 코딩 규칙 그대로: 제품 형태가 k 개 범주이면 지시변수는 $k - 1$ 개, 나머지 한 범주는 기준
- 지시변수 계수는 조성과 조사 조건을 고정했을 때 제품 형태에 따른 TTS의 평균 차이로 해석

이 장의 정리

≡ Dummy Variable

한 줄 요약: 범주 정보는 0/1 가변수 $k - 1$ 개로 모형에 들어간다. 가변수는 절편을 바꾸고(평행선 모형), x 와 곱해 넣으면 기울기까지 바꾼다(상호작용 모형).

- 질적 설명변수 $\rightarrow$ 가변수 $k - 1$ 개 $\rightarrow$ 설계행렬 $\mathbf{X}$ 의 열. 회귀분석 8단계 중 4단계(모형 설정)의 확장
- 기준 범주는 절편 β_0 가 담당. 가변수를 k 개 모두 넣으면 완전 공선성으로 dummy trap
- 가변수 계수는 다른 설명변수를 고정했을 때의 조건부 기댓값 차이로 해석
- ice cream 자료: 온도를 고정해도 3년차는 1년차보다 평균 소비가 0.0743 높음

🔗 다음 장: Summary: 여덟 장을 관통한 공식과 기호를 한자리에 모으고, 현장에서 사용할 실무 체크리스트로 정리

참고문헌

이 장에서 인용한 문헌

- ASTM E900-21e1. *Standard Guide for Predicting Radiation-Induced Transition Temperature Shift in Reactor Vessel Materials*. ASTM International.
- *Metals*, 12(3), 481 (2022). doi:10.3390/met12030481
- Kutner, M. H., et al. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill. (가변수 코딩)

교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.