

Regression Analysis

8. Summary | Special Lecture for KINS

Boncho Ku, Ph.D. in Statistics 

secondmoon@kiom.re.kr

Digital Health Research Division
Korea Institute of Oriental Medicine

2026-09-03

Summary

핵심 공식 정리: 적합의 뼈대

≡ 식 1에서 4까지

#	이름	식	의미
1	최소제곱 목적함수	$Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$	점과 직선 사이 세로 거리의 제곱합
2	최소제곱(OLS) 해	$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$	Q 를 가장 작게 만드는 계수
3	모자행렬	$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$	관측 $\mathbf{y}$ 를 적합값 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 로 보내는 직교사영
4	계수의 분산	$\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$	추정한 계수가 자료에 따라 흔들리는 정도

Core formulas for fitting a linear model

기호

- $\mathbf{X}$: 절편열을 포함한 $n \times (p + 1)$ 설계행렬
- σ^2 : 오차 ε_i 의 분산. 관측이 참값 주위에 흩어진 정도
- 4번 식의 대각원소에 제곱근을 취한 값이 각 계수의 **표준오차**

핵심 공식 정리: 평가와 확장

≡ 식 5에서 7까지

#	이름	식	의미
5	결정계수	$R^2 = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$	반응변수의 변동 중 모형이 설명한 비율
6	가중최소제곱(WLS) 해	$\hat{\beta}_W = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$	관측마다 다른 가중치 w_i 를 반영한 적합
7	AIC	$AIC = -2 \log \hat{L} + 2k$	적합도와 모수 개수의 절충을 한 값으로 비교 (Akaike, 1974)

Formulas for evaluating and extending the fitted model

기호

- $e_i = y_i - \hat{y}_i$: 잔차
- $\mathbf{W} = \text{diag}(w_1, \dots, w_n)$: 가중행렬. 오차분산이 큰 관측일수록 작은 w_i 를 부여
- $\hat{L}$: 최대가능도. 모형이 지금의 자료를 설명하는 그럴듯함의 최댓값
- k : 추정하는 모수의 개수. AIC는 값이 작을수록 선호

기호 정리

◎ 표기

기호는 각 장에서 정의한 것과 같다.

기호	뜻
$y_i, \hat{y}_i$	i 번째 관측의 반응변수와 적합값
x_i 또는 x_{ij}	i 번째 관측의 설명변수, $j = 1, \dots, p$
$\beta_0, \beta_1, \dots, \beta_p$	회귀계수, 모자를 쓰면 자료로 추정한 값
ε_i	오차, 분산은 σ^2
$e_i = y_i - \hat{y}_i$	잔차, 관측값과 적합값의 차이
$\mathbf{X}$	설계행렬, 절편열을 포함해 $n \times (p + 1)$
$\mathbf{W} = \text{diag}(w_1, \dots, w_n)$	가중치를 대각에 놓은 가중행렬
$\hat{L}, k$	최대가능도와 추정 모수의 개수
n, p	관측 수와 설명변수 개수

Notation used throughout the lecture

강의 구성 요약

≡ 정리

장	주제	핵심 결과
1	Introduction	회귀는 조건부 기댓값 $E(Y \mid X = x)$, 회귀분석 8단계
2	Preliminary Knowledge	공분산과 상관, 행렬 표현. ice 자료 $\text{cov} = 0.838, r = 0.776$
3	Simple Linear Regression	$\hat{y} = 0.207 + 0.00311 \text{ temp}$, $R^2 = 0.602 = r^2$
4	Multiple Linear Regression	full model $R^2 = 0.719$, adj. $R^2 = 0.686$
5	Diagnosis and Variable Selection	진단 4패널, 최대 Cook 거리 0.475. 최종 모형 $IC \sim \text{income} + \text{temp}$
6	Weighted Regression	물리 측정 자료 WLS $\hat{y} = 144.8 + 549.5x, R^2 = 0.929$
7	Dummy Variable	관측 연차 가변수 2개 투입, $R^2 = 0.790$, adj. $R^2 = 0.765$

Structure of the lecture and the main result of each chapter

실무 체크리스트: 1~4단계

✂ 자료를 만들기까지

단계	점검 항목	근거
1 문제의 진술	답하려는 질문을 한 문장으로 적을 것. 예측이 목적인지 효과 확인이 목적인지 먼저 정할 것	제1장
2 관련 변수의 선택	반응변수는 하나, 설명변수는 측정 가능하고 기록이 남는 것만 후보로	제1장
3 자료 수집	n 행 직사각형 표로 정리하고 단위와 결측을 먼저 확인할 것	제1장
4 모형 설정	적합하기 전에 산점도부터 그릴 것. 요약 수치가 같아도 자료 모양은 전혀 다를 수 있음	Anscombe (1973)

Practical checklist, steps 1 to 4 of regression analysis

실무 체크리스트: 5~8단계

✂ 적합에서 사용까지

단계	점검 항목	근거
5 적합 방법의 선택	관측마다 측정 불확도가 다르면 가중치 w_i 를 반영할 것 (가중회귀)	제6장
6 모형 적합	계수만 보지 말고 표준오차를 함께 볼 것	제3장, 제4장
7 모형 검증과 비판	진단 4패널을 확인하고, 변수선택으로 모형이 바뀌면 진단을 다시 할 것	Cook (1977), 제5장
8 선택된 모형의 사용	다중회귀 계수는 다른 설명변수를 고정했을 때의 효과로 읽을 것. 자료 범위 밖은 예측하지 말 것	제4장, 제7장

Practical checklist, steps 5 to 8 of regression analysis

참고문헌

📖 원전과 이름의 유래

- Galton, F. (1877, 1885, 1886). 완두콩 실험, regression 의 첫 등장, *Journal of the Anthropological Institute*, 15, 246-263.
- Pearson, K., & Lee, A. (1903). *Biometrika*, 2, 357-462.
- Gorroochurn, P. (2016). *The American Statistician*, 70(2), 227-231.
- Stanton, J. M. (2001). *Journal of Statistics Education*, 9(3).

🔗 방법론

- Akaike, H. (1974). *IEEE Trans. Automatic Control*, 19(6), 716-723.
- Anscombe, F. J. (1973). *The American Statistician*, 27(1), 17-21.
- Cook, R. D. (1977). *Technometrics*, 19(1), 15-18.
- Hoaglin, D. C., & Welsch, R. E. (1978). *The American Statistician*, 32(1), 17-22.

💡 현장 사례

- ASTM E900-21e1. ASTM International. / *Metals*, 12(3), 481 (2022).
- *Analytical Chemistry*, 91(7) (2019). / INMM Annual Meeting Proceedings.
- *Carcinogenesis* (2025). Life Span Study, 1958-2009.

📖 교과서

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill.
- Faraway, J. J. (2015). *Linear Models with R*, 2nd ed. CRC Press.