

회귀분석(Regression Analysis)

Sangin Lee

Department of Information and Statistics

Chungnam National University

제1장. 서론

1.1 통계분석을 시작하기 전에

- 통계분석 시 유의할 사항

- 데이터에 대한 배경과 문제에 대한 이해가 있어야 한다.
- 목적을 명확히 해야 한다.
- 문제를 통계적 용어로 표현할 수 있어야 한다.
- 다음을 포함한 데이터 수집 단계에 대한 정보가 필요하다.

관측 데이터(observational data) 또는 실험 데이터(experimental data) 여부
무응답(nonresponse) 또는 결측값(missing value)이 있는지

질적 변수(qualitative variable)는 어떻게 코딩되었는지
변수의 단위는 무엇인지

데이터 입력 오류 등 데이터에 대한 정확성

1.2 초기 데이터 분석

- 변수의 분포 또는 특성을 알려주는 통계량을 구하고 그래프 기법으로 표현
- 각 변수들의 분포, 이상점, 변수들 간의 상관성 등을 파악
- 구체적인 통계적 분석 전에 데이터에 대한 정리와 점검

(예제 1.1) 흑체리 나무 데이터에 대한 기초 데이터 분석(p2)

[1.1 기초통계량]

```
data(trees); attach(trees)
mean(trees)
sd(trees)
summary(trees)
```

```
## 예1.1 trees data
trees$Girth[trees$Girth==0]<-NA # 결측값처리
trees$Height[trees$Height==0]<-NA
trees$Volume[trees$Volume==0]<-NA
```

[1.2 분포 관련 그래프]

그림 1.1 상자그림

```
par(mfrow=c(1,3))
boxplot(trees$Girth, xlab="Girth")
boxplot(trees$Height, xlab="Height")
boxplot(trees$Volume, xlab="Volume")
```




그림 1.2 히스토그램

```
par(mfrow=x(1,3))
hist(trees$Girth, xlab="Girth")
hist(trees$Height, xlab="Height")
hist(trees$Volume, xlab="Volume")
```





그림 1.3 확률밀도함수그림




```
par(mfrow=c(1,3))
plot(density(trees$Girth), main="kernel density est for Girth")
plot(density(trees$Height), main="kernel density est for Height")
plot(density(trees$Volume), main="kernel density est for volume")
```




```
# 그림 1.4 Q-Q 그림
par(mfrow=c(1,3))
qqnorm(trees$Girth, main="Normal Q-Q plot for Girth")
qqline(trees$Girth)
qqnorm(trees$Height, main="Normal Q-Q plot for Height")
qqline(trees$Height)
qqnorm(trees$Volume, main="Normal Q-Q plot for volume")
qqline(trees$Volume)
```

```
# scatterplot matrix 그림 1.5 산점도 행렬
```

```
library(lattice)
splom(trees)
```





Scatter Plot Matrix

1.3 회귀분석을 하고자 할 경우

● 회귀분석

- 반응변수(response variable)와 설명변수(explanatory variable) 간의 관계를 설명하는 통계적 분석방법
- 반응변수=출력변수(output variable)=종속변수(dependent variable)
- 설명변수=입력변수(input variable)=독립변수(independent variable)
- 단순회귀분석(simple regression analysis) : 한 개의 종속변수와 한 개의 독립변수 사이의 관계를 분석하는 경우
- 다중회귀분석(multiple regression analysis) : 한 개의 종속변수와 여러 개의 독립변수 사이의 관계를 규명하는 경우

● 회귀분석의 목적

- 변수들 간의 관계에 대한 표현
- 설명변수에 따른 반응변수의 변화
- 미래 관측값에 대한 예측

● 회귀분석의 가정

- 1) 등분산성(homoscedasticity) : 오차항은 동일한 분산을 갖는다.
- 2) 독립성(independence of error) : 오차항 간에는 상관관계가 없다.
- 3) 정규성(normality) : 오차항의 평균은 0이며 분산은 σ^2 인 정규분포를 따른다.
- 4) 비다중공선성(nomulticollinearity) : 독립변수(설명변수)가 여러 개 있는 경우, 독립변수 상호 간에는 상관관계가 없다.

1.4 회귀분석 사례

(예제 1.2) 환자 혈압 수치와 콜레스테롤 수치와의 관계(p8)

환자번호	성별	나이	이완기 혈압	수축기 혈압	콜레스테롤
1	m	45	136	90	190
2	m	35	125	80	190
3	m	55	150	70	210
4	f	24	160	90	190
5	f	29	145	86	205
6	f	48	155	78	210
7	f	39	170	75	200
8	m	42	145	90	220
9	m	50	136	90	230
10	m	49	140	98	190
11	m	39	125	100	200
12	f	42	140	89	220
13	f	48	142	86	250
14	f	49	139	80	230
15	f	51	142	80	211

(예제 1.3) 고등학교 성적과 대학입학을 위한 수학능력시험 성적 간의 관계 연구 및 예측

- (1) A대학에서 각 신입생에 대해 주요 5개 과목에 대한 고등학교 성적과 수학능력시험 성적을 조사하였다. 수학능력시험성적을 반응변수로 하여 회귀분석으로 관계식을 구함으로써 고등학생의 수학능력시험을 예측할 수 있다.
- (2) <표 1.2>는 미국 대학입학시험 SAT 점수 데이터로 변수의 의미는 다음과 같다.

female = 1 if the respondent is female (=0 otherwise)

rdsc = scaled reading score (mean=50, std. dev=10)

vocab = scaled vocabulary score

matssc = scaled mathematics score

이 자료로부터 reading 점수와 math 점수간의 관계식을 구할 수 있음.

<표 1.2> 미국 대학입학시험 SAT 점수 --> 교재 p9

(예제 1.4) 대기오염과 사망률과의 관계(p8)

서울의 23개 지역에서 30분마다 기상환경 데이터와 함께 대기오염물질인 오존과 pm10 등이 측정되고 매일 서울의 사망자수도 조사된다. 오존과 사망률 간의 관계식을 회귀분석으로 구할 수 있다. <표1.3>은 1999년 1월에 기록된 데이터로 측정된 변수는 다음과 같다.

<표1.3> 1999년 1월 서울의 기상과 사망률 데이터 -> 교재 p10

(예제 1.5) 경제 지표 변수들 간의 관계

(1) 한국 주식시장의 주가(KOSDAQ) 변화율에 따른 주식거래량과의 관계식을 회귀분석으로 구할 수 있으며 구한 추정식을 통해 주식 거래량을 예측할 수 있다.

(2) 설명변수로서 노동 투입량과 자본 투입량에 대해 반응변수로서 GDP(국민총생산)와의 관계식을 회귀분석으로 구할 수 있으며 구한 추정식을 통해 GDP를 예측할 수 있다.

(3) <표 1.4>는 미국의 1945년부터 2002년까지 GDP 관련 데이터이다. GDP와 여러 관련 변수들과의 회귀분석으로 관계식을 구하고 다음 해에 대한 예측을 할 수 있다.

<표 1.4> 미국 연간 GDP 데이터 -> 교재 p11

1.5 회귀분석과 통계소프트웨어 R

- R 시스템은 데이터 분석과 그래프 작업에 매우 편리한 소프트웨어
- 다양한 패키지를 제공

1.6 R에서 데이터셋 다루기

1.6.1 데이터 프레임 생성

- mydata 생성

```
mydata <- data.frame(one=1:10, two=11:20, three=21:30)
mydata
```

- as.data.frame() 함수 이용

```
mydata <- as.data.frame(matrix(1:30, ncol=3))
names(mydata) <- c("one", "two", "three")
```

- 데이터프레임이름\$변수이름 : 일부 벡터나 행렬을 추출

```
> mydata$one
[1] 1 2 3 4 5 6 7 8 9 10
> mydata[, "one"]
[1] 1 2 3 4 5 6 7 8 9 10
> mydata[, 1]
[1] 1 2 3 4 5 6 7 8 9 10
> mydata[, c(1,3)]
  one three
1    1    21
2    2    22
3    3    23
4    4    24
5    5    25
6    6    26
7    7    27
8    8    28
9    9    29
10   10    30
```

- attach() 함수

```
> attach(mydata)
> mean(one)
[1] 5.5
> detach(mydata)
> with(mydata, mean(one))
[1] 5.5
```

1.6.2 데이터 입출력

```
write.table(mydata[,1], file="D://mydata.txt", col.names=TRUE)
my1 <- read.table("D://mydata.txt", header=TRUE)
```

```
write.table(mydata, file="D://my2.csv", sep=",")
my2 <- read.table("D://my2.csv", header=TRUE)
```

```
write.csv(mydata, file="D://my3.csv")
my3 <- read.table("D://my3.csv", header=TRUE)
```

```
# R binary data 로 저장
save(my, file="my3.rda")
load("my3.rda")
```

1.6.3 범주형 데이터

```
g <- rep(0:1, c(3,4))  
g  
g<-factor  
summary(g)
```

1.6.4 연속형 데이터

```
x <- c(1,2,3,4,5,6,7,8,9,10)  
mean(x)  
summary(x)
```