


제3장. 단순선형회귀분석

3.1 이변량 데이터와 산점도

- 산점도(scatterplot 또는 scatter diagram) : n 개 쌍의 관측값이 주어진 경우 각 개체에 대한 관측값이 2차원 공간에서의 한 점으로 표현되는 그래프

[프로그램 3.1] cars 데이터에 대한 속도와 거리 산점도

```
data(cars)
cars
attach(cars)
plot(speed, dist)
```



3.2 이변량 데이터와 상관계수

3.2.1 표본상관계수

- 상관계수

$$\rho = cor(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X) Var(Y)}}$$

- 피어슨 상관계수

$$r = \widehat{cor}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{s_X} \right) \left(\frac{Y_i - \bar{Y}}{s_Y} \right)$$


$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$


$$s_X = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$s_Y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2}$$


- 상관계수의 범위는 $-1 \leq \rho \leq 1$ 이고, 이에 대한 추정량도 $-1 \leq r \leq 1$ 이다.




(a)



(b)



(c)



(d)

■ 통계적 가설검정

$H_0 : \rho = 0$ (두 변수 간의 상관계수가 0이다.)


$H_1 : \rho \neq 0$ (두 변수 간의 상관계수가 0이 아니다.)

- 검정통계량 : $T = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim {}^{H_0}t(n-2)$
- 검정방법: $|T| \geq t_{n-2}(\alpha/2)$ 이면 귀무가설을 기각한다.

[프로그램 3.2] 상관계수의 상관성 검정

```
data(cars)
cars
attach(cars)
cor(speed, dist)
cor.test(speed, dist)
```

3.2.2 표본상관계수 해석시의 유의점



3.3 단순선형회귀모형

- 한 개의 설명변수(독립변수) X 와 한 개의 반응변수(종속변수) Y 간의 선형관계식을 구하고자 할 때 일차 선형모형(linear model) $Y = \beta_0 + \beta_1 X + \epsilon$
- 이변량 관측벡터 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 에 대해 단순선형회귀모형(simple linear regression model)은 $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, i = 1, \dots, n.$
- β_0 : 절편(intercept)
 β_1 : 기울기(slope)
 오차항 $\epsilon_i \sim iid N(0, \sigma^2)$ 을 가정
- 벡터와 행렬을 이용해 $Y = X\beta + \epsilon$ 로 표현

● 일반적인 회귀분석 단계

- (1) 산점도를 그려 변수 간의 관계를 살펴보고 예측한다.
- (2) 회귀모형 설정 및 모수추정: 최소제곱법 등을 이용하여 모형에 포함된 모수를 추정한다.
- (3) 회귀계수에 대한 유의성 검정: 각 회귀계수의 유의성을 검정한다.
- (4) 모형 적합도: R^2 (결정계수), $R^{2_{adj}}$ (수정된 결정계수) 등 여러 가지 통계량들을 이용하여 모형의 적합성에 대해 판단한다.
- (5) 모형 진단: 추정한 모형의 적합도를 진단하여 적절한 모형여부를 판단하게 된다. 잔차그림을 통해 독립성, 등분산성을 검토하고 Q-Q 그림 등을 통해 정규성에 대해 알아본다.

3.4 모수추정

- 분석하고자 하는 회귀모형을 결정한 후에는 모형에 포함된 모수를 추정해야 한다.

3.4.1 최소제곱법을 이용한 모수추정

- 표본 데이터로부터 회귀계수를 추정하는 방법 중 가장 널리 이용되는 방법은 오차제곱합을 최소화하는 최소제곱법(least squares method)이다.

$$S = S(\beta_0, \beta_1) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

을 구하고 $S(\beta_0, \beta_1)$ 를 최소화하도록 회귀계수에 대한 최소제곱추정량 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 을 구하면 정리 3.1을 얻는다.

[정리 3.1]

단순선형회귀모형 (3.8)에서 회귀계수 $\hat{\beta}_0$ 과 $\hat{\beta}_1$ 의 최소제곱추정량은

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{YY}} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sum_{i=1}^n X_i^2 - n\bar{X}^2}$$

$$\beta_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

여기서,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i,$$

$$S_{XX} = \sum_{i=1}^n (X_i - \bar{X})^2 \quad S_{YY} = \sum_{i=1}^n (Y_i - \bar{Y})^2 \quad S_{XY} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

회귀모형에 의한 추정식은 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 X$

[증명]

$$S = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

$$\frac{\delta S}{\delta \beta_0} = -2 \sum (Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\frac{\delta S}{\delta \beta_1} = -2 \sum X_i (Y_i - \beta_0 - \beta_1 X_i) = 0$$

정리하면,

$$\beta_0 n + \beta_1 \sum X_i = \sum Y_i$$

$$\beta_0 \sum X_i + \beta_1 \sum X_i^2 = \sum X_i Y_i$$

이를 정규방정식(normal equation)이라 한다.

$$G = \begin{pmatrix} \frac{\partial^2 S}{\partial \beta_0^2} & \frac{\partial^2 S}{\partial \beta_0 \partial \beta_1} \\ \frac{\partial^2 S}{\partial \beta_1 \partial \beta_0} & \frac{\partial^2 S}{\partial \beta_1^2} \end{pmatrix} \text{가 양정치행렬이면 정규방정식의 해가 } S \text{를 최소화한다.}$$

$$\frac{\partial^2 S}{\partial \beta_0^2} > 0, |G| > 0$$

$$\frac{\partial^2 S}{\partial \beta_0^2} = 2n > 0, |G| = \begin{vmatrix} 2n & 2\sum X_i \\ 2\sum X_i & 2\sum X_i^2 \end{vmatrix} = 4n \sum (X_i - \bar{X})^2 > 0$$

정규방정식 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 에 대해 풀면 최소제곱추정량

$$\hat{\beta}_1 = \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{\sum X_i^2 - (\sum X_i)^2} = \frac{\sum X_i Y_i - n \bar{X} \bar{Y}}{\sum X_i^2 - n \bar{X}^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{S_{XY}}{S_{XX}}$$

$$\begin{aligned}
 \hat{\beta}_0 &= \frac{\sum Y_i \sum X_i^2 - \sum X_i \sum X_i Y_i}{n \sum X_i^2 - (\sum X_i)^2} = \frac{\bar{Y} \sum X_i^2 - \bar{X} \sum X_i Y_i}{\sum X_i^2 - n \bar{X}^2} = \frac{\bar{Y} (\sum X_i^2 - n \bar{X}^2) - \bar{X} \sum X_i Y_i + n \bar{X} \bar{Y}}{\sum X_i^2 - n \bar{X}^2} \\
 &= \bar{Y} - \bar{X} \frac{S_{XY}}{S_{XX}} = \bar{Y} - \hat{\beta}_1 \bar{X}
 \end{aligned}$$

- (잔차 자유도) = (관측 개체수) - (모형에서 모수의 수)

3.4.2 정규성 가정의 경우 우도함수를 이용한 모수추정

- 오차항이 정규분포를 따른다고 가정할 수 있다면 오차항에 대한 우도함수를 구할 수 있으므로 우도함수를 이용한 추론을 할 수 있다.
- 이변량 데이터에 대한 결합우도함수(joint likelihood)는

$$\begin{aligned}
 L(Y_1, \dots, Y_n | \beta_0, \beta_1, \sigma^2, X_1, \dots, X_n) &= \prod_{i=1}^n P(Y_i | \beta_0, \beta_1, \sigma^2, X_i) \\
 &= \prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2\right\}
 \end{aligned}$$

$$\widehat{\sigma}_{ML}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \widehat{\beta}_0 - \widehat{\beta}_1 X_i)^2$$

3.4.3 추정량의 성질

[정리3.2] 가우스-마코프 정리(Gauss-Markov Theorem)

- 선형회귀모형에서 오차항의 기댓값이 0이고 서로 독립이며 등분산인 경우, 회귀계수에 대한 최적선형불편추정량(best linear unbiased estimator : BLUE)은 최소제곱추정량이다.

(증명) 4장 정리 4.2 다중 선형회귀모형에 대한 증명 참조

$$E(\hat{\beta}_0) = \beta_0$$

$$E(\hat{\beta}_1) = \beta_1$$

최소제곱추정량 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 의 분산은 다음과 같다.

$$Var(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\overline{X^2}}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

또한

$$E(\hat{\sigma}^2) = \sigma^2 \text{ 이 성립.}$$

$$\widehat{Var}(\hat{\beta}_0) = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\overline{X^2}}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

$$\widehat{Var}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

회귀계수의 표준오차(standard error)는

$$se(\hat{\beta}_0) = \sqrt{\widehat{Var}(\hat{\beta}_0)}$$

$$se(\hat{\beta}_1) = \sqrt{\widehat{Var}(\hat{\beta}_1)}$$

3.5 모형에 대한 적합도 검정

1. 결정계수 : 회귀모형의 적합도에 대한 측도

설명변수 X_i 에서 반응추정값 $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, $i = 1, 2, \dots, n$

오차의 추정값 = 잔차 = $e_i = Y_i - \hat{Y}_i$, $i = 1, 2, \dots, n$

- 총변동 = 회귀모형에 의한 변동 + 오차에 의한 변동

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

(TSS(전체제곱합) = SSR(회귀제곱합) + SSE(잔차제곱합))

$$\text{결정계수 } R^2 = \frac{SSR}{TSS} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} \quad (0 \leq R^2 \leq 1)$$

즉, 전체 변동 중 추정된 회귀식에 의해 설명되는 비율이며,

R^2 값이 클수록 추정된 회귀식의 설명력이 높다.

<단순회귀모형 분산분석표>

	SS	DF	MS	F	유의확률
Model	SSR	1	$SSR/1$	$F_0 = MSR/MSE$	$F_{1,n-2}(\alpha)$
Error	SSE	$n-2$	$SSE/(n-2)$		
Total	TSS	$n-1$			

모형의 유의성에 대한 가설 검정에서

$$H_0 : Y = \beta_0 + \epsilon \quad H_1 : Y = \beta_0 + \beta_1 X + \epsilon$$

검정통계량은

$$F_0 = MSR/MSE, \quad F_0 \geq F_{1,n-2}(\alpha) \text{이면 } H_0 \text{를 기각한다.}$$

2. 회귀계수에 대한 검정

- 절편 회귀계수에 대한 유의성 검정 (t-검정)

$$H_0 : \beta_0 = \beta_0^* \quad H_1 : \beta_0 \neq \beta_0^* \quad (\beta_0^* \text{은 특정하게 주어진 값})$$

검정통계량

$$t = \frac{\hat{\beta}_0 - \beta_0^*}{[Var(\hat{\beta}_0)]^{1/2}} = \frac{\hat{\beta}_0 - \beta_0^*}{\left[MSE \left(\frac{1}{n} + \frac{\bar{X}^2}{(n-1) \sum_{i=1}^n (X_i - \bar{X})^2} \right) \right]} \sim t(n-2)$$

$|t| \geq t_{n-2}(\alpha/2)$ 이면 H_0 를 기각한다.

- 기울기 회귀계수에 대한 유의성 검정 (t-검정)

$$H_0 : \beta_1 = \beta_1^* \quad H_1 : \beta_1 \neq \beta_1^* \quad (\beta_1^* \text{은 특정하게 주어진 값})$$

검정통계량

$$t = \frac{\hat{\beta}_1 - \beta_1^*}{[Var(\hat{\beta}_1)]^{1/2}} = \frac{\hat{\beta}_1 - \beta_1^*}{\left[\frac{MSE}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]} \sim {}^{H_0} t_{(n-2)}$$

$|t| \geq t_{n-2}(\alpha/2)$ 이면 H_0 를 기각한다.

3. 회귀계수에 대한 신뢰구간과 예측구간

1) β_j 에 대한 $100(1-\alpha)\%$ 신뢰구간

$$\hat{\beta}_j \pm t_{n-2}(\alpha/2) \sqrt{\widehat{Var}(\hat{\beta}_j)}, \quad j = 0, 1$$

2) 새로운 설명변수 값(X_*)에 대한 반응변수 값(Y_*) 예측

$$\widetilde{Y}_* = \hat{\beta}_0 + \hat{\beta}_1 X_*$$

분산은 $\hat{\beta}_0$ 과 $\hat{\beta}_1$ 의 추정값에서의 변동과 Y_* 가 $E(Y_*)$ 와 일치하지 않는데 기인한 변동

$$\begin{aligned} E[(\widetilde{Y}_* - Y_*)^2] &= E\{[\widetilde{Y}_* - E(Y_*)] - [Y_* - E(Y_*)]\}^2 \\ &= E[\widetilde{Y}_* - E(Y_*)]^2 + E[Y_* - E(Y_*)]^2 - 2E[\widetilde{Y}_* - E(Y_*)][Y_* - E(Y_*)] \\ &= Var(\hat{Y}) + \sigma^2 \end{aligned}$$

미래 예측값에 대한 분산을 구하면

$$Var(\widetilde{Y}_*|X_*) = \sigma^2 + \sigma^2 \left(\frac{1}{n} + \frac{(X_* - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right) \quad \text{이므로}$$

분산추정량은

$$\widehat{Var}(\widetilde{Y}_*|X_*) = \widehat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(X_* - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right).$$

* 모형추정에 사용한 X 의 범위에서 Y 에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\widehat{\beta}_0 + \widehat{\beta}_1 X \pm F_{1, n-2}^{1/2}(\alpha) \sqrt{\widehat{\sigma}^2 \left(\frac{1}{n} + \frac{(X - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)}$$

3.6 잔차분석

- 선형회귀모형에서 사용되는 가정들

1) 선형성 : 입력변수와 출력변수간의 관계가 선형적

잔차산점도를 그렸을 때, 잔차들이 0을 중심으로 랜덤하게 나타나야 한다.

2) 등분산성 : 오차의 분산이 입력변수와 무관하게 일정

$$\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = 0 \quad (\text{잔차 합은 0이다.})$$

$$\text{단순선형회귀모형에서 잔차의 분산} \quad S^2 = \frac{1}{n-2} \sum_{i=1}^n e_i^2$$

3) 독립성 : 오차들이 서로 독립

Durbin-Watson 으로 가설 검정

$$H_0 : \rho = 0 \quad H_1 : \rho \neq 0$$

검정통계량

$$d = \frac{\sum_{i=1}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}$$

$d < d_L$ 이면 H_0 를 기각하고, $d > d_U$ 이면 H_0 를 기각하지 못한다.

만약 $d_L < d < d_U$ 이면 H_0 기각여부를 결정하지 못한다.

여기서 d_L, d_U 는 설명변수 k 에 의존하여 결정된다.

4) 정규성 : 오차의 분포가 정규분포

정규 Q-Q Plot 을 그려 확인 가능.

먼저, n 개의 확률표본 $U_1, U_2, \dots, U_n$ 에 대하여 $U_{(1)} \leq U_{(2)} \leq \dots \leq U_{(n)}$ 순서통계량 정의
 $(U_{(i)}, \frac{i-0.5}{n})$ 의 그림은 경험분포함수를 나타냄.

$$q_{(i)} \text{는 } i\text{번째 사분위수 일 때, } P[Z \leq q_{(i)}] = \int_{-\infty}^{q_{(i)}} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz = p_{(i)}$$

Q-Q 그림은 $(q_{(i)}, X_{(i)})$ 을 2차원 평면에 나타낸 것이다.

따라서, 경험분포와 이론적 분포가 일치하면 선형관계를 갖는 것으로 판단.

잔차의 정규성 검정 : Shapiro-Wilks 검정

H_0 : 관측 데이터는 정규분포를 따른다.

H_1 : 관측 데이터는 정규분포를 따르지 않는다.

검정통계량 : 값이 작을수록 귀무가설 기각.

$$W = \frac{(\sum_{i=1}^n a_i e_{(i)})^2}{\sum_{i=1}^n (e_i - \bar{e}_i)^2}$$

여기서 $e_{(i)}$ 는 $\{e_1, \dots, e_n\}$ 를 순서대로 재배열한 잔차 순서통계량

a_i 는 표본의 크기가 n 인 정규분포 표본으로부터의 순서통계량이 고려된 상수

$$(a_1, \dots, a_n) = \frac{m' V^{-1}}{m' V^{-1} V^{-1} m},$$

$m_1, \dots, m_n$ 은 표준정규분포에서 나온 표본에 대한 순서통계량의 기댓값이고,

V 는 이러한 순서통계량의 공분산 행렬.

3.7 R 활용 단순선형회귀분석

[예제3.1] 이변량 데이터 (x, y) 를 포함한 벡터 x, y 가 다음과 같을 때, 회귀분석을 해 보자.

x	1.9	0.8	1.1	0.1	-0.1	4.4	4.6	1.6	5.5	3.4
y	0.7	-1.0	-0.2	-1.2	-0.1	3.4	0.0	0.8	3.7	2.0

[예제3.2] 책의 부피(설명변수)와 무게(반응변수)에 대해 회귀분석을 하고자 한다.

$$Y = \beta_0 + \beta_1 X + \epsilon, \quad \epsilon \sim iid N(0, \sigma^2)$$

x(부피)	412	953	929	1492	419	1010	595	1034
y(무게)	250	700	650	975	350	950	425	725

[예제3.3] 예제3.2 데이터를 이용하여 회귀계수에 대해 0이 아닌 특정한 회귀계수값에 대한 검정으로 다음의 가설에 대한 검정을 해보자.

$$H_0 : \beta_1 = 1 \quad H_1 : \beta_1 \neq 1$$

[예제3.4] 예제3.2 데이터에 대해서 원점을 지나는 회귀직선을 구하고자 한다.

$$Y = \beta X + \epsilon, \quad \epsilon \sim iid N(0, \sigma^2)$$