

제5장. 회귀진단 및 보정

회귀진단(regression diagnostics)

- 넓은 의미: 적합된 회귀직선의 전반적인 검토. 모형검토(model checking)라고도 함

- (1) 선형성
- (2) 오차항의 분포
- (3) 다중공선성
- (4) 영향력 관측치 탐색

- 좁은 의미: 영향력 관측치 탐색
⇒ 잔차와 지레값(leverage values)을 사용

5.1 모자행렬과 지렛대

n 개 개체를 포함한 데이터에 대해 다음의 회귀모형에 대한 잔차분석을 고려해 보자.

$$Y = X\beta + \epsilon, \quad \text{Var}(\epsilon) = \sigma^2 I$$

- 오차벡터 ϵ 는 등분산을 가지며 서로 독립인 확률변수라고 가정.

- 적합한 모형에 의한 반응추정벡터 $\hat{Y}$ 의 표현

$$\hat{Y} = X\hat{\beta} = (X'X)^{-1}X'Y = HY$$

- 모자행렬(hat matrix) H 의 정의

$$H = X(X'X)^{-1}X'$$

모자행렬 H 는 반응벡터 Y 를 적합된 반응벡터 $\hat{Y}$ 으로 변환하는 행렬.

- 잔차벡터 $e = (e_1, \dots, e_n)'$ 표현

$$\begin{aligned}
 e &= Y - \widehat{Y} \\
 &= Y - X(X'X)^{-1}X'Y \\
 &= [I - X(X'X)^{-1}X']Y \\
 &= [I - H]Y
 \end{aligned}$$

- 1) 잔차벡터 e 의 기댓값과 분산

$$E[e] = 0, \quad Var[e] = \sigma^2(I - H)$$

- 2) i 번째 개체에 대한 잔차 e_i 에 대한 기댓값과 분산

$$E[e_i] = 0, \quad Var[e_i] = \sigma^2(1 - h_{ii}), \quad i = 1, 2, \dots, n$$

☞ 지렛대(leverage): 모자행렬의 대각원소 h_{ii} 는 H 행렬의 i 번째 대각선의 원소

- 3) $cov(e_i, e_j) = -h_{ij}\sigma^2 \quad (i \neq j)$

$$4) \quad corr(e_i, e_j) = -\frac{h_{ij}}{\sqrt{1-h_{ii}}\sqrt{1-h_{jj}}}$$

- 잔차들은 척도무관(scale invariant)한 값이 아님. 표준화 잔차를 고려해야함(5.2절).

회귀진단은 잔차를 통해 이루어지며 모자행렬 H 는 e 의 공분산행렬에 대한 정보를 담고 있으므로 모자행렬 H 를 활용한 회귀진단이 가능.

■ 모자행렬 H 는 $n \times n$ 대칭행렬로 다음의 특성을 갖는다.

(i) $HX = X$ 이므로 $(I - H)X = 0$

(ii) $HH = H$ 이므로 $Cov(\hat{Y}, e) = H(I - H)\sigma^2 = 0$

즉, H 는 X 의 열 공간(column space)에 직교투영(orthogonal projection) 역할을 한다.

(iii) H 의 (i, j) 번째 성분 h_{ij} 는 $h_{ij} = x_i'(X'X)^{-1}x_j = x_j'(X'X)^{-1}x_i = h_{ji}$ 이며,

i 번째 대각선 성분은 $h_{ii} = x_i'(X'X)^{-1}x_i$ 이다. $0 \leq h_{ii} \leq 1$ 을 만족한다.

(iv) $\sum_{i=1}^n h_{ii} = tr(H) = k + 1$ 이고, $\sum_{i=1}^n h_{ij} = \sum_{j=1}^n h_{ij} = 1$ (증명생략!! Try them~!!)

(v) h_{ii} 가 1에 가까울수록 $\hat{Y}_i$ 은 Y_i 로 가까워진다. $i = 1, 2, \dots, n$

$$(vi) \quad h_{ii} = \frac{1}{n} + (X_i - \bar{X})'(X_c' X_c)^{-1}(X_i - \bar{X}), \quad i = 1, 2, \dots, n \quad (\text{증명 생략!!})$$

여기서 X_i' 는 절편이 제거된 X 에서 i 번째 행벡터, $j = (1, \dots, 1)'$ 는 일벡터, 그리고 $X_c = X - j\bar{X}'$ 를 나타내며 평균벡터로 수정된 행렬

$$X_c = \begin{pmatrix} X_{11} - \bar{X}_1 & X_{12} - \bar{X}_2 & \cdots & X_{1k} - \bar{X}_k \\ X_{21} - \bar{X}_1 & X_{22} - \bar{X}_2 & \cdots & X_{2k} - \bar{X}_k \\ \vdots & \cdots & \cdots & \vdots \\ X_{n1} - \bar{X}_1 & X_{n2} - \bar{X}_2 & \cdots & X_{nk} - \bar{X}_k \end{pmatrix}$$

이고, $\bar{X} = (\bar{X}_1, \bar{X}_2, \dots, \bar{X}_k)'$ 는 변수들의 평균벡터이다.

- 식 (vi) 오른쪽 항을 보면 $\bar{X}$ 를 중심으로 타원체를 형성
- h_{ii} 값이 크면 i 번째 관측값이 전체 X 관측값의 중심에서 멀리 있다는 것을 의미
- 지렛대 값이 클수록 $Var(e_i)$ 가 작아지며 추정값 $\hat{Y}_i$ 은 관측값 Y_i 로 가까워짐.
- h_{ii} 의 평균은 $\frac{1}{n} \sum_{i=1}^n h_{ii} = \frac{k+1}{n}$ 이다.

- 일반적으로 $\frac{2(k+1)}{n}$ 보다 큰 경우 관찰해야 할 필요가 있음.
- 지렛대값이 매우 큰 경우는 반응변수 Y 와는 관계없이 설명변수 X_i 가 극단적으로 매우 큰 경우임.
- 지렛대값이 매우 큰 경우를 **지렛대점(leverage point)**이라고 한다.

참고 단순회귀모형 $Y_i = \beta_0 + \beta_1 X_{i1} + e_i$, $i = 1, 2, \dots, n$ 에서 모자행렬 H 를 구해보자.

$$\begin{aligned}
 h_{ij} &= x_i' (X'X)^{-1} x_j \\
 &= (1 \ X_{i1}) \begin{pmatrix} \frac{\sum_t X_{t1}^2}{nS_{XX}} & \frac{-\overline{X_1}}{S_{XX}} \\ \frac{-\overline{X_1}}{S_{XX}} & \frac{1}{S_{XX}} \end{pmatrix} \begin{pmatrix} 1 \\ X_{j1} \end{pmatrix} \\
 &= \frac{1}{n} + \frac{(X_{i1} - \overline{X_1})(X_{j1} - \overline{X_1})}{S_{XX}}
 \end{aligned}$$

이고, 대각선상에서의 값을 구하면 $h_{ii} = \frac{1}{n} + \frac{(X_{i1} - \overline{X_1})^2}{S_{XX}}$ 이다.

- $X_{i1} = \overline{X_1}$ 일 때 h_{ii} 의 최소값을 가짐
- $\overline{X_1}$ 로부터 멀어질수록 h_{ii} 값이 증가함.

5.2 스튜던트화 잔차(studentized residual)

- e_i 의 평균과 분산이 $(1 - h_{ii})\sigma^2$ 이므로, e_i 를 다음과 같이 표준화 할 수 있음.
- 스튜던트화 잔차(studentized residual) 정의

$$r_i = \frac{e_i - 0}{\sqrt{\text{var}(e_i)}} = \frac{e_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}$$


스튜던트화 잔차에 대한 기댓값은 $E(r_i) = 0$, $i = 1, 2, \dots, n$ 이지만 $\sum_{i=1}^n r_i \neq 0$ 이다.

- 스튜던트화 잔차를 이용하여, 오차항에 대한 가정을 검토할 수 있음.
 - 스튜던트화 잔차가 -2에서 2사이에 있고, 아무런 패턴이 없고, 퍼점 정도가 일정하면 보통 오차항의 가정을 만족한다고 생각

※ 스튜던트화 잔차는 정규분포를 따르지 않지만, 정규분포를 따른다고 생각하여 잔차분석

5.3 영향점

- 영향점(influential point) : 어떤 특정 관측값이 있을 때와 그것을 제외했을 때, 적합된 회귀함수에 큰 차이가 생기는 경우



(예제) 한 개의 영향점이 추정직선의 기울기의 부호를 바꾸는데 큰 영향을 미칠 수 있음

- $\hat{\beta}_{(i)}$ 은 i 번째 관측을 제외한 후 추정한 회귀계수벡터

$$\hat{\beta}_{(i)} = (X_{(i)}' X_{(i)})^{-1} X_{(i)}' Y_{(i)} ,$$

- $X_{(i)}$ 는 X 에서 i 번째 행을 제외한 $(n-1) \times (k+1)$ 행렬

5.3.1 쿡의 거리

- $\hat{\beta}$ 과 $\hat{\beta}_{(i)}$ 를 비교하는 통계량은 i 번째 관측의 영향력에 대한 측도로 이용
- 쿡의 거리(Cook's distance)

$$D_i = \frac{(\hat{\beta}_{(i)} - \hat{\beta})'(X'X)(\hat{\beta}_{(i)} - \hat{\beta})}{(k+1)\hat{\sigma}^2}$$

- Cook의 거리로 i 번째 관측이 n 개의 적합값 전체에 미치는 영향의 크기를 측정
- $\hat{Y} = X\hat{\beta}$ 이고 $\hat{Y}_{(i)} = X\hat{\beta}_{(i)}$ 일 때 i 번째 관측값에 대한 Cook의 거리

$$D_i = \frac{(\hat{Y}_{(i)} - \hat{Y})'(\hat{Y}_{(i)} - \hat{Y})}{(k+1)\hat{\sigma}^2}$$

- D_i 값이 큰 경우는 i 번째 관측이 모형적합에 영향을 주는 것으로 판단
- 이렇게 영향력이 있는 경우의 관측을 제외하면 모형에 변화가 생긴다.

- D_i 의 스튜던트화 잔차와 h_{ii} 를 이용한 표현

$$D_i = \frac{r_i^2 h_{ii}}{(k+1)\hat{\sigma}^2(1-h_{ii})^2}$$

- D_i 는 스튜던트화 잔차 r_i 의 크기와 지렛대값 h_{ii} 에 의해 영향을 받음.

즉, r_i 나 h_{ii} 가 클수록 D_i 가 커진다.

- * Cook의 거리 측도 D_i 에 대한 영향력 정도를 $F_{k+1, n-k-1}$ 분포에서와 대응하는 백분위수값을 이용하여 다음과 같이 해석가능.

1) 백분위수값이 10%나 20%보다 작으면 i 번째 관측은 적합값에 별로 영향이 없다.

2) 백분위수가 50% 부근이거나 더 크면 i 번째 관측을 포함하고 얻은 적합값과 포함하지 않고 얻은 적합값은 상당히 다르다고 간주되어 적합에 영향을 미침을 의미.

만일 $D_i > F_{k+1, n-k-1}(0.5)$ 이면 i 번째 관측은 영향이 큰 관측값으로 간주.

3) $D_i > 3.67 / (n-k-1)$ (Kim and Storer, 1996)

5.3.2 DFFITS(Difference in Standardized Fits)

- DFFITS 통계량

$$(DFFITS_i)^2 = \frac{(\hat{\beta}_{(i)} - \hat{\beta})'(X'X)(\hat{\beta}_{(i)} - \hat{\beta})}{(k+1)\widehat{\sigma}_{(i)}^2}$$

- $\widehat{\sigma}_{(i)}^2$ 은 i 번째 관측을 제외한 분산추정량

- 스튜던트화 제외 잔차와 h_{ii} 를 이용해 표현

$$DFFITS_i = r_{(i)} \left(\frac{h_{ii}}{(1 - h_{ii})} \right)^{1/2}$$

- $r_{(i)}$ 는 스튜던트화 제외잔차

$$r_{(i)} = \frac{\hat{e}_i}{\hat{\sigma}_{(i)} \sqrt{1 - h_{ii}}}$$

- DFFITS의 절대값이 $2\sqrt{(k+1)/n}$ 보다 클 때 영향점이라고 판단
- DFFITS 측도를 이용해 i 번째 관측이 그것의 적합값 $\hat{Y}_i$ 에 얼마나 영향을 미치는가를 확인

5.3.3 추가변수그림

- 단순선형회귀분석에서는 Y 와 X 간의 관계를 산점으로 표현
- 다중회귀분석 상황에서 반응변수 Y 와 설명변수 X_i 만의 관계는 나머지 설명변수 $X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_k$ 가 반영된 상황을 보여주지 못함.
- 이러한 경우, 추가변수그림(added variable plot)으로 X_i 를 제외한 다른 설명변수들이 반영된 상황을 나타낼 수 있다.

추가변수그림 그리는 단계

- (1) 반응변수 Y 에 대해 X_i 를 제외한 나머지 설명변수들과 회귀식을 구하여 잔차 $e_Y(X_i)$ 를 구한다.
 - (2) X_i 를 반응변수로 놓고 X_i 를 제외한 나머지 설명변수들과 회귀식을 구해 잔차 $e_{X_i}(X_i)$ 를 구한다.
 - (3) Y 와 나머지 변수들이 조정된 후의 X_i 와의 관계는 $e_Y(X_i)$ 과 $e_{X_i}(X_i)$ 의 관계로 나타낼 수 있게 된다.
 - (4) $(e_{X_i}(X_i), e_Y(X_i))$ 로 점을 찍어 나타낸 그림을 추가변수 그림이라 한다.
- 추가변수그림에서 강력한 선형관계를 보인다면 Y 와 X_i 에 대해 나머지 설명변수들로 조정된 후 관계가 강하다고 할 수 있음.

5.4 이상점

• 이상점 검정

(1) i 번째 관측을 제외한 데이터, 즉 $n-1$ 개 경우로만 선형모형을 적합:

- 회귀계수벡터를 $\widehat{\beta}_{(i)}$, 분산추정량을 $\hat{\sigma}_{(i)}^2$, 여기에서, $\hat{\sigma}_{(i)}^2$ 는 자유도 $n-1-(k+1)=n-k-2$

(2) 제거된 데이터에 대해 (1)에서 적합한 모형으로 추정을 하여 $\widetilde{Y}_{(i)} = x_i' \widehat{\beta}_{(i)}$ 를 구함.

- i 번째 관측은 (1) 모형적합 시 제외되었으므로 Y_i 와 $\widetilde{Y}_i$ 는 서로 독립이고
- $Var(Y_i - \widetilde{Y}_i) = \sigma^2 [1 + x_i' (X_{(i)}' X_{(i)})^{-1} x_i]$

(3) Y_i 가 이상점이 아니라면 $E(Y_i - \widetilde{Y}_i) = 0$ 이 된다. 오차항이 정규분포를 따를 경우,

$$\text{검정통계량} \quad t_i = \frac{Y_i - \widetilde{Y}_i}{\widehat{\sigma}_{(i)} [1 + x_i' (X_{(i)}' X_{(i)})^{-1} x_i]^{1/2}} \sim t(n-k-2)$$

(4) $H_0 : E(Y_i - \widetilde{Y}_i) = 0$, $H_1 : E(Y_i - \widetilde{Y}_i) \neq 0$ 에 대해 유의수준 α 검정법은 만일,

$$|t_i| \geq t_{n-k-2}(\alpha/2) \text{이면 } H_0 \text{를 기각}$$

*** 이상점 탐지에서의 유의점**

- (i) 두 개 이상의 이상점이 이웃하면 서로의 이상점 효과가 상쇄될 수 있다.
- (ii) 어떤 모형에서의 이상점은 변수변환 등을 하여 다른 모형으로 적합할 경우 이상점이 아닐 수 있다. 그러므로 모형이 변하면 이상점을 다시 조사해야 한다.
- (iii) 오차항이 정규분포를 따르지 않을 경우에서 잔차가 크더라도 오차 분포 특성에 의한 것으로 이상점이 아닐 수 있다.
- (iv) 데이터셋이 클 경우 한 두 개의 이상점은 문제가 되지 않지만 이상점이 그룹을 형성하는 경우에는 분석에 주의해야 한다.

*** 이상점에 대해 취해야 할 방법**


- (i) 데이터 입력 오류를 검사한다.
- (ii) 이상점의 상황에 대해 알아본다.
- (iii) 이상점을 제거하고 분석한다. 그리고 분석 결과에서 제거한 이상점에 대해 설명한다.
그러나 새로운 모형을 적합할 경우 제거했던 이상점을 다시 포함시켜 분석해야 한다.
- (iv) 이상점으로 보이지만 실제 가능한 경우라면 이들을 포함한 적절한 모형,
예를 들어, 로버스트(robust) 회귀식 등을 찾아야한다.

[예제 5.1] `library(car)` 내장데이터 `mtcars`에 대한 회귀분석과 회귀진단을 하고자 한다.
이 데이터는 여러 가지 차종에 대한 특성 변수들을 측정한 데이터이다.

5.5 회귀진단 후 보정 방법

5.5.1 잔차그림

- 독립성 가정을 만족한다면 잔차들은 0을 중심으로 랜덤하게 퍼져야 한다.



(a) : 랜덤한 형태(이상적)

(b) : 오른쪽으로 분산 증가하는 메가폰 형태

(c) : 오른쪽으로 분산 감소하는 형태


(d) : 분산이 증가했다 감소하는 형태

(1) (반응변수 추정값 $\hat{Y}_i$, 스튜던트화 잔차 r_i):


(2) (관측값 순서, 스튜던트화 잔차) 그림: 순서에 따른 경향을 볼 수 있다.

(3) (설명변수, 스튜던트화 잔차) 그림: 설명변수에 따른 경향을 볼 수 있다.


$|r_i| \leq 2$ 이면 잔차가 근사적으로 정규분포를 따를 경우 95% 이내의 값이 된다.




(a) 비선형성-곡선경향



(b) 비선형성



(c) 비독립성-양의상관



(d) 비독립성-음의상관

5.5.2 정규성을 만족하지 않는 경우

- 잔차가 정규성을 벗어나면 정규성 가정을 만족시키지 못하므로 다른 모형을 찾아야 한다.
- Box-Cox 변환의 목적은 전환 후, 오차항이 거의 정규분포를 따르도록 만드는 것이다.
- Box-Cox 변환을 통해 $Y^\lambda = X\beta + \epsilon$, $Var(\epsilon) = \sigma^2 I$ 을 만족하는 λ 구하고자 함.
 - $Y^\lambda = (Y_1^\lambda, Y_2^\lambda, \dots, Y_n^\lambda)'$ 이다.
- Box-Cox 변환(Box-Cox transformation)
 - $Y > 0$ 인 경우 다음과 같은 변환식을 이용

$$Y^{(\lambda)} = \begin{cases} \frac{Y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln Y, & \lambda = 0 \end{cases}$$

- λ 는 $l(\lambda) = -\frac{n}{2} \ln \left[\frac{1}{n} \sum_{i=1}^n (Y_i^{(\lambda)} - \overline{Y^{(\lambda)}})^2 \right] + (\lambda - 1) \sum_{i=1}^n \ln Y_i$ 을 최대화 하는 상수로 결정

- 반응변수에 대한 변환은 모형 해석이 어려워질 수 있으므로 주의해야함.

(cf) 검토를 위해 λ 에 대한 신뢰구간을 구해보거나 $H_0 : \lambda = \lambda_0$ 에 대한 카이제곱 검정 시행.

λ 에 대한 $100(1 - \alpha)\%$ 신뢰구간은

$$\{\lambda : L(\lambda) > L(\hat{\lambda}) - \frac{1}{2}\chi_1^2(\alpha)\}$$

$$- P(\chi^2 \geq \chi_1^2(\alpha)) = \alpha$$

검정통계량 $T = 2(L(\hat{\lambda}) - L(\lambda_0))$ 는 $H_0 : \lambda = \lambda_0$ 하에서

근사적으로 자유도 1인 카이제곱분포를 따른다.

그러므로 유의수준 α 에서 카이제곱검정법은 만일 $T \geq \chi_1^2(\alpha)$ 이면 H_0 를 기각

[예제 5.2] Galapagos 섬 데이터에 대해 다중선형회귀모형을 적합하고자 한다. 반응변수에 대한 Box-Cox 변수 변환을 고려하고자 하며 적절한 λ 값을 구하고자 한다.

5.5.3 등분산이 아닌 경우

- 등분산 가정은 오차항의 분산이 반응변수에 의존하지 않음을 의미
- 등분산 가정을 만족하지 않는다면 다음의 방법을 고려할 수 있다.

(1) 가중최소제곱회귀모형을 적합한다.

(2) 반응변수에 대한 분산안정화 변환(variance stabilizing transformation)

변환식	분산에 대한 상황	설명
$\sqrt{Y}$	$var(\epsilon_i) \propto E(Y_i)$	분산이 기댓값과 비례하는 경우
$\sqrt{Y+1}$	$var(\epsilon_i) \propto E(Y_i)$	Y_i 값이 0 또는 0에 가까운 경우
$\log Y$	$var(\epsilon_i) \propto [E(Y_i)]^2$	가장 많이 활용되는 변환. $Y(>0)$ 의 범위가 큰 경우
$\log(Y+1)$	$var(\epsilon_i) \propto [E(Y_i)]^2$	$Y=0$ 이 존재하는 경우
$\frac{1}{Y}$	$var(\epsilon_i) \propto [E(Y_i)]^4$	$Y(>0)$ 작은 값을 많이 갖는 경우
$\frac{1}{Y+1}$	$var(\epsilon_i) \propto [E(Y_i)]^4$	$Y=0$ 이 존재하는 경우
$\sin^{-1}(\sqrt{Y})$	$var(\epsilon_i) \propto E(Y_i)(1-E(Y_i))$	이항분포를 따르는 변수인 경우

5.5.4 선형이 아닌 경우

- 적합된 추정값과 잔차에 대한 산점도에서 잔차들이 모형에서 가정한 선형성 대신, 곡선 경향 등 비선형성을 나타낼 경우, 변환 등을 통한 보정을 할 수 있음.
- 다중회귀의 경우, 추가변수그림 또는 부분잔차그림 등을 통해 비선형성을 진단할 수 있다.

(예) $Y = \alpha X^\beta$ 을 적합하고자 하는 경우 로그 변환을 통해 선형회귀모형

$\log Y = \log \alpha + \beta \log X + \epsilon$ 을 고려할 수 있다.

선형화 변환

변환식		단순회귀식	다중회귀식
$\log Y$	$\log X$	$Y = \alpha X^\beta$	$y = \alpha X_1^{\beta_1} X_2^{\beta_2} \cdots X_k^{\beta_k}$
$\log Y$	X	$Y = \alpha e^{\beta X}$	$y = \alpha e^{\sum \beta_j X_j}$
Y	$\log X$	$Y = \alpha + \beta \log X$	$y = \alpha + \sum \beta_j \log X_j$
$\frac{1}{Y}$	$\frac{1}{X}$	$Y = \frac{X}{\alpha X + \beta}$	$y = \frac{1}{\alpha + \sum \beta_j X_j}$
$\frac{1}{Y}$	X	$Y = \frac{1}{\alpha + \beta X}$	$y = \frac{1}{\alpha + \sum \beta_j X_j}$
Y	$\frac{1}{X}$	$Y = \alpha + \beta \left(\frac{1}{X} \right)$	$y = \alpha + \sum \beta_j \left(\frac{1}{X_j} \right)$

5.6 R활용 회귀진단

R에서는 `ls.diag()` 함수로 여러 가지 회귀진단을 할 수 있다.

R 내장 회귀진단 함수 `ls.diag(lm object)` 에 포함된 함수 및 통계량

통계량 함수	회귀진단 내용
<code>std.dev</code>	오차항의 표준편차
<code>hat</code>	모자행렬(hat matrix) H 의 대각선에 놓인 값 h_{ii}
<code>std.res</code>	표준화(standardized) 잔차
<code>stud.res</code>	스튜던트화(studentized) 잔차
<code>cooks</code>	Cook's distance 통계량
<code>dts</code>	DFITS 통계량
<code>correlation</code>	상관행렬
<code>std.err</code>	회귀계수에 대한 표준오차(standard error)
<code>cov.scaled</code>	회귀계수에 대한 수정(scaled) 공분산행렬
<code>cov.unscaled</code>	회귀계수에 대한 무수정(unscaled) 공분산행렬

[예제 5.3] R 시스템에 내장된 `longley` 데이터셋에 대해 다중선형회귀모형을 적합하고 진단하고자 한다.