

(표준화된 회귀계수: Standardized regression coefficients)

- ☞ 설명변수들의 단위가 다를 때, 원 회귀계수의 절대크기는 의미가 없음
- ☞ 표준화된 회귀계수를 사용하여 설명변수들의 상대적인 효과 크기를 비교

제6장. 모형 비교와 변수선택법


6.1 다중공선성(multicollinearity)

- 설명변수 간에 연관성이 높으면, 즉 설명변수를 다른 설명변수에 의존하게 되어 회귀모형 추정에 문제가 생기므로, 다중회귀분석에서 설명변수들 간의 다중공선성 확인필요!
- 설명변수들 간의 상관관계가 높으면 최소제곱추정량의 분산이 커지는 문제가 발생하는데, 이 때 설명변수들 간에 **다중공선성이 존재**한다고 한다.
- 설명변수에 대해 상수항 c_0, c_1, c_2 로 다음의 선형식


$$c_1X_1 + c_2X_2 = c_0$$

이 성립되면, 두 변수 간 완전한 공선성이 존재(collinear)


(예제) 그림과 같이 두 설명변수 X_1, X_2 의 공선성이 존재하는 경우에 이 변수들을 회귀모형에 포함하면 추정하는 데 문제가 발생



<두 변수 간 완벽한 공선성>



(a) 이상점이 공선성을 유도하는 경우



(b) 이상점이 공선성을 숨기는 경우

(a) : 이상점 때문에 두 변수 간의 관련성이 높아진다.

(b) : 이상점을 숨기는 경우, 즉 이상점을 제거하면 두 변수 간의 관련성이 높아진다.

- 설명변수 중 한 개가 다른 설명변수들의 선형조합으로 표현된다면 $X'X$ 가 singular이므로 $X'X$ 의 역행렬을 구할 수 없어 회귀계수 β 에 대한 최소제곱추정량을 구하는데 어려움.
- 설명변수가 2개인 다중회귀모형을 고려해보자.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$$

- X_1 과 X_2 의 상관계수를 r_{12} 라고 할 때,

$$Var(\hat{\beta}_j) = \sigma^2 \left(\frac{1}{1 - r_{12}^2} \right) \left(\frac{1}{S_{X_j X_j}} \right), \quad j = 1, 2$$

$$\text{여기에서, } S_{X_j X_j} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

- $Var(\hat{\beta}_1)$ 과 $Var(\hat{\beta}_2)$ 은 $r_{12} = 0$ 일 때 최소값
- $r_{12} \approx 1$ 이면 $\hat{\beta}_1$ 과 $\hat{\beta}_2$ 의 분산은 크게 팽창되어 회귀계수의 추정값은 불안정

(Fact) 다중선형회귀모형에서 개별 회귀계수의 다른 표현

- k 개의 설명변수 $X_1, X_2, \dots, X_k$ 와 일변량 반응변수 Y 간의 선형회귀모형은 다음과 같이 표현

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k + \epsilon$$

- j 번째 회귀계수의 추정량은

$$\hat{\beta}_j = \frac{Z_j^T Y}{Z_j^T Z_j}$$

- $Z_j \in R^n$ 는 X_j 를 반응변수로 나머지 설명변수 ($X_i : i \neq j$)로 회귀분석 한 후의 잔차
- Z_j 와 Y 의 단순선형회귀모형에서의 추정량
- 이것은 나머지 설명변수들을 이용한 X_j 의 직교화: $Z_j^T X_i = 0, i \neq j$

- $X_1, \dots, X_p$ 가 서로 직교라면, 다중선형회귀모형에서 회귀계수는 각각의 변수를 사용한 단순선형회귀모형에서의 회귀계수와 정확히 일치
 - X_j 는 다른 설명변수와 직교이기 때문에, $Z_j = X_j - 0 = X_j$
 - 따라서, $\hat{\beta}_j = \frac{Z_j^T Y}{Z_j^T Z_j} = \frac{X_j^T Y}{X_j^T X_j}$
- $X_1, \dots, X_p$ 가 높은 상관이 존재한다면,
 - 나머지 설명변수들로의 회귀분석 후의 예측치와 X_j 는 거의 비슷함: $Z_j \approx 0$
(극단적으로 X_j 와 $(X_i : i \neq j)$ 이 같은 공간에 있으면 예측치는 똑같음)
 - 따라서, $\hat{\beta}_j = \frac{Z_j^T Y}{Z_j^T Z_j}$ 는 상당히 불안정
 - 또한, $Var(\hat{\beta}_j) = \frac{Var(Z_j^T Y)}{(Z_j^T Z_j)^2} = \frac{\sigma^2}{(Z_j^T Z_j)}$ 로 분산이 커짐
 - 이러한 현상을 다중공선성이 존재한다고 함

• 다중공선성이 판단되는 경우

- (1) 설명변수들 간의 상관행렬에서 절대값이 큰 상관계수를 갖는 경우
- (2) j 번째 설명변수를 반응변수 위치에 놓고 나머지 설명변수들로 회귀모형을 적합했을 때 결정계수 R_j^2 이 1에 가까운 경우
- (3) $X'X$ 의 고유값을 구한 후 크기 순서대로 나열한 후, 가장 큰 고유값을 λ_1 이라 하자.
 $\lambda_1 > \lambda_2 > \dots > \lambda_{k+1}$ 을 만족하며 가장 작은 고유값 λ_{k+1} 에 대해 조건수

$$\kappa = \sqrt{\frac{\lambda_1}{\lambda_{k+1}}}$$

만일 $\kappa \geq 30$ 이면 다중공선성이 있다고 판단.

- 분산팽창인수(VIF, variance inflation factor): 다중공선성을 조사하는 방법으로 널리 쓰임

$$VIF_j = \frac{1}{1 - R_j^2}, \quad j = 1, 2, \dots, k$$

- 공차한계(tolerance) = $1 - R_j^2$
- R_j^2 은 j 번째 설명변수를 반응변수 위치에 놓고 나머지 설명변수들로 회귀모형을 적합했을 때의 결정계수
- 만약, j 번째 설명변수가 나머지 변수들의 선형종속이면 $R_j^2 \approx 1$ 이고, $\frac{1}{1 - R_j^2}$ 은 커진다.
- $R_j^2 \geq 0.60$ 인 경우, 즉 $VIF_j \geq 2.50$ 이면 다중공선성 의심
- 일반적으로,
 - * VIF_j 의 값의 최대값이 5 혹은 10 이상이면 다중공선성을 의심
 - * tolerance가 0.2 혹은 0.1 이하면 다중공선성 의심

- 다중공선성을 제거하려면,

- 1) 상관성이 큰 설명변수를 제거한 후 분석하거나
- 2) 모든 설명변수를 포함시키고자 한다면 능형회귀(ridge regression) 등의 대안 모형 모색

6.2 모형 비교와 F-검정

- k 개의 설명변수가 있는 다중회귀모형에서 고려해보면,

$$Y = X\beta + \epsilon$$

여기서 Y 는 $n \times 1$ 벡터, X 는 $n \times (k+1)$ 벡터, β 는 $(k+1) \times 1$ 벡터, ϵ 는 $n \times 1$ 벡터.

만약 X 를 X_1 과 X_2 로 분할하고, β 를 β_1 과 β_2 로 분할하여 다시 식을 쓰면

$$Y = X_1\beta_1 + X_2\beta_2 + \epsilon.$$

여기서 β_1 은 $p \times 1$ 벡터, β_2 는 $(k+1-p) \times 1$ 벡터,

일부의 설명변수 X_2 를 제거한 축소모형 $Y = X_1\beta_1 + \epsilon$ 이 된다.

축소모형에서의 β_1 에 대한 추정

$$\hat{\beta}_1 = (X_1'X_1)^{-1}X_1'Y$$

- $Y = X_1\beta_1 + X_2\beta_2 + \epsilon$, $Y = X_1\beta_1 + \epsilon$ 이 두 모형 비교를 위한 가설 검정.

$$H_0 : Y = X_1\beta_1 + \epsilon \quad H_1 : Y = X_1\beta_1 + X_2\beta_2 + \epsilon$$

$$F = \frac{(RSS_{H_1} - RSS_{H_0}) / (df_{H_1} - df_{H_0})}{RSS_{H_0} / df_{H_0}} \sim {}^{H_0}F(df_{H_1} - df_{H_0}, df_{H_0})$$

RSS_{H_0} : H_0 하에서의 잔차제곱합이며 자유도는 df_{H_0}

RSS_{H_1} : H_1 하에서의 잔차제곱합이며 자유도는 df_{H_1}

F -통계량이 클수록 또는 $F \geq F_{df_{H_0} - df_{H_1}, df_{H_1}}(\alpha)$ 이면 귀무가설 기각

6.3 변수선택

- 단계별 변수선택법:

유의한 설명변수를 추가하거나 제거함으로써 유의한 설명변수만으로 회귀모형을 설정
최적의 설명변수들의 부분집합을 찾는 방법

=> 전진적 선택법(forward selection), 후진적 선택법(backward selection),
단계별 선택법(stepwise selection)

- 변수선택법 절차

- ① 설명변수들 중 반응변수와 상관관계가 가장 크고 설명력이 유의한 설명변수를 먼저 선택
- ② 선택된 설명변수를 제외한 나머지 설명변수를 하나씩 추가하여 유의한 설명변수 선택
- ③ 새로 선택된 설명변수가 먼저 선택되었다는 가정 하에 이미 추가된 설명변수의 유의성에 대한 F -검정 시행.
- ④ ③에서 유의하지 않는 설명변수 제외
- ⑤ 위의 과정을 반복하면서 추가된 모형이 전 단계의 모형보다 유의하지 않으면 추가된 모형을 최종모형으로 결정.

• 최종모형을 선택하기 위한 측도

1) 수정된 결정계수

$$R_{adj}^2 = 1 - \frac{SSE_p / (n-p)}{SST / (n-1)} = 1 - (1 - R_p^2) \left(\frac{n-1}{n-p} \right)$$

- p 는 현재모형에 포함된 회귀계수의 개수
- 결정계수 R^2 은 모형에 중요하지 않은 독립변수가 추가되는 경우에도 값이 증가하기 때문에 이를 해결하기 위한 통계량
- R_{adj}^2 로 변수를 선택하는 것은 $MSE_p = SSE_p / (n-p)$ 로 변수를 선택하는 것과 동일 (SST 는 고정), 즉, R_{adj}^2 가 작을수록 좋은 모형

2) Mallows' C_p 통계량: n 개의 적합값 $\hat{Y}_i$ 의 총 평균제곱오차에 기반한 척도

$$C_p = \frac{SSE_p}{MSE_{full}} - (n - 2p)$$

- p 는 현재모형에 포함된 회귀계수의 개수
- SSE_p : 현재모형에서의 SSE
- MSE_{full} 은 최대모형에서의 MSE
- C_p 가 작을수록 좋은 모형
- 현재모형이 좋은 모형이라면, $SSE_p \approx (n - p)MSE_{full} = SSE_{full}$
 이때, $C_p \approx (n - p) - (n - 2p) = p$ 가 되면 좋은 모형이라 판단
- 최대모형에서는 항상 $C_p = p$

- C_p 통계량은 n 개의 적합값 $\hat{Y}_i$ 의 총평균제곱오차에 기반한 측도

- i 번째 적합값의 평균오차제곱은

$$E(\hat{Y}_i - \mu_i)^2 = \text{Var}(\hat{Y}_i) + \{E(\hat{Y}_i) - \mu_i\}^2$$

$$- \sum_{i=1}^n \{ \text{Var}(\hat{Y}_i) + (E(\hat{Y}_i) - \mu_i)^2 \} / \sigma^2 = \frac{E(SSE_p)}{\sigma^2} - (n - 2p)$$

- 따라서, C_p 통계량은 n 개의 적합값에 대한 평균제곱오차에서 $E(SSE_p)$ 와 σ^2 대신 그들의 추정치인 SSE 와 MSE_{full} 로 대체하여 만든 통계량임.

[예제6.1] 예제5.1에서 다룬 데이터에 대해 모형비교와 변수선택 문제를 고려해보자.