


제7장. 아이스크림 데이터에 의한 다중회귀분석

7.1 아이스크림 데이터

아이스크림 섭취량과 아이스크림의 가격, 가족의 월수입, 평균기온의 관계를 연구하기 위한 회귀모형을 개발하기 위하여 다음의 자료를 수집하였다.

<표 7.1> 변수 설명 및 기초통계량

변수이름		설명	평균	표준편차
IC	Y	아이스크림 섭취량 (단위: pint)	0.3594	0.06579
price	X_1	아이스크림 가격 (단위: dollar)	0.2753	0.00834
income	X_2	가족의 월수입 (단위: dollar)	84.60	6.24555
temp	X_3	평균기온 (단위: fahrenheit)	49.10	16.4219



아이스크림의 가격, 가족의 월수입, 평균기온의 각 변수에 대한 아이스크림 소비량의 산점도를 보면 아이스크림 소비량은 평균기온과 선형적 관계를 가짐을 알 수 있다.

7.2 다중선형회귀분석

세 개의 설명변수 아이스크림 가격(X_1), 가족의 월수입(X_2), 평균기온(X_3)과 아이스크림 소비량 Y 와의 다중선형회귀모형

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \epsilon_i, \quad i = 1, 2, \dots, 30 \quad (7.1)$$

오차항 ϵ_i 는 독립이며 평균 0, 분산 σ^2 인 정규분포를 가정한다.

모형 (7.1)을 행렬로 표현하면,

$$Y = X\beta + \epsilon \quad (7.2)$$

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \vdots \\ Y_{30} \end{pmatrix}, \quad X = \begin{pmatrix} 1 & X_{11} & X_{12} & X_{13} \\ 1 & X_{21} & X_{22} & X_{23} \\ 1 & X_{31} & X_{32} & X_{33} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & X_{30,1} & X_{30,2} & X_{30,3} \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}, \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \vdots \\ \epsilon_{30} \end{pmatrix} \quad (7.3)$$

Y 는 반응변수 벡터, X 는 30x4인 설계행렬, β 는 회귀계수벡터, ϵ 은 오차벡터이다.

<표7.2> 완전모형에 대한 회귀계수 최소제곱 추정

회귀계수	추정값	표준오차	t-통계량	p-값
절편(β_0)	0.19732	0.27022	0.73	0.4718
아이스크림 가격(β_1)	-1.04441	0.83436	-1.25	0.2218
가족의 월수입(β_2)	0.00331	0.00117	2.82	0.0090
평균기온(β_3)	0.00346	0.00044555	7.73	<0.001

추정된 회귀식

$$\hat{Y} = 0.197 - 1.044X_1 + 0.003X_2 + 0.003X_3 \quad (7.4)$$

$$MSE=0.0013, R^2=0.719, \text{수정 } R^2=0.6866$$

$\therefore R^2$ (전체 변동 중 적합된 회귀식에 의해 설명되는 비율)이 높으므로 설명력이 높은편이다.

7.3 단계별 회귀에 의한 변수선택

유의하지 않은 설명변수인 아이스크림 가격(β_1)을 제거

<표7.3> 단계별 회귀변수 선택법의 최종요약

단계	변수삽입	부분 결정계수	모형 결정계수	C_P	F-통계량	p-값
1	temp	0.6016	0.6016	10.8624	42.28	<.0001
2	income	0.1005	0.7021	3.5669	9.10	0.0055

<표7.4> 축소모형에 대한 회귀계수 최소제곱 추정

변수	회귀계수추정값	표준오차	부분제곱합	F-통계량	p-값
절편	-0.11320	0.10828	0.00151	1.09	0.3051
월평균수입	0.00353	0.00117	0.01261	9.10	0.0055
평균기온	0.00354	0.00044496	0.08784	63.41	<.0001

추정된 회귀식

$$\hat{Y} = 0.197 - 1.004X_1 + 0.003X_2 + 0.003X_3 \quad (7.4)$$

$$MSE=0.00139, R^2=0.7021$$

7.4 다중공선성


다중공선성에 대한 확인방법으로 분산팽창인수를 고려하고자 한다.

다중공선성을 확인해야 할 조건

- ① 분산팽창인수 = $1/\text{tolerance}$ 에서 tolerance가 0.4이하
- ② 분산팽창인수(VIF)가 2.50 이상

변수	자유도	tolerance	분산팽창인수(VIF)
아이스크림 가격	1	0.96556	1.03567
월평균 가족수입	1	0.87398	1.14419
평균기온	1	0.87385	1.14437

결과: $VIF < 2.00$ 이고 $\text{tolerance} > 0.40$ 이므로 다중공선성 문제는 고려하지 않아도 된다.




<그림7.2> 회귀계수간의 상관관계

그림 <7.2>는 회귀계수간의 상관관계 크기를 보여주는 그림이다. 절편 β_0 와 아이스크림의 가격 β_1 의 상관관계가 높음을 알 수 있는데 변수들간의 관계가 아니므로 다중공선성 결과에 영향을 미치지 않는다.


7.5 지렛대점과 이상점

영향점을 진단하는 방법인 지렛대점, 모자행렬, 잔차 등을 이용하여 이상점을 찾아볼 수 있다.

(a) <쿡의 거리>





(b) <DFFITS>



<그림 7.4> 아이스크림 데이터의 지렛대점

<그림 7.5> 아이스크림 데이터에 대한 스튜던트화 잔차와 모자행렬



- ① 그림(a)는 각 개체 i 에 대한 쿡의 거리값을 나타낸다. 이 값이 클수록 이상점 혹은 영향점일 가능성이 높다. (기준값=1)

30번째 관측값은 쿡의거리값이 1보다 크므로 이상치일 이상점일 가능성이 높다.

- ② 그림(b)는 각 개체 i 에 대한 DFFITS값을 나타낸다. DFFITS값이 완전모형의 $\hat{Y}_i$ 와 차이가 크다면 이상점 혹은 영향점일 가능성이 높다.

$$(\text{기준값} = 2\sqrt{\frac{k+1}{n-k-1}} = 2\sqrt{\frac{4+1}{30-4-1}} = 0.89)$$

30번째 관측값은 DFFITS값이 0.89보다 크므로 관측이 영향점 혹은 이상점일 가능성이 높다.

- ③ 그림 <7-4>는 모자행렬의 대각원소 h_{ii} 의 지렛대의 기울기와 영향점을 나타낸다. 관측값 Y_i 가 지렛대 점에 상응되어 나타나면 좋은 점이다. 관측값 Y_{30} 은 최소제곱선에서 멀리 떨어져 있고 다른 관측값에 비해 데이터 추세에도 벗어나있으므로 이상점일 가능성이 높다.

- ④ 그림 <7.5>는 지렛대값에 대한 스튜던트화 잔차와 더불어 쿡의 거리를 원의 크기로 표현한 잔차그림이다. 관측값 Y_{30} 은 스튜던트화 잔차가 범위 -2와 2 사이를 벗어나므로 이상치일 가능성이 높다.

7.6 모형 제안 및 예측

이상점으로 판단된 30번째 관측을 제거한 후 최종모형

<표 7.6> 아이스크림 값 변수(X_1)과 이상점(Y_{30}) 제거 후 축소된 회귀모형 추정

회귀계수	추정값	표준오차	95% 신뢰구간		t-통계량	p-값
절편(β_0)	-0.02240	0.09882	-0.22554	0.18074	-0.23	0.8225
월평균 가족수입(β_2)	0.00265	0.00106	0.00047924	0.00483	2.51	0.0187
평균기온(β_3)	0.00313	0.00041027	0.00229	0.00397	7.63	<.0001

$$\hat{Y} = -0.0224 + 0.00265X_2 + 0.00313X_3.$$

<표 7.7> 완전모형(설명변수 3개)과 축소모형(설명변수 2개) 비교

	추정량	완전모형A	축소모형B	축소모형(30번째 제거) C
회귀모수	절편(β_0)	0.19732	-0.11320	-0.0224
	아이스크림 가격(β_1)	-1.04441		
	월평균 가족수입(β_2)	0.00331	0.00353	0.00265
	평균기온(β_3)	0.00346	0.00354	0.00313
적합도	MSE	0.001357	0.001385	0.001052
	잔차자유도	26	27	26
	RSE(잔차 표준편차)	0.0368	0.0372	0.0324
	R^2	0.7190	0.7021	0.6918
	Adjusted R^2	0.6866	0.6800	0.6681
	C_p	4.0000	3.5600	3.0000

축소모형의 수정된 R^2 가 완전모형의 수정된 R^2 보다 더 작고, C_p 를 고려해보면 모형 B보다 모형 C가 더 적합하다. 하지만 β_1 이 중요한 변수라면 완전모형을 선택할 수도 있다.

<표 7.8> 변수의 평균 추정값과 95% 신뢰구간

변수	평균	95% 신뢰하한	95% 신뢰상한
월평균 소득	84.4137931	82.0285166	86.7990696
평균기온	48.3448276	42.1926510	54.4970042
아이스크림 섭취량	0.3529310	0.3315170	0.3743450

아이스크림 섭취량의 예측값

$$\hat{y}^* = -0.0224 + 0.00265 \times 84.41 + 0.00312 \times 48.34 = 0.3511 \text{ (pints)}$$


아이스크림 섭취량의 95% 신뢰구간

$$\hat{y}_* \pm t_{26}(0.025)s \sqrt{x_*'(X'X)^{-1}x_*} = (0.2788, 0.4253)$$

여기서 $x_* = (1, X_{*2}, X_{*3})' = (1, 48.43, 84.41)'$, $s = 0.0324$, $t_{26}(0.025) = 2.055$ 이다.

$X_* = (X_{*2}, X_{*3})'$ 에서 아이스크림 소비량의 95% 예측 신뢰구간은

$$\hat{y}_* \pm t_{26}(0.025)s \sqrt{1 + x_*'(X'X)^{-1}x_*} = (0.2531, 0.4510)$$




<그림 7.7> 아이스크림 소비량에 대한 95% 신뢰구간과 예측구간

점선(-----): 신뢰구간

가는 점선(.....): 추정구간

7.7 잔차분석

(a) Q-Q 그림



(b) 잔차그림





그림 (a)는 스튜던트화 잔차에 대한 t-분포 Q-Q그림이다. 점들이 직선에 가깝게 위치하여 있다. 그림 (b)는 잔차등이 전반적으로 수평대 이내에 놓여있고 음양의 값이 랜덤하게 나타나고 있으므로 선형성을 만족한다.



<그림 7.9> 아이스크림 데이터에 대한 편잔차 그림

<그림 7.9>의 직선을 살펴보면 선형성을 만족하는 점선에 가까운 편이므로 수입과 기온은 선형성을 크게 벗어나지 않는다.