

제8장. 일반화 가중회귀모형

8.1 일반화 회귀모형

- k 개 설명변수 $X_1, X_2, \dots, X_k$ 와 반응변수 Y 에 대한 다중선형회귀모형

$$Y = X\beta + \epsilon$$

오차벡터 ϵ 은 $E(\epsilon) = 0, \text{Var}(\epsilon) = \sigma^2 I$ (4장)

- 오차항이 서로 독립이 아니고 공분산을 갖는 경우는 추정된 최소제곱추정량이 불편추정량이 되어도 최소분산을 갖지 않음. (Gauss-Markov 정리에서 가정이 성립하지 않음)
- 오차항이 공분산을 갖는 다중선형회귀모형

$$Y = X\beta + \epsilon$$

오차벡터 ϵ 은 $E(\epsilon) = 0, \text{Var}(\epsilon) = \sigma^2 \Sigma$

Σ 는 공분산행렬로 대칭인 양정치 행렬, Y 와 ϵ 은 $n \times 1$ 벡터

X 는 $n \times (k+1)$ 행렬, β 는 $(k+1) \times 1$ 벡터

8.2 최소제곱법을 이용한 모수추정

- 회귀계수 β 의 추정량 $\hat{\beta}$ 을 구하기 위한 일반화 최소제곱법:

$$RSS(\beta) = (Y - X\beta)' \Sigma^{-1} (Y - X\beta)$$

- $RSS(\beta)$ 을 최소화 하도록 하는 방법으로 일반화 최소제곱추정량은

$$\hat{\beta} = (X' \Sigma^{-1} X)^{-1} X' \Sigma^{-1} Y$$

- $\text{Var}(\epsilon) = \sigma^2 \Sigma$ 에 대해 $C' C = C C' = \Sigma^{-1}$ ($C^{-1} [C^{-1}]' = \Sigma$)를 만족하는 대칭행렬 C

$$C = \Sigma^{-1/2}$$

- C 를 이용하면 위 회귀모형을 다시 표현하면,

$$CY = CX\beta + C\epsilon$$

- $Z = CY$, $M = CX$, $d = C\epsilon$ 로 놓으면,

$$Z = M\beta + d$$

- 이때, 행렬 C 에 의해 변환된 오차벡터에 대한 공분산 행렬

$$\text{Var}(d) = \text{Var}(C\epsilon) = C\sigma^2\Sigma C' = \sigma^2 CC^{-1}[C^{-1}]'C' = \sigma^2 I$$

- 최소제곱추정량: $\hat{\beta} = (M'M)^{-1}M'Z$

$$- X \text{와 } Y \text{로 표현하면, } \hat{\beta} = (X'\Sigma^{-1}X)^{-1}X'\Sigma^{-1}Y$$

- 실제 자료 분석에서 행렬 C 를 구해 변환된 자료에 최소제곱법을 이용하는 것이 편리

- 오차항이 서로 독립이며 분산이 서로 다른 경우에 대해 회귀계수 벡터구하기:

$$- \text{오차항의 공분산행렬은 } \Sigma = W^{-1} \text{이라 하면, } W^{-1} = \begin{pmatrix} \frac{1}{w_1} & & 0 \\ \vdots & \frac{1}{w_2} & \vdots \\ 0 & & \frac{1}{w_n} \end{pmatrix}$$

$$- \Sigma^{-1} \text{의 제곱근 행렬 } C = \begin{pmatrix} \sqrt{w_1} & & 0 \\ & \sqrt{w_2} & \\ 0 & & \sqrt{w_n} \end{pmatrix}$$

- 회귀계수 추정: $\hat{\beta} = (M'M)^{-1}M'Z$

– 여기에서,

$$M = \begin{pmatrix} \sqrt{w_1} & \sqrt{w_1} X_{11} & \cdots & \sqrt{w_1} X_{1k} \\ \sqrt{w_2} & \sqrt{w_2} X_{21} & \cdots & \sqrt{w_2} X_{2k} \\ & & \ddots & \\ \sqrt{w_n} & \sqrt{w_n} X_{n1} & \cdots & \sqrt{w_n} X_{nk} \end{pmatrix}, \quad Z = \begin{pmatrix} \sqrt{w_1} Y_1 \\ \sqrt{w_2} Y_2 \\ \vdots \\ \sqrt{w_n} Y_n \end{pmatrix}$$

[예제 8.1] 양자충돌 실험에서 다음의 데이터를 얻었다. 입자 a 가 빛의 속도로 움직이며

(프로그램 9.1) 총에너지는 $s = 2m_p p_a^{lab}$ 으로 근사된다. 물리학 이론적으로 다음의 관계식

$$Y = \beta_0 + \beta_1 s^{-1/2} + \text{small terms}$$

을 만족할 때 회귀모형을 적합하고자 한다. 여기서 s 의 단위는 $(GeV)^2$, $1GeV = 1 \times 10^9$ 전자볼트로 인자가 가속되어 도달하는데 필요한 에너지, 양자에 대한 질량은

$m_p = 0.938 GeV$, p_a^{lab} 는 a 빔줄기에 대한 모멘트이다.

p_a^{lab} (GeV/c) momentum	$s^{-1/2}$ (GeV/c ⁻¹) x	(μb) Y	σ estimated standard deviation
4	0.345	367	17
6	0.287	311	9
8	0.251	295	9
10	0.225	268	7
12	0.207	253	7
15	0.186	239	6
20	0.161	220	6
30	0.132	213	6
75	0.084	193	5
150	0.060	192	5

[예제 8.2] McIntosh 사과나무의 어린가지에 관한 데이터가 <표8.2>와 같다. 평균 줄기 길이 $\bar{y}$ 와 저장일수 day 와의 관계를 다음의 회귀모형 $Y = \beta_0 + \beta_1 day + \epsilon$ 으로 구하고자 한다. 여기서 $\bar{y}$ 값은 n 가지 수에 대한 평균값이므로 오차항의 분산은 가지수 n 에 의존하게 된다. $\epsilon \sim N(0, \frac{\sigma^2}{n})$ 을 가정한다. 가중값 n 을 고려한 가중회귀식을 구하고자 한다.

8.3 R활용 가중회귀분석

- R에서는 `lm()` 함수에서 `weight` 옵션을 이용하여 가중 선형회귀분석을 할 수 있다.

예제 8.3에서는 오차항의 자기상관을 고려한 가중회귀 예를 보여준다.

[예제 8.3] R 시스템 내장 데이터 `data(longley)` 에서의 1947년부터 1962년까지 데이터에 대해 GNP와 인구수를 설명변수로 하고 취업자 수를 반응변수로 하여 가중회귀분석을 하고자 한다.